



دانشکده مهندسی برق و کامپیوتر

پایان نامه برای دریافت درجه کارشناسی
در رشته مهندسی کامپیوتر گرایش نرم افزار

عنوان:

ترجمه ی زبان اشاره (ناشنوایان) با استفاده از یادگیری عمیق

دانشجو:

یاسمین توکلی

استاد راهنما:

دکتر حسام عمران پور

خرداد ۱۴۰۲

C

چکیده

زبان اشاره ابزاری ارتباطی است که به افراد ناشنوا و کم شنوا این امکان را می‌دهد تا با افراد دیگر ارتباط برقرار کنند. زبان اشاره با تکیه بر حرکات بصری، به افراد ناشنوا و کم شنوا، امکان ارتباط بدون نیاز به خواندن لب‌ها یا تبادلات نوشتاری را می‌دهد.

زبان اشاره از جهات زیادی حائز اهمیت است از جمله ارتباط و دسترسی به اطلاعات. زبان اشاره راه ارتباطی بین افراد ناشنوا و کم‌شنوا و دیگر افراد جامعه می‌باشد و این امکان را به آن‌ها می‌دهد تا نظرات خود را بیان کنند و درک متقابل از محیط اطراف خود داشته‌باشند. بدون زبان اشاره، این افراد موانع قابل توجهی در بیان افکار، نیازها و احساساتشان خواهند داشت. زبان اشاره افراد ناشنوا را قادر می‌سازد تا در فعالیتهای اجتماعی شرکت کنند، به آموزش دسترسی پیدا کنند، استخدام شوند و در رویدادهای جامعه شرکت کنند.

زبان اشاره برای آموزش کودکان ناشنوا بسیار حائز اهمیت است. زیرا که به عنوان زبان اول آنها عمل می‌کند و ارتباط مؤثری را با معلمان، همکاران و سایر کارشناسان آموزشی فراهم می‌کند. زبان اشاره به کودکان ناشنوا امکان دسترسی به اطلاعات، مشارکت در بحث‌های کلاسی و درگیر شدن کامل در فرآیند یادگیری را ممکن می‌سازد. همچنین زبان اشاره برای اطمینان از اینکه افراد ناشنوا بتوانند حقوق قانونی و شهروندی خود را بهره‌برداری کنند، بسیار حائز اهمیت است. بدون زبان امضا، افراد ناشنوا ممکن است با مشکلاتی در دسترسی به عدالت و استفاده از حقوق خود مواجه شوند.

متأسفانه با وجود تعداد زیادی افراد ناشنوا و کم‌شنوا در کشورمان، به این موضوع آنچنان پرداخته نشده‌است. این درحالی است که به دلیل پیشرفت‌های اخیر در زمینه هوش مصنوعی و شبکه‌های عصبی کانولوشن سایر کشورها پیشرفت چشمگیری در این زمینه داشته‌اند. از این رو به این فکر افتادیم تا ابزاری را برای تسهیل ارتباطات این افراد، پیاده‌سازی کنیم.

طی سال‌های اخیر، پژوهشگران زیادی به پردازش زبان اشاره با روش‌های مختلف پرداخته‌اند. از این روش‌ها، استفاده از پردازش تصویر و ساخت ابزار ترجمه و یا ساخت ابزارهایی مانند دستکش‌های هوشمند جهت تسهیل تشخیص خودکار زبان اشاره فارسی را می‌توان نام برد. همچنین در سال‌های اخیر و با پیشرفت چشم‌گیر عملکرد شبکه‌های عصبی عمیق و همچنین پیشرفت قدرت پردازشی کامپیوترهای شخصی و فراهم شدن امکان استفاده از شبکه‌های عصبی در زندگی روزمره، پژوهش‌های متعددی در زمینه تشخیص دست و تشخیص زبان اشاره به کمک یادگیری عمیق صورت گرفته است.

از این رو یک رویکرد سیستماتیک برای تشخیص حرکات دست استاتیک در حروف الفبای زبان اشاره فارسی ارائه شده و مجموعه داده‌ای، جهت آموزش و پیاده‌سازی یک زیرساخت تشخیص زبان اشاره، ارائه شده است. این

مجموعه داده که با استفاده از یک دوربین دیجیتال به دست آمده است، شامل ۴۰۷۰ تصویر برش خورده از دست‌ها می‌باشد. برای تولید این مجموعه داده، تصاویر جمع‌آوری شده طی یک مرحله پیش‌پردازش و با استفاده از شناساگر دست MediaPipe، دست‌ها برش داده شده‌اند. با استفاده از این مجموعه داده، سه مدل Resnet18، Vit و Resnet152 آموزش داده شدند و توسط صحت^۱، دقت^۲، پوشش^۳ و معیار F_1 ^۴ مورد ارزیابی قرار گرفته‌اند. مدل resnet152، بالاترین دقت را در این میان بدست آورده‌است. در ادامه مقایسات و ارزیابی‌های کمی انجام شده مورد بررسی قرار خواهند گرفت.

واژگان کلیدی: زبان اشاره فارسی، Persian Sign language، PSL، Mediapipe، Resnet18.

Image Classification، Vit، Resnet152

¹ Precision

² Accuracy

³ Recall

⁴ F_1 Score

فهرست

چکیده	۴
فصل اول : کلیات	۱۱
۱-۱ مقدمه، ضرورت و کاربرد	۱۲
۱-۲ تعریف مسئله	۱۴
۱-۳ اهداف تحقیق و سوالات اصلی تحقیق	۱۵
۱-۴ ساختار پایان نامه	۱۶
فصل دوم : ادبیات تحقیق	۱۸
۲-۱ مقدمه	۱۹
۲-۱ زبان اشاره فارسی	۱۹
۲-۲ طبقه بندی تصاویر	۲۰
۲-۳ شناسایی دست	۲۱
۲-۴ یادگیری ماشین	۲۲
۲-۵ یادگیری عمیق	۲۲
۲-۶ بینایی ماشین	۲۲
۲-۷ شبکه های عصبی کانولوشن	۲۳
۲-۷-۱ لایه کانولوشن	۲۴
۲-۷-۲ pooling لایه های	۲۵
۲-۷-۳ لایه تماما متصل	۲۶
۲-۷-۴ معماری شبکه های عصبی کانولوشن	۲۷
۲-۸ مدل Resnet18	۲۷
۲-۹ مدل Resnet152	۲۸
۲-۱۰ مدل Vision Transformer (ViT)	۲۸
فصل سوم: مروری بر مطالعات انجام شده	۳۰

۳-۱	مقدمه	۳۱
۳-۲	تشخیص زبان اشاره فارسی با استفاده از تبدیل موجک و شبکه‌های عصبی	۳۱
۳-۳	شناسایی ایستا زبان اشاره فارسی با استفاده از استخراج ویژگی مبتنی بر هسته	۳۲
۳-۴	یک سیستم مبتنی بر شبکه عصبی برای تشخیص زبان اشاره فارسی	۳۳
۳-۵	شناسایی مبتنی بر مسیر زبان اشاره پویا فارسی با استفاده از مدل پنهان مارکوف	۳۴
۳-۶	تشخیص زبان اشاره فارسی با استفاده از حسگرهای IMU و EMG سطحی	۳۴
۳۵	فصل چهارم: ایده پیشنهادی	
۴-۱	مقدمه	۳۶
۴-۲	خواندن و پردازش تصاویر ورودی	۳۶
۴-۳	آموزش و ذخیره مدل‌ها	۳۷
۴-۴	مدل‌ها	۳۸
۴-۵	فریم‌ورک تبدیل ویدئو به متن یا صوت	۳۸
۴-۴	نتایج و بحث	۳۹
۴-۵	نتیجه‌گیری	۳۹
۴۰	فصل پنجم: داده‌ها	
۵-۱	مقدمه	۴۱
۵-۲	جمع‌آوری پایگاه داده	۴۱
۵-۳	پیش‌پردازش	۴۱
۵-۳-۱	مدیاپایپ	۴۱
۵-۳-۲	تغییر سائز	۴۲
۴۴	فصل ششم: تجزیه و تحلیل نتایج	
۶-۱	نتایج پیاده‌سازی	۴۵
۶-۲	آزمایش ۱ - استفاده از مدل Resnet18	۴۶

۴۸.....	۶-۳ آزمایش ۲ – استفاده از مدل Vit
۵۰.....	۶-۴ آزمایش ۳ – استفاده از مدل ResNet152
۵۲.....	۶-۵ مقایسه با نتایج تحقیقات پیشین
۵۵.....	فصل هفتم: نتیجه گیری و پیشنهادات
۵۷.....	مراجع

فهرست تصاویر

شکل ۱:- شمایی کلی از عملکرد مدل های تشخیص زبان اشاره	۱۵
شکل ۲- الفای زبان اشاره فارسی	۲۰
شکل ۳- شناسایی دست به واسطه مکان مفاصل	۲۱
شکل ۴- معماری شبکه عصبی کانولوشن	۲۴
شکل ۵- عملیات لایه کانولوشن	۲۵
شکل ۶- عملیات MAX POOLIG	۲۶
شکل ۷- عملیات لایه های تماما متصل	۲۶
شکل ۸- دیاگرام سیستم تشخیص پیشنهادی	۳۲
شکل ۹- دیاگرام سیستم تشخیص پیشنهادی	۳۳
شکل ۱۰- شناسایی و برش دست توسط مدیاپایپ	۴۲
شکل ۱۱- تغییر سایز دست برش داده شده	۴۳
شکل ۱۲- ماتریس اغتشاشگر مدل RESNET18	۴۷
شکل ۱۳- کلاسهای مشابه با درصد خطا بالاتر از میانگین در RESNET18	۴۸
شکل ۱۴- ماتریس اغتشاشگر مدل ViT	۴۹
شکل ۱۵- کلاسهای مشابه با درصد خطا بالاتر از میانگین در ViT	۵۰
شکل ۱۶- ماتریس اغتشاشگر مدل RESNET152	۵۱
شکل ۱۷- کلاس های مشابه با درصد خطا بالاتر از میانگین در RESNET152	۵۲

فهرست جداول

جدول ۱- مدل‌های مبتنی بر شبکه عصبی کانولوشن	۲۷
جدول ۲- نتایج ارزیابی مدل RESNET18، ViT و RESNET152	۴۵
جدول ۳- مقایسه معیارهای ارزیابی مدل ۳ مدل RESNET152، ViT و RESNET18	۵۳

فصل اول : کلیات

۱-۱ مقدمه، ضرورت و کاربرد

زبان اشاره یک زبان بصری پیچیده است که توسط افراد ناشنوا یا کم شنوا برای ارتباط و تعامل با دیگران استفاده می‌شود. این سیستم شامل حرکات دستی، حرکات بدنی و بیانات چهره است که به منظور انتقال معنا و فراهم کردن ارتباط مؤثر به کار می‌رود. زبان اشاره برای میلیون‌ها نفر در سراسر جهان به عنوان اصلی‌ترین وسیله ارتباطی استفاده می‌شود و جزو مهمی از هویت اجتماعی و زبانی آن‌ها را تشکیل می‌دهد.

بر خلاف زبان‌های گفتاری که به صدا وابسته‌اند، زبان‌های اشاره از طریق بصری برای انتقال اطلاعات استفاده می‌کنند. هر نماد در زبان اشاره به یک کلمه، مفهوم یا ایده اشاره می‌کند و می‌تواند با سایر نمادها ترکیب شده و جملات معناداری را شکل دهد، که این امر امکان بیان افکار پیچیده را فراهم می‌سازد. حرکات و اشارات در زبان اشاره از یک ساختار دستوری تبعیت می‌کنند که شباهتی به زبان‌های گفتاری دارد و در آن قواعدی برای ترتیب کلمات، ساختار جمله و نحویات وجود دارد.

زبان‌های اشاره در سطح مناطق و کشورهای مختلف تفاوت‌های قابل توجهی دارند. به عنوان مثال، زبان اشاره آمریکایی (ASL) به طور قابل توجهی با زبان اشاره بریتانیایی (BSL)، متفاوت است. هر یک از این زبان‌های اشاره دارای واژگان، قواعد دستوری و تفاوت‌های فرهنگی خود هستند که بازتابی از جوامع و سوابق منحصر به فردی است که به آن‌ها مرتبط هستند.

یادگیری زبان اشاره علاوه بر ارتباط اولیه برای افراد ناشنوا، مزایای فراوانی دارد. این یادگیری همبستگی و امکان برقراری ارتباط مساوی با افراد ناشنوا را فراهم می‌کند و در نتیجه، موانع ارتباطی را برطرف می‌کند و درک متقابل را تسهیل می‌کند. همچنین، زبان اشاره ابزارهای ارتباطی بی‌نظیری را برای کارشناسان در زمینه‌های آموزش، بهداشت و خدمات اجتماعی ارائه می‌دهد که این امر به آن‌ها کمک می‌کند تا افرادی که از زبان اشاره استفاده می‌کنند را بهبود بخشند.

در سال‌های اخیر، زبان اشاره به عنوان یک زبان رسمی در بسیاری از کشورها شناخته شده است، که این امر اهمیت و ارزش آن را بیشتر تأکید می‌کند. تلاش‌هایی برای افزایش دسترسی به زبان اشاره منجر به توسعه ابزارها شده است، از جمله فرهنگ‌نامه‌های دیجیتالی و دوره‌های آموزش آنلاین که به دسترسی آسان‌تر به زبان اشاره برای جمعیت گسترده‌تری از افراد کمک می‌کند.

در حوزه‌های پر رونق هوش مصنوعی، یادگیری عمیق به طور قابل توجهی در حوزه مهم پردازش زبان اشاره تأثیرگذار بوده است. در پردازش زبان اشاره، الگوریتم‌های یادگیری عمیق مانند شبکه‌های عصبی پیچشی^۵ و

^۵ Convolutional Neural Networks (CNNs)

شبکه های عصبی بازگشتی^۶ به تحقق پیشرفت های چشمگیر در تشخیص، ترجمه و تولید زبان اشاره کمک کرده اند. این مدل ها به طور موثر از نمونه های زبان اشاره استخراج ویژگی های معناداری را انجام می دهند و توانایی تشخیص و ترجمه دقیق حرکات زبان اشاره را فراهم می کنند.

این پیشرفت ها نه تنها ارتباط و یکپارچگی را برای جامعه ناشنوا بهبود بخشیده اند، بلکه وظایف مربوط به زبان مانند ترجمه، تحلیل احساسات و تولید متن را نیز بهبود بخشیده اند. با تحقیقات و توسعه های پیش رو، یادگیری عمیق به عنوان مهمترین عامل در پیشرفت این حوزه ها، در بهبود دسترسی و کیفیت زندگی افراد ناشنوا نقش اساسی را ایفا می کند.

متأسفانه خیلی به این زمینه در کشورمان پرداخته نشده است. برای همین به این فکر افتادیم تا پایگاه داده ای در این زمینه جمع آوری کنیم. از این رو با استفاده از دوربین دیجیتال از ۳۶ نفر که رده سنی بین ۲۰ تا ۲۳ سال داشتند، در مکان های مختلف با پس زمینه های مختلف و شرایط متفاوت عکس برداری شده است و در نهایت، پایگاه داده ای با ۴۰۷۰ تصویر بدست آمده است. با استفاده از ابزار شناساگر دست mediapipe، دست را شناسایی شده و تصویر بر روی دست ها برش داده شده است. در نهایت از این تصاویر برش داده شده جهت آموزش مدل ها استفاده شده است.

مجموعه داده فوق با روش اعتبارسنجی Holdout به نسبت ۸۰،۲۰ به دو دسته آموزش^۷ و ارزیابی^۸ تقسیم کردیم. از تصاویر آموزشی برای آموزش سه مدل Resnet18، Vit و Resnet152 استفاده کردیم. برای نوشتن این پروژه از زبان پایتون^۹ و چارچوب^{۱۰} پایتورچ^{۱۱} استفاده شده است.

پایتون یک زبان برنامه نویسی چندمنظوره است که به طور گسترده در حوزه های مختلف، از جمله هوش مصنوعی و یادگیری ماشین، استفاده می شود. سادگی، قابلیت خوانایی و کتابخانه های بسیاری که در اختیار آن قرار دارد، این زبان را به یک انتخاب محبوب برای توسعه برنامه های هوش مصنوعی می کند.

پایتورچ به طور خاص برای پایتون طراحی شده است. این چارچوب یک زیرساخت منعطف و کارآمد را برای توسعه و آموزش شبکه های عصبی فراهم می کند. پایتورچ به طور سازگار با پایتون ادغام شده است و به برنامه نویسان امکان استفاده از ویژگی های قدرتمند آن برای ساختارهای پیچیده یادگیری عمیق را می دهد. این

⁶ Recurrent Neural Networks (RNNs)

⁷ Train

⁸ Test

⁹ Python

¹⁰ Framework

¹¹ Pythorch

چارچوب گراف‌های محاسباتی پویا را فراهم می‌کند که به ایجاد معماری‌های مدل انعطاف‌پذیر و اشکال‌زایی آسان‌تر کمک می‌کند.


برای ارتباط متقابل بین افراد ناشنوا و کم‌شنوا با بقیه افراد جامعه بخشی طراحی شده تا با گرفتن صوت آن را در قالب ویدیوای از تصاویر نمادهای زبان اشاره فارسی نشان دهد. در این بخش برای دریافت صوت از سیستم تبدیل گفتار به متن گوگل استفاده شده‌است. متن گرفته شده به صورت حرف حرف جدا می‌شود و تصویر هر کدام در خروجی نمایش داده می‌شود.

این پژوهش به طور کلی سه دستاورد به همراه داشت. این دستاوردها عبارتند از:

۱. در این پژوهش جهت حل مشکل کمبود داده‌های تصویری از زبان اشاره فارسی، مجموعه‌داده‌ای با ۴۰۷۰ تصویر آماده شده است. این مجموعه‌داده شامل تصویر دست‌های زبان اشاره فارسی در محیط‌ها و شرایط متنوعی می‌باشد. این تنوع قدرت تعمیم مدل‌های آموزش داده‌شده بر روی این دیتاست را برای استفاده در دنیای واقعی افزایش می‌دهد.
۲. چند مدل عصبی عمیق با استفاده از مجموعه‌داده‌ی ذکر شده آموزش داده شدند تا مدل‌های پایه‌ای برای تشخیص زبان اشاره فارسی وجود داشته باشد.
۳. یک زیرساخت تبدیل زبان اشاره به متن برای استفاده در ابزارهای آینده ارائه شده است که امکان ارتباط موثر بین افراد ناشنوا و دیگر افراد را فراهم می‌کند.

۲-۱ تعریف مسئله

زبان اشاره فارسی دارای ۳۷ نماد است. مسئله تشخیص نمادهای زبان اشاره فارسی، شامل پیاده‌سازی، آموزش و ارزیابی یک مدل یادگیری ماشین یا یادگیری عمیق با استفاده از مجموعه‌ای از تصاویر دست می‌باشد.



شکل ۱- شمایی کلی از عملکرد مدل‌های تشخیص زبان اشاره

در مسئله تشخیص زبان اشاره قصد داریم برای یک تصویر ورودی I را با استفاده از یک سری محاسبات F ، یک کلاس خروجی P و میزان اطمینان C را تعیین کنیم. خروجی P عددی صحیح در بازه $[0, 37]$ می‌باشد که نشان‌دهنده یکی از ۳۷ نماد زبان اشاره فارسی می‌باشد. C میزان اطمینان مدل از درست بودن خروجی بوده که عددی حقیقی در بازه $[0, 1]$ می‌باشد.

$$P, C = F(I), \quad P \in \mathbb{Z} \ \& \ C \in \mathbb{R}$$

در مرحله بعد با گذراندن این خروجی از یک فیلتر S با آستانه تحمل T ، خروجی پروژه را مشخص می‌کنیم. به این صورت که اگر میزان اطمینان از حد آستانه بیشتر باشد کلاس پیش‌بینی شده به عنوان خروجی نمایش داده می‌شود و در غیر این صورت مقدار منفی یک را برمی‌گرداند. مقدار منفی یک، بدین معناست که تصویر ورودی نشان‌دهنده هیچ‌یک از نمادهای زبان اشاره فارسی نیست.

$$S(P, C) = \begin{cases} P, & T < C \\ -1, & T \geq C \end{cases}$$

۳-۱ اهداف تحقیق و سوالات اصلی تحقیق

زبان اشاره از اهمیت بالایی برخوردار است زیرا به افراد ناشنوا اجازه می‌دهد تا با دیگران به طور مؤثری ارتباط برقرار کنند، به صورت کامل در جامعه شرکت کنند و به خدمات و فرصت‌های مختلف دسترسی پیدا کنند. این زبان به عنوان پلی عمل می‌کند که موانع ارتباطی بین جهان ناشنوا و شنوا را برمی‌شکند و جامعه‌پذیری، درک و حقوق مساوی را ترویج می‌دهد.

هوش مصنوعی می‌تواند نقش قابل توجهی در بهبود تشخیص و ارتباطات زبان اشاره ایفا کند. از طریق تکنیک‌های بینایی ماشین^{۱۲}، الگوریتم‌های هوش مصنوعی قادرند به تجزیه و تحلیل حرکات دست و حرکات بدنی مرتبط با زبان اشاره پردازند. این قابلیت، توسعه سامانه‌های تشخیص زبان اشاره را که تمامی علائم را به طور دقیق ضبط و درک می‌کنند و ترجمه زنده آن را به زبان نوشتاری یا شفاهی ممکن می‌سازد، به وجود می‌آورد. همچنین، تکنیک‌های پردازش زبان طبیعی نیز می‌توانند برای ترجمه زبان نوشتاری یا شفاهی به زبان اشاره استفاده شوند و پلی ارتباطی بی‌درز بین افراد ناشنوا و شنوا ایجاد کنند. با بهره‌گیری از فناوری‌های هوش مصنوعی، می‌توانیم دقت، کارایی و دسترسی به ارتباطات زبان اشاره را بهبود بخشیم و باعث توانمندسازی جامعه ناشنوا و ترویج جامعه‌پذیری و درک بیشتر در جامعه شویم.

در زبان اشاره فارسی، کارهای مشابه زیادی انجام نشده است. این به این معنی است که نیازمندی‌ها و چالش‌های ارتباطی جامعه ناشنویان در ایران هنوز به صورت کامل مورد توجه قرار نگرفته است. با این حال، ما تلاش می‌کنیم تا زندگی آنان را آسان‌تر کنیم و با بهره‌گیری از فناوری‌های هوش مصنوعی، بهبودی قابل توجهی در ارتباطات زبان اشاره و زندگی روزمره آنان ایجاد کنیم. هدف ما این است که با فراهم کردن ابزارها و راهکارهای نوآورانه، جامعه ناشنویان را قدرتمند کنیم و محیطی شامل و دسترس‌پذیر برای آنان فراهم آوریم تا بتوانند به طور کامل در جامعه شرکت کنند و به حقوق و امکانات اساسی دسترسی داشته باشند.

آنچه در این پژوهش مورد آزمایش قرار می‌گیرد اعتبار روش ارائه شده در شناسایی و تشخیص زبان اشاره فارسی است. این اعتبار سنجی در مقایسه با نتایج پژوهشی که در این حوزه ارائه شده است، صورت می‌گیرد تا به پرسش "میزان نمونه‌هایی که مدل ارائه شده در تشخیص آن‌ها موفق بوده، چقدر است؟"^{۱۳} پاسخ دهد.

از معیارهای دیگری که در سنجش کارایی مدل ارائه شده و اعتبار سنجی آن استفاده شده است معیار دقت^{۱۴} و صحت^{۱۵} است. دقت عبارت است از این که چه میزان از نمونه‌های انتخابی درست هستند. صحت بر این مفهوم که چه میزان از نمونه‌های صحیح موجود، انتخاب شده اند.

۴-۱ ساختار پایان‌نامه

در فصل دوم ادبیات مورد استفاده در این تحقیق بیان شده است. در فصل بعد آن، متدها و روش‌هایی که پیش از این در این حوزه انجام شده است، مورد تحلیل و بررسی قرار می‌گیرد. در فصل چهارم روش پیشنهادی این

¹² Computer Vision

¹³ Accuracy

¹⁴ Precision

¹⁵ Recall

پژوهش تشریح می‌شود. در فصل پنجم نتایج پیاده سازی ارائه و تحلیل می‌گردد. در نهایت در فصل ششم نتیجه‌گیری، جمع بندی و پیشنهادات کار برای آینده بیان می‌شود.

فصل دوم : ادبیات تحقیق

۲-۱ مقدمه

برای حل مسئله‌ی زبان اشاره فارسی در این پژوهش، از مدل Resnet18، Vit و Resnet152 استفاده شده است. از این رو در این بخش به بیان و تشریح الگوریتم‌ها و مفاهیم مرتبط با آن‌ها پرداخته است.

۲-۱ زبان اشاره فارسی

زبان اشاره فارسی (PSL)، که در زبان فارسی به نام "زبان اشاره" شناخته می‌شود، یک زبان فضایی بصری است که توسط جامعه ناشنوایان در ایران استفاده می‌شود. زبان اشاره فارسی یک زبان طبیعی کامل با ساختار گرامری، واژگان و دستور زبان خاص خود است. از طریق ترکیب اشاره دست، ابتسامات چهره و حرکات بدن، به منظور انتقال معنا و فراهم کردن ارتباط مؤثر استفاده می‌شود. زبان اشاره فارسی از زبان‌های گفتاری متمایز است و ساختار زبانی خود را دارد. این زبان نقش حیاتی در تسهیل ارتباطات و تقویت هویت فرهنگی در جامعه ناشنوایان ایران دارد. این زبان در حوزه‌های مختلفی از جمله مؤسسات آموزشی، تعاملات اجتماعی و رویدادهای فرهنگی کاربرد دارد و به عنوان وسیله‌ای برای خودبیانی و ترویج هم‌اندیشی برای افراد ناشنوا در جامعه ایران عمل می‌کند. زبان اشاره فارسی شامل دو بخش استاتیک^{۱۶} و داینامیک^{۱۷} است. در این پژوهش تنها بخش استاتیک آن مورد بررسی و آزمایش قرار گرفته است.

¹⁶ Static

¹⁷ Dynamic



شکل ۲- الفای زبان اشاره فارسی

۲-۲ طبقه بندی تصاویر

طبقه‌بندی تصویر یک وظیفه اساسی در بینایی ماشین است که شامل اختصاص برچسب‌ها یا دسته‌بندی‌های پیش‌تعیین شده به تصاویر می‌شود. هدف این وظیفه، توسعه الگوریتم‌ها و مدل‌هایی است که بتوانند بر اساس محتوای بصری تصاویر، آن‌ها را به‌طور خودکار تشخیص داده و دسته‌بندی کنند. این وظیفه معمولاً شامل آموزش مدل یادگیری ماشین بر روی مجموعه داده‌های برچسب‌گذاری شده^{۱۸} است، به طوری که مدل بتواند ویژگی‌ها^{۱۹} و الگوهای^{۲۰} مرتبط را از تصاویر ورودی استخراج کند. شبکه‌های عصبی کانولوشنی (CNN) به

¹⁸ Labeled Dataset


¹⁹ Features

²⁰ Patterns

عنوان یک تکنیک محبوب در طبقه‌بندی تصویر شناخته شده‌اند، زیرا در به دست آوردن نمایش‌های سلسله‌مراتبی^{۲۱} از تصاویر بسیار موفق عمل می‌کنند. طبقه‌بندی تصویر کاربردهای گسترده‌ای دارد که شامل تشخیص اشیاء، شناسایی چهره، تصویربرداری پزشکی و جستجوی محتوای تصویر می‌شود. پیشرفت‌های حاصل از طبقه‌بندی تصویر به طرز چشم‌گیری در حوزه‌های مختلف، امکان تجزیه و تحلیل خودکار، تصمیم‌گیری و بهره‌برداری از اطلاعات بر اساس داده‌های بصری را فراهم کرده است.

۲-۳ شناسایی دست

تشخیص دست، یک تکنیک بینایی ماشین است که بر تشخیص و مکان‌یابی دست‌های انسان در تصاویر یا ویدیوها تمرکز می‌کند. این تکنیک نقش حیاتی در برنامه‌های مختلفی از جمله تشخیص حرکات دست، تفسیر زبان اشاره، تعامل انسان-کامپیوتر و واقعیت مجازی ایفا می‌کند. الگوریتم‌های تشخیص دست از ویژگی‌های مختلفی مانند رنگ، بافت و شکل استفاده می‌کنند تا دست‌ها را از پس‌زمینه و اشیاء دیگر تمایز دهند. این وظیفه می‌تواند با استفاده از روش‌های یادگیری ماشینی مانند شبکه‌های عصبی کانولوشنی (CNN) یا تکنیک‌های سنتی بینایی ماشین مانند تقسیم بندی رنگ پوست و تطبیق الگو به دست آید. تشخیص دقیق دست، امکان پیگیری دقیق و تحلیل حرکات دست را فراهم می‌کند و در نتیجه رابط‌های انسان-کامپیوتر شفاف و تجارب فراگیری را به ارمغان می‌آورد.



شکل ۳- شناسایی دست به واسطه مکان مفصل

²¹ Hierarchical Representations

۲-۴ یادگیری ماشین

یادگیری ماشین زیرمجموعه‌ای از هوش مصنوعی است که بر روی توسعه الگوریتم‌ها و مدل‌های آماری تمرکز می‌کند تا به سیستم‌های کامپیوتری امکان یادگیری از داده‌ها، پیش‌بینی و تصمیم‌گیری بدون نیاز به برنامه‌ریزی صریح را بدهد. این روش شامل استفاده از تکنیک‌های ریاضی و آماری جهت استخراج الگوها و بینش‌ها از مجموعه‌های داده بزرگ است. الگوریتم‌های یادگیری ماشین به طور مداوم از داده‌ها یاد می‌گیرند و با تنظیم پارامترهای خود، کارایی خود را در طول زمان بهبود می‌بخشند. این فرآیند مکرر که به آن آموزش^{۲۲} می‌گویند، الگوریتم‌ها را قادر می‌سازد از داده‌های آموزشی^{۲۳} استنباط بردارند و با دقت پیش‌بینی‌هایی را در مورد داده‌های جدید و نامعلوم ارائه دهند. تعلم ماشین در حوزه‌های مختلفی نظیر تشخیص تصویر و گفتار^{۲۴}، پردازش زبان طبیعی^{۲۵}، سیستم‌های توصیه‌گر^{۲۶} و وسایل نقلیه خودکار^{۲۷} کاربردهای متنوعی دارد.

۲-۵ یادگیری عمیق

طی سالهای اخیر، یادگیری عمیق بصورت گسترده در حوزه بینایی کامپیوتر مورد مطالعه قرار گرفته است. نتایج این مطالعات، به وجود آمدن تعداد زیاد روش‌های مرتبط با روش یادگیری عمیق بوده است. این روش‌ها بر اساس روش پایه‌ای که از آن مشتق شده اند، بطور کلی به ۴ دسته مختلف تقسیم می‌شوند که عبارتند از : Auto encoders، Restricted Boltzmann Machines (RBMS)، Convolutional neural networks، و در آخر Sparse Coding. آنچه از یادگیری عمیق در این بخش مورد بررسی و تشریح قرار خواهد گرفت، شبکه‌های عصبی کانولوشن خواهد بود.

۲-۶ بینایی ماشین

بینایی ماشین به عنوان یک حوزه از علوم کامپیوتر و هوش مصنوعی، درگیر امکان فراهم ساختن قابلیت برای کامپیوترها برای استخراج اطلاعات معنادار و تفسیر داده‌های بصری از تصاویر و ویدیوها است. هدف اصلی آن در توسعه و پیاده‌سازی الگوریتم‌ها و تکنیک‌هایی است که بتوانند محتوای رسانه‌های بصری را تجزیه و فهم کنند. با سعی در تقلید از توانایی‌های سیستم بصری انسان در درک و شناخت اطلاعات بصری، دید کامپیوتری شامل

²² Training

²³ Training data

²⁴ Image and Speech Recognition

²⁵ Natural Language Processing

²⁶ Recommendation Systems

²⁷ Autonomous Vehicles

وظایف گسترده‌ای مانند تشخیص تصویر^{۲۸}، تشخیص اشیاء^{۲۹}، تقسیم بندی تصویر^{۳۰} و درک صحنه^{۳۱} می‌شود. پیشرفت‌های عمیق در این حوزه منجر به کاربردهای قابل توجهی در حوزه‌های مختلف مانند خودروهای خودکار، تصویربرداری پزشکی^{۳۲}، سیستم‌های نظارتی^{۳۳} و واقعیت افزوده شده^{۳۴} شده است. بنابراین، دید کامپیوتری نقش حیاتی در بخش‌بندی قابلیت ماشین‌ها برای تعامل و درک جهان بصری ایفا می‌کند و در فرایندهای اتوماسیون و تصمیم‌گیری کمک می‌کند.

۷-۲ شبکه‌های عصبی کانولوشن

شبکه‌های عصبی کانولوشن یکی از مهمترین روش‌های یادگیری عمیق است که در آن چندین لایه با روشی قدرتمند آموزش می‌بینند. این روش بسیار کارآمد بوده و یکی از رایج‌ترین روش‌ها در کاربردهای مختلف بینایی کامپیوتر است. تصویر کلی یک معماری شبکه عصبی کانولوشن در شکل ۴ نمایش داده شده است. بطور کلی، یک شبکه CNN از سه لایه اصلی تشکیل می‌شود که عبارتند از: لایه کانولوشن، لایه pooling و لایه تماما متصل.

لایه‌های مختلف وظایف مختلفی را انجام می‌دهند. در شکل ۴ یک معماری کلی از شبکه عصبی کانولوشن برای دسته بندی تصاویر بصورت لایه به لایه نمایش داده شده است. در هر شبکه عصبی کانولوشن دو مرحله برای آموزش وجود دارد: مرحله پیش‌خورد^{۳۵} و مرحله‌ی پس انتشار^{۳۶}. در مرحله‌ی اول تصویر ورودی به شبکه تغذیه می‌شود و این عمل ضرب نقطه ای بین ورودی و پارامترهای هر نورون و نهایتاً اعمال عملیات کانولوشن در هر لایه است. سپس خروجی شبکه محاسبه می‌شود. در این جا به منظور تنظیم پارامترهای شبکه و یا به عبارت دیگر همان آموزش شبکه، از نتیجه خروجی جهت محاسبه میزان خطای شبکه استفاده می‌شود. برای این کار خروجی شبکه را با استفاده از یک تابع خطا (loss function) با پاسخ صحیح مقایسه کرده و اینطور میزان خطا محاسبه می‌شود. در مرحله بعدی بر اساس میزان خطای محاسبه شده مرحله‌ی پس انتشار آغاز می‌شود. در این مرحله گرادیانت هر پارامتر با توجه به قاعده chain rule محاسبه می‌شود و تمامی پارامترها با توجه به تاثیری

²⁸ Image Recognition

²⁹ Object Detection

³⁰ Image Segmentation

³¹ Scene Understanding

³² Medical Image

³³ Surveillance Systems


³⁴ Augmented Reality

³⁵ Feed-forward

³⁶ Backpropagation

که بر خطای ایجاد شده در شبکه دارند تغییر پیدا می‌کنند. بعد از بروزآوری شدن پارامترها مرحله بعدی feed-forward شروع می‌شود. بعد از تکرار تعداد مناسبی از این مراحل آموزش شبکه پایان میابد.

در حالت کلی، یک شبکه عصبی کانولوشن یک شبکه عصبی سلسله مراتبی است که لایه‌های کانولوشنی آن بصورت یک در میان با لایه‌های pooling بوده و بعد از آنها تعدادی لایه تماماً متصل وجود دارد.



شکل ۴- معماری شبکه عصبی کانولوشن

۱-۷-۲ لایه‌ی کانولوشن


در این لایه‌ها، شبکه CNN از هسته^{۳۷}های مختلف برای Convolve کردن تصویر ورودی و همینطور feature map های میانی استفاده می‌کند. اینگونه feature map های مختلفی همانند آنچه در شکل ۵ مشاهده می‌کنید ایجاد می‌شود. انجام عملیات کانولوشن سه فایده دارد:

۱. مکانیزم اشتراک وزن در هر feature map باعث کاهش شدید تعداد پارامترها می‌شود.

۲. اتصال محلی، ارتباط بین پیکسل‌های همسایه را یاد می‌گیرد.

۳. باعث تغییر ناپذیری و ثبات نسبت به تغییر مکان شیء می‌شود.

³⁷ Kernel



شکل ۵- عملیات لایه کانولوشن


۲-۷-۲ لایه‌های pooling

یک لایه pooling معمولاً بعد از یک لایه کانولوشنی قرار می‌گیرد و از آن برای کاهش اندازه feature map ها و پارامترهای شبکه استفاده می‌شود. همانند لایه‌های کانولوشنی، لایه‌های pooling نسبت به تغییر مکان^{۳۸} با ثبات هستند. این ثبات بخاطر در نظر گرفتن پیکسل‌های همسایه در محاسبات لایه‌ی pooling است. رایج‌ترین پیاده‌سازی لایه Pooling استفاده از تابع max (max pooling) یا تابع Average (Average pooling) است. می‌توانید نمونه‌ای از فرایند Max pooling را در شکل ۳ مشاهده کنید. یک feature map با اندازه ۸*۸ با استفاده از فیلتر max pooling با اندازه ۲*۲ و گام^{۳۹} دو، یک خروجی با اندازه ۴*۴ را ایجاد می‌کند.

[1] Boureau et al. تحلیل نظری دقیقی از کارایی max pooling و average pooling ارائه داد. Scherer et al. [2] هم مقایسه‌ای بین این دو عملیات انجام داد و فهمید max pooling می‌تواند باعث همگرایی سریعتر، بهبود تعمیم دهی و انتخاب ویژگی‌های نامتغیر بسیار عالی شود. در طی سال‌های اخیر اکثر پیاده‌سازی‌ها سریع CNN که بر روی GPU انجام شده‌اند، از عملیات Max pooling استفاده کردند.

³⁸ Translation

³⁹ stride




شکل ۶- عملیات max pooling

۳-۷-۲ لایه تماماً متصل

بعد از آخرین لایه، Pooling، لایه‌های تماماً متصل وجود دارند که جهت ادامه فرآیند بازنمایی ویژگی ^{۴۰} feature mapهای دو بعدی را به بردار ویژگی ^{۴۱} یک بعدی، تبدیل می‌کند (شکل ۷).

لایه‌های تماماً متصل همانند همتایان خود در شبکه‌های عصبی مصنوعی سنتی عمل می‌کنند و تقریباً ۹۰٪ پارامترهای یک شبکه CNN را شامل می‌شوند. لایه تماماً متصل اجازه می‌دهد تا نتیجه شبکه در قالب یک بردار با اندازه مشخص ارائه شود. می‌توان از این بردار برای دسته‌بندی تصاویر استفاده کرد و یا اینکه از آن جهت ادامه پردازش‌های بعدی بهره برد.

Fully Connected Layer



شکل ۷- عملیات لایه‌های تماماً متصل

^{۴۰} Feature representation

^{۴۱} Feature vector

۴-۷-۲ معماری شبکه‌های عصبی کانولوشن

با پیشرفت‌های اخیر CNN در حوزه‌ی بینایی کامپیوتر، مدل‌های معروفی از شبکه‌های عصبی کانولوشن بوجود آمدند. پیکربندی و دستاوردهای چند مدل CNN در جدول ۱ آورده شده است.

جدول ۱- مدل‌های مبتنی بر شبکه عصبی کانولوشن

مدل	سال	ویژگی‌های کلیدی	نتایج
ResNet	۲۰۱۵	ساختار ز شبکه عصبی با اتصالات residual	دست‌یافتن به نرخ خطای برتر ۵.۵۷٪ در مجموعه داده ImageNet، که برتری نسبت به روش‌های پیشین را نشان می‌دهد
ResNet152	۲۰۱۵	اتصالات Residual و ۱۵۲ لایه کلی	دست‌یافتن به نرخ خطای برتر ۳.۵۷٪
ResNet18	۲۰۱۶	نسخه‌ای از رزنت با ۱۸ لایه، مناسب برای مجموعه داده‌های کوچکتر و محدودیت منابع سیستمی	دست‌یافتن به نرخ خطای برتر ۱.۲۴٪ در مجموعه داده ImageNet
Vision Transformers (ViT)	۲۰۲۰	ساختار بر پایه ترانسفورمر برای وظایف دسته‌بندی تصویر با مکانیزم خودتوجهی	دست‌یافتن به نتایج رقابتی در وظایف دسته‌بندی تصویر که قابل مقایسه با شبکه‌های عصبی کانولوشنی پیشرو هستند

۸-۲ مدل Resnet18

ساختار ResNet18 [3] شامل ۱۸ لایه است که شامل لایه‌های کانولوشنی^{۴۲}، لایه‌های پولینگ^{۴۳} و لایه‌های کاملاً متصل^{۴۴} می‌شود. شبکه با یک لایه کانولوشنی ۷x۷ آغاز می‌شود و پس از آن لایه‌های پولینگ وجود دارد. سپس شامل چهار بلوک باقیمانده است که هر کدام حاوی دو یا سه لایه کانولوشنی با اتصالات مستقیم هستند. این اتصالات مستقیم به گرادین‌ها امکان جریان مستقیم به لایه‌های قبلی را فراهم می‌کنند و مشکل کاهش گرادین را برطرف می‌کنند و آموزش شبکه‌های عمیق را تسهیل می‌کنند. لایه‌های نهایی ResNet18 شامل پولینگ میانگین سراسری و سپس یک لایه کاملاً متصل برای طبقه‌بندی است. استفاده از اتصالات باقیمانده در

^{۴۲} Convolutional Layers

^{۴۳} Pooling Layers

^{۴۴} Fully Connected Layers

ResNet18 به شبکه امکان یادگیری نگاشت‌های باقیمانده را می‌دهد که تفاوت بین ورودی و خروجی یک لایه را مشخص می‌کنند. با یادگیری این نگاشت‌ها، شبکه می‌تواند بر روی جزئیات دقیق تمرکز کند و فرآیند یادگیری را بهینه کند. اتصالات پرشی^{۴۵} در ResNet18 به طور قابل توجهی مشکل کاهش کیفیت را برطرف می‌کنند و به آموزش شبکه‌های بسیار عمیق در حفظ دقت بالا کمک می‌کنند.

۹-۲ مدل Resnet152

مقاله "یادگیری عمیق residual برای تشخیص تصویر"^{۴۶} [4] که توسط هی^{۴۶} و همکارانش در سال ۲۰۱۵ منتشر شد، یک معماری شبکه عصبی به نام یادگیری عمیق residual را پیشنهاد می‌دهد. این چارچوب آموزش شبکه‌هایی که عمق آن‌ها به طور قابل توجهی بیشتر از آن‌چه قبلاً استفاده می‌شد، را آسان می‌کند. این کار با بازنویسی لایه‌ها به عنوان توابع residual آموزشی با توجه به ورودی لایه‌ها، به جای یادگیری توابع بی‌ارجاع، صورت می‌پذیرد.

این معماری برای تشخیص تصویر استفاده شده و بهبودهای قابل توجهی نسبت به روش‌های موجود حاصل کرده است. در مجموعه داده ImageNet، شبکه‌های باقیمانده با عمق ۱۵۲ لایه ارزیابی شده‌اند و یک مجموعه از این شبکه‌های باقیمانده با خطای ۳.۵۷٪ در مجموعه آزمون ImageNet، به عنوان رتبه اول در رده‌بندی ILSVRC ۲۰۱۵ قرار گرفتند.

۱۰-۲ مدل Vision Transformer (ViT)

مقاله "تصویر هم ارزش ۱۶*۱۶ کلمه: ترانسفورمرها برای تشخیص تصویر مقیاس‌پذیر"^{۴۷} [5] که توسط دوسوویتسکی^{۴۷} و همکارانش در سال ۲۰۲۰ منتشر شد، به بررسی کاربرد معماری ترانسفورمر، که به عنوان استاندارد دی‌فاکتو برای وظایف پردازش زبان طبیعی شناخته شده است، در بینایی ماشین می‌پردازد. این مقاله نشان می‌دهد که ترانسفورمری خالص که مستقیماً بر روی دنباله‌های تکه‌های تصویر اعمال می‌شود، می‌تواند در وظایف دسته‌بندی تصویر عملکرد بسیار خوبی داشته باشد.

^{۴۵} Skip Connections

^{۴۶} He

^{۴۷} Dosovitskiy

این مدل پس از پیش‌آموزش بر روی تعداد بسیار زیادی از داده‌ها عملکرد بسیار خوبی بر روی معیارهای ارزیابی^{۴۸} دسته بندی تصاویر کسب کرده‌است. این در حالی است که این مدل نیاز به منابع محاسباتی قابل توجهی برای آموزش ندارد.

⁴⁸ Benchmark

فصل سوم: مروری بر مطالعات انجام شده

۳-۱ مقدمه

این بخش درصدد معرفی مختصر روش‌های ارائه شده در زمینه زبان اشاره فارسی است. تحقیقات اخیر درباره تشخیص زبان اشاره فارسی (PSL) با استفاده از روش‌های مختلفی مانند تبدیل موجک، شبکه‌های عصبی (NN)، روش‌های استخراج ویژگی مبتنی بر هسته و تبدیل موجک گسسته (DWT) ارائه شده‌اند. این سیستم‌ها با استفاده از مجموعه‌های داده‌های تصاویر زبان اشاره فارسی پیاده‌سازی و آزمایش شده‌اند و دقت طبقه‌بندی بالایی را بدست آورده‌اند. زبان اشاره به عنوان شکل اساسی ارتباط برای افراد نابینا استفاده می‌شود و این سیستم‌ها هدف دارند تا ارتباطات بین جامعه نابینا و بینوا را آسان کنند.


۳-۲ تشخیص زبان اشاره فارسی با استفاده از تبدیل موجک و شبکه‌های عصبی

در سال ۲۰۱۱ مقاله ای با این عنوان [6] منتشر شد که در آن یک سیستم برای تشخیص حرکات ثابت حروف الفبای زبان اشاره فارسی با استفاده از تبدیل موجک و شبکه‌های عصبی ارائه شد. تصاویر مورد نیاز برای حروف انتخاب شده با استفاده از دوربین دیجیتال به دست می‌آیند. تصاویر رنگی بریده می‌شوند، تغییر اندازه داده می‌شوند و به تصاویر خاکستری تبدیل می‌شوند.

سپس، تبدیل موجک گسسته (DWT) روی تصاویر خاکستری اعمال می‌شود و برخی از ویژگی‌ها استخراج می‌شوند. در نهایت، ویژگی‌های استخراج شده برای آموزش یک شبکه عصبی چندلایه‌ای (MLP) به کار می‌روند. سیستم هیچ گونه دستکش یا سیستم علامت‌گذاری بصری را به کار نمی‌برد و تنها نیاز به تصاویر دست برای تشخیص دارد.

این سیستم با استفاده از یک مجموعه داده شامل ۶۴۰ نمونه تصویر اشاره فارسی پیاده‌سازی و آزمایش شد؛ ۲۰ تصویر برای هر نماد. نتایج تجربی نشان می‌دهد که سیستم قادر است ۳۲ حرف الفبای انتخاب شده در PSL را با دقت طبقه‌بندی متوسط ۹۴.۰۶٪ تشخیص دهد.


سیستم پیشنهادی از دو مرحله تشکیل شده است: مرحله استخراج ویژگی و مرحله طبقه‌بندی. در مرحله استخراج ویژگی، تبدیل موجک بر روی تصاویر به دست آمده اعمال می‌شود و برخی از ویژگی‌ها با استفاده از ضرایب موجک استخراج می‌شوند. در مرحله طبقه‌بندی، ویژگی‌های استخراج شده برای آموزش یک شبکه عصبی با ساختار پیشرو به عنوان طبقه‌بند استفاده می‌شوند. دیاگرام تشخیص روش پیشنهادی در شکل ۸ آمده است.



شکل ۸. دیاگرام سیستم تشخیص پیشنهادی

۳-۳ شناسایی ایستا زبان اشاره فارسی با استفاده از استخراج ویژگی مبتنی بر هسته

این مقاله [7] در سال ۲۰۱۱ منتشر شده است. در این مقاله، با استفاده از روش‌های استخراج ویژگی مبتنی بر هسته، از جمله تحلیل مؤلفه اصلی هسته‌ای (KPCA) و تحلیل تمایزی هسته‌ای (KDA)، روی نمادها زبان اشاره فارسی ارزیابی انجام می‌دهد. برای مقایسه تأثیر ویژگی‌ها بر نرخ تشخیص نمادها، طبقه‌بندی نظیر فاصله کمینه، ماشین بردار پشتیبان (SVM) و شبکه عصبی (NN) استفاده شده است. دیاگرام تشخیص روش پیشنهادی در شکل ۹ آمده است.



شکل ۹- دیاگرام سیستم تشخیص پیشنهادی

۳-۴ یک سیستم مبتنی بر شبکه عصبی برای تشخیص زبان اشاره فارسی

این مقاله [8] در سال ۲۰۱۸ در ادامه مقاله اول منتشر شد که یک سیستم تشخیص حرکات ثابت برای تشخیص برخی از کلمات انتخاب شده در زبان اشاره فارسی (PSL) ارائه می‌دهد. تصاویر مورد نیاز برای کلمات انتخاب شده با استفاده از دوربین دیجیتال به دست می‌آیند. تصاویر رنگی ابتدا تغییر اندازه داده می‌شوند و سپس به تصاویر خاکستری تبدیل می‌شوند.

سپس، تبدیل موجک گسسته (DWT) بر روی تصاویر انتخاب شده اعمال می‌شود و برخی از ویژگی‌ها استخراج می‌شوند. در نهایت، یک شبکه عصبی چندلایه (MLP) آموزش داده می‌شود تا تصاویر انتخاب شده را دسته‌بندی کند. سیستم تشخیص استفاده‌ای از هیچ دستکش یا سیستم علامت‌گذاری بصری ندارد.

سیستم با استفاده از مجموعه داده‌ای شامل ۲۴۰ نمونه تصویر اشاره فارسی پیاده‌سازی و آزمایش شد؛ ۳۰ تصویر برای هر علامت. آزمایش‌ها نشان می‌دهند که سیستم پیشنهادی قادر است با دقت طبقه‌بندی ۹۸.۷۵٪ علامت‌های PSL انتخاب شده را تشخیص دهد هنگامی که شبکه با استفاده از MATLAB NN Toolbox آموزش داده شود.

۵-۳ شناسایی مبتنی بر مسیر زبان اشاره پویا فارسی با استفاده از مدل پنهان مارکوف

در سال ۲۰۲۰ این مقاله [9] منتشر شد و در آن یک سیستم تشخیص حرکات دینامیکی زبان اشاره فارسی را ارائه می‌دهد. مجموعه‌ای شامل ۱۲۰۰ ویدئو از ۱۲ فرد در حال انجام ۲۰ حرکت دینامیکی با یک دستکش سفید ساده ضبط شد. مسیر دست‌ها همراه با اطلاعات شکل دست از هر ویدئو با استفاده از یک تکنیک رشد منطقه‌ای ساده استخراج شد.

سپس، این مسیرهای زمانی متغیر با استفاده از مدل مخفی مارکوف (HMM) با توابع چگالی احتمال گاوسی به عنوان مشاهدات مدل‌سازی شدند. عملکرد سیستم با استراتژی‌های آزمایشی مختلف ارزیابی شد. آزمایش‌های مستقل از متحدها و وابسته به متحد در سیستم پیشنهادی انجام شد و دقت میانگین ۹۷.۴۸٪ به دست آمد.

۶-۳ تشخیص زبان اشاره فارسی با استفاده از حسگرهای IMU و EMG سطحی

این مقاله [10] در سال ۲۰۲۱ منتشر شد. در این مقاله، یک دستگاه پوشیدنی با هزینه کم بر اساس سنسورهای الکترومیوگرافی سطحی (sEMG) و واحد اندازه‌گیری لینرسی (IMU) برای تشخیص زبان اشاره فارسی ارائه می‌دهد. ترکیب این دو سنسور، دقت سیستم را در ثبت حرکات افزایش می‌دهد.

سیگنال‌های sEMG و IMU از ده داوطلب جمع‌آوری شدند که هر کدام بیست حرکت متداول در زبان اشاره فارسی (PSL) را ده بار در فواصل زمانی مشخص انجام دادند. برای افزایش کارایی محاسباتی الگوریتم پیشنهادی، ۲۵ ویژگی با بالاترین رتبه از دو حالت sEMG و (IMU استخراج شده و توسط طبقه‌بند KNN دسته‌بندی شد که دقت میانگین ۹۶.۱۳٪ را به دست آورد.

فصل چهارم: ایده پیشنهادی

۴-۱ مقدمه

این گزارش یک مطالعه جامع درباره پیاده‌سازی یک مدل شناسایی عکس برای تشخیص دقیق علائم زبان اشاره فارسی (PSL) ارائه می‌دهد. این مدل با استفاده از ساختار ResNet-152، یک شبکه عصبی کانولوشنی عمیق که در وظایف دید کامپیوتری بسیار مؤثر است، پیاده‌سازی شده است. همچنین، تکنیک‌های افزایش داده در طول فرآیند آموزش استفاده می‌شوند. این سیستم پیاده‌سازی شده، نتایج قابل قبولی در مقابل دقت و خطا کسب کرده است و قابلیت‌های بالقوه‌ای برای کاربردهای عملی دارد.

شناسایی عکس نقش کلیدی را در حوزه‌های مختلفی مانند دید کامپیوتری و تشخیص الگو ایفا می‌کند. در این پروژه، ما تمرکز خود را بر روی توسعه یک مدل پیشرفته شناسایی عکس به منظور مقابله با چالش‌های منحصر به فرد در تشخیص علائم PSL قرار داده‌ایم. ساختار ResNet-152 که به خاطر ساختار عمیق لایه‌ای آن شناخته شده است، به عنوان پایه برای مدل ما انتخاب شده است. علاوه بر این، تکنیک‌های افزایش داده برای غنی‌سازی داده‌های آموزشی و بهبود قابلیت مدل در تعمیم داده‌ها استفاده می‌شود.

برای پیاده‌سازی این پروژه از پایتورچ به عنوان چارچوب کلی استفاده شده است. در مرحله اول دیتاست و دیتالودر^{۴۹} برای مراحل آموزش و ارزیابی تولید شدند. سپس برای هر یک از مدل‌ها، مرحله آموزش و ارزیابی هر اپاک اجرا می‌شود. در انتها مدل‌های آموزش داده شده برای استفاده در مراحل آینده ذخیره شده است. در ادامه به شرح هر یک از این مراحل خواهیم پرداخت.

۴-۲ خواندن و پردازش تصاویر ورودی

در این قسمت دو دیتاست از دادگان تهیه می‌شود. دیتاست اول که شامل ۸۰ درصد دادگان مجموعه داده پروژه می‌باشد، جهت آموزش مدل‌ها استفاده می‌شود. به همین صورت، دیتاست دوم با ۲۰ درصد باقی‌مانده دادگان جهت ارزیابی مدل مورد استفاده قرار می‌گیرد.

در هر دیتاست، تصویر ورودی از پوشه مربوط به خود خوانده شده و سپس به سائز ۲۲۴ در ۲۲۴ تغییر اندازه داده می‌شود. برای دیتاست آموزش، از تبدیل‌های آماده‌ی پایتورچ جهت ایجاد تنوع بین داده‌ها و افزایش تعمیم‌پذیری مدل‌ها استفاده می‌شود. این تبدیل‌ها ماهیت شانس‌ی داشته و در هر اپاک ممکن است به ازای تصویر ورودی یکسان، تصویر خروجی متفاوتی بدهند. بدین ترتیب، هر تصویر به صورت شانس‌ی و با احتمال ۵۰ درصد به صورت افقی آینه می‌شود. سپس تصویر با زاویه‌ای بین ۱۵- و ۱۵ درجه چرخانده می‌شود. با انجام این

⁴⁹ Dataloader

عملیات در هر اپاک، تصاویر بین اپاک‌ها متفاوت شده و احتمال عملکرد بهتر مدل بر روی داده‌های دنیای واقعی را افزایش می‌دهد. در مقابل، دادگان ارزیابی نباید بین اپاک‌ها تغییری کنند و بدین دلیل، تبدیلی بر روی این دادگان صورت نمی‌گیرد تا مقایسه بین عملکرد میان‌اپاکی میسر گردد.

پس از تهیه دیتاست‌ها، دو دیتالودر برای بسته‌بندی^{۵۰} و آماده‌سازی داده‌های دیتاست‌ها برای گذراندن آن‌ها از مدل‌ها ساخته می‌شود. در این دیتالودر ها هر بسته^{۵۱} حاوی ۸ تصویر می‌شود. در ادامه و در هر اپاک، با پیاده‌سازی حلقه بر روی هر دیتالودر، مدل‌ها آموزش داده شده و ارزیابی می‌شوند.

۳-۴ آموزش و ذخیره مدل‌ها

در این مرحله، هر مدل با دادگان پردازش شده آموزش داده می‌شود. از آنجایی که مسئله این پژوهش از نوع دسته‌بندی چندکلاسه می‌باشد، بهترین تابع خطا^{۵۲} برای آموزش مدل، تابع خطای آنتروپی متقاطع^{۵۳} می‌باشد. این تابع خطا ابتدا خروجی‌های مدل را به احتمال صحت تبدیل کرده و سپس با فرمول آنتروپی متقاطع، خطای مدل را محاسبه می‌کند.

پس از محاسبه خطا با استفاده از بهینه‌ساز آدام^{۵۴}، پارامترهای مدل‌ها را بهینه‌سازی می‌کنیم. دلیل استفاده از بهینه‌ساز آدام، توانایی این تابع در افزایش تعمیم‌پذیری مدل و همچنین مقاومت این تابع در برابر کمینه‌های محلی^{۵۵} می‌باشد. نرخ یادگیری^{۵۶} در پروسه آموزش ۰.۰۱ مقداردهی شده است که با پیش‌روی مدل در اپاک‌ها به صورت شبه‌کسینوسی کاهش می‌یابد. برای کاهش تدریجی نرخ‌یادگیری از زمانبند گرمادهی کسینوسی^{۵۷} استفاده شده است. این مدل به دلیل کاهش شدید نرخ یادگیری در اپاک‌های میانی و کاهش کند این نرخ در اپاک‌های ابتدایی و انتهایی، عملکرد مطلوبی دارد.

در هر اپاک، پس از آموزش مدل بر روی تمامی داده‌های آموزش (۸۰ درصد کل دادگان)، مدل بر روی داده‌های ارزیابی مورد بررسی قرار گرفته و عملکرد مدل بر اساس میانگین تابع خطا و میانگین دقت مدل در تشخیص درست کلاس‌ها، ارزیابی می‌شود. سپس، در صورتی که عملکرد مدل نسبت به بهترین عملکرد مدل در اپاک‌های پیشین بهبودی داشته باشد، مدل به همراه لیستی از تمامی میانگین توابع خطای اپاک‌های تا همان لحظه، در

⁵⁰ Batching

⁵¹ Batch

⁵² Loss Function

⁵³ Cross-Entropy Loss

⁵⁴ Adam

⁵⁵ Local Minimum

⁵⁶ Learning Rate

⁵⁷ Cosine Annealing Scheduler

سیستم ذخیره شده و جایگزین فایل قبلی می‌شود. همچنین مدل‌ها در هر اپاک در یک فایل دیگر ذخیره می‌شوند تا در صورت نیاز، از آن‌ها برای ادامه آموزش مدل استفاده شود.

۴-۴ مدل‌ها

مدل‌های متعدد و متنوعی برای آموزش مدل‌های دسته‌بندی وجود دارد. در این پژوهش ۳ مدل رایج در مسائل دسته‌بندی مورد استفاده قرار گرفته است. دلیل انتخاب این مدل‌ها، افزایش ترتیبی اندازه و تعداد پارامترهای آن‌ها می‌باشد. مدل ResNet18 به دلیل ۱۸ لایه‌ای که دارد جزو مدل‌های کم‌حجم به حساب می‌آید. مدل ResNet152 از لایه‌های زیادی برخوردار است که آن را به یک مدل بزرگتر از متوسط تبدیل می‌کند. در انتها مدل ViT استفاده شده است که به دلیل استفاده از ترنسفورمرها، اندازه بسیار بزرگی دارد. پیچیدگی فضایی این مدل، با افزایش اندازه تصویر ورودی، به صورت توانی افزایش می‌یابد.

برای پیاده‌سازی مدل‌های ResNet18 و ResNet152 از مدل‌های آماده‌ی پایتورچ استفاده شده است. پس از ساختن این مدل‌ها در پیاده‌سازی، لایه پایانی آن‌ها حذف شده و یک لایه خطی^{۵۸} جایگزین آن می‌شود. این لایه دارای ۳۷ مقدار خروجی است که پیش‌بینی مدل را برای هر یک از نمادهای زبان اشاره فارسی نشان می‌دهند.

برای پیاده‌سازی مدل ViT از کتابخانه HuggingFace [11] استفاده شده است. مدل ViT در این پژوهش برای تصاویر ۲۲۴ در ۲۲۴ پیاده‌سازی شده است. به همین دلیل، استفاده از این مدل با تصاویر بزرگتر یا کوچکتر از این اندازه میسر نمی‌باشد. همچنین با استفاده از امکاناتی که کتابخانه HuggingFace ارائه می‌دهد، نیازی به جایگزینی لایه آخر نبوده و در هنگام تولید مدل، تعداد کلاس‌های خروجی آن را مشخص می‌کنیم.

۴-۵ فریم‌ورک تبدیل ویدئو به متن یا صوت

یکی از استفاده‌های مدل تشخیص زبان اشاره، استفاده از این مدل‌های جهت ترجمه علائم اشاره به حروف یا کلمات فارسی می‌باشد. با استفاده از این قابلیت می‌توان ابزارهای برای تسهیل ارتباط میان افراد کم‌شنوا و ناشنوا با دیگر افراد جامعه ایجاد کرد. به طور مثال اگر چنین ابزاری بر روی تلفن‌های همراه ارائه شود، افرادی که مشکل شنوایی دارند می‌توانند با استفاده از این ابزار، با تلفن در زبان اشاره صحبت کنند و شخص مقابل ترجمه فارسی آن را از تلفن مذکور بشنوند.

⁵⁸ Linear Layer

برای محقق ساختن این امر از ابزار تبدیل صوت به متن گوگل استفاده شده است. این ابزار صدا را از کاربر دریافت می‌کند و پس از پردازش، آن را به صورت متن درمی‌آورد. در این مرحله عبارت را به صورت حرف از یک دیگر تفکیک می‌کنیم. و در نهایت خروجی را در قالب ویدئو نشان می‌دهیم.

۴-۴ نتایج و بحث

عملکرد مدل با توجه به معیارهای خطا و دقت اعتبارسنجی به دقت ارزیابی می‌شود. خطای آموزش به طور پیوسته کاهش می‌یابد که نشان می‌دهد مدل قادر به یادگیری از داده‌های آموزش است. اگرچه خطای اعتبارسنجی ممکن است گاهی اوقات نوسان کند یا برجسته شود، اما دقت اعتبارسنجی بهبود مداوم دارد که نشان دهنده توانایی مدل در تعمیم به داده‌های ناشناخته است.

بهترین مدل با دقت تحسین برانگیز ۹۴.۹۷٪ روی دسته‌های زبان اشاره PSL دست یافت. این نتایج نشان‌دهنده کارایی مدل در دسته‌بندی دقیق تصاویر علائم زبان اشاره فارسی است.

۴-۵ نتیجه‌گیری

این پروژه نشان داد که با استفاده از یادگیری عمیق و تکنیک‌های افزایش داده، می‌توان مدل‌های شناسایی عکسی قوی برای تشخیص علائم زبان اشاره فارسی ایجاد کرد. این مدل قابلیت‌های بالقوه‌ای برای استفاده در سامانه‌های ترجمه یا تفسیر زبان اشاره فارسی دارد و می‌تواند بهبود قابل توجهی در کاربردهای واقعی داشته باشد. در آینده، می‌توان با تنظیم پارامترها، افزایش تنوع داده‌ها و بررسی پیشرفت‌های معماری پیشرفته، دقت و استحکام مدل را بهبود داد.

فصل پنجم: داده‌ها

۵-۱ مقدمه

در زمینه زبان اشاره در سایر کشورها، پژوهش‌های زیادی انجام شده است. پیشرفت‌های اخیر در زمینه یادگیری عمیق، سبب شده است تا ارتباطات میان افراد ناشنوا و کم‌شنوا با دیگر افراد جامعه تسهیل یابد. از این رو در این زمینه پایگاه داده‌های زیادی در زبان‌های مختلفی همچون انگلیسی و عربی موجود می‌باشد. اما متأسفانه با وجود این که زبان فارسی از محدود زبان‌هایی است که زبان اشاره خاص خود را دارد، پژوهش کافی در مورد این زبان انجام نشده است. از این رو پایگاه داده مناسبی برای زبان اشاره فارسی وجود ندارد. با توجه به این موضوع، تصمیم به جمع‌آوری پایگاه داده مناسب گرفتیم.

۵-۲ جمع‌آوری پایگاه داده

با استفاده از دوربین دیجیتال از ۳۶ نفر که رده سنی بین ۲۰ تا ۲۳ سال داشتند، در مکان‌های مختلف با پس‌زمینه‌های مختلف و شرایط متفاوت عکس برداری شده است و در نهایت، پایگاه داده‌ای با ۴۰۷۰ تصویر به دست آمده است. با استفاده از ابزار شناساگر دست mediapipe، دست را شناسایی شده و تصویر بر روی دست‌ها برش داده شده است. در نهایت از این تصاویر برش‌داده‌شده جهت آموزش مدل‌ها استفاده شده است.

۵-۳ پیش‌پردازش


۵-۳-۱ مدیاپایپ

مدیاپایپ (MediaPipe) [12] یک چارچوب نرم‌افزاری بصری و صوتی است که توسط شرکت گوگل توسعه داده شده است. این چارچوب قدرتمند قابلیت‌های متنوعی را در اختیار توسعه‌دهندگان قرار می‌دهد، از جمله قابلیت تشخیص دست و برش دست.

تشخیص دست، یکی از قابلیت‌های برجسته مدیاپایپ است. این قابلیت به توسعه‌دهندگان امکان می‌دهد تا با استفاده از الگوریتم‌های پیچیده، دست را در تصاویر یا ویدئوها تشخیص داده و آن را از سایر اجسام محیطی تفکیک کنند. این امر برای بسیاری از کاربردهای مختلف مانند بازی‌های واقعیت مجازی، کنترل دستگاه‌ها با حرکات دست و پیاده‌سازی واسط کاربری‌های نوآورانه بسیار مفید است.

برش دست نیز از دیگر قابلیت‌های مدیاپایپ است که به توسعه‌دهندگان اجازه می‌دهد تا دست را از تصاویر یا ویدئوها برش داده و محدوده آن را مشخص کنند. این قابلیت برای برخی کاربردهای خاص مانند تشخیص

حضور دست در فیلم‌های آموزشی، تحلیل حرکات دست در ورزش و ارائه داده‌های ورودی به الگوریتم‌های یادگیری ماشینی بسیار ارزشمند است.



شکل ۱۰- شناسایی و برش دست توسط مدیاپایپ


۲-۳-۵ تغییر سائز

در این مرحله ابعاد تصاویر برش داده شده را به ۲۲۴ در ۲۲۴ پیکسل تغییر می‌دهیم. مدل‌های یادگیری عمیق برای آموزش به طور موثر نیاز به حجم بزرگی از داده دارند. تغییر اندازه داده به ما این امکان را می‌دهد اندازه تصاویر و دنباله‌های ورودی را کاهش داده و در نتیجه نیازهای محاسباتی در طول آموزش و استدلال را کاهش دهیم. با تغییر اندازه داده به یک ابعاد کوچکتر، می‌توانیم فرآیند آموزش را به طور قابل توجهی سریع‌تر کنیم و امکان آموزش مدل‌های پیچیده را در منابع محاسباتی محدود فراهم کنیم.

تغییر اندازه داده، به یکنواختی و استانداردسازی مجموعه داده کمک می‌کند. مدل‌های یادگیری عمیق به طور معمول اندازه‌های ثابتی را برای ورودی‌ها انتظار دارند. با تغییر اندازه داده به یک شکل یکنواخت، مطمئن می‌شویم که تمام نمونه‌ها در مجموعه داده ابعاد یکسانی داشته باشند که فرآیند پردازش و تجزیه و تحلیل آن‌ها را آسان‌تر می‌کند. این امر امکان یکپارچه‌سازی بی‌درز داده‌ها با معماری مدل و سازگاری بین لایه ورودی و لایه‌های بعدی را فراهم می‌کند.

مدل‌های یادگیری عمیق معمولاً در طول آموزش نیاز به ذخیره کامل مجموعه داده در حافظه دارند. تغییر اندازه داده می‌تواند به کاهش فضای حافظه مصرفی مجموعه داده کمک کند و امکان آموزش مدل‌های بزرگتر یا کار با مجموعه داده‌های بزرگتر را بدون محدودیت حافظه فراهم کند. با تغییر اندازه داده به یک اندازه کوچکتر، به طور موثر مقدار حافظه مورد نیاز برای ذخیره داده را کاهش می‌دهیم و بهره‌وری حافظه را افزایش می‌دهیم.

تغییر اندازه داده نقش حیاتی در بهبود توانایی مدل‌های یادگیری عمیق دارد. با تغییر اندازه داده، آن را تقویت می‌کنیم. با اعمال تکنیک‌های تغییر اندازه مانند برش یا مقیاس‌بندی، تنوعی در داده‌های آموزشی وارد می‌کنیم که مدل را در برابر تغییرات در اندازه ورودی قوی‌تر می‌کند و توانایی آن را برای عموم‌بخشی به داده‌های ناشناخته افزایش می‌دهد. این امر به جلوگیری از بیش‌برازش^{۵۹} و بهبود عملکرد مدل در داده‌های واقعی کمک می‌کند.



شکل ۱۱- تغییر سایز دست برش داده شده

⁵⁹ Overfitting

فصل ششم: تجزیه و تحلیل نتایج

۱-۶ نتایج پیاده‌سازی

از سه مدل متفاوت به نام‌های ResNet18، ViT و ResNet152 برای آموزش و آزمون یک مجموعه داده متمرکز بر تشخیص زبان اشاره فارسی استفاده کردم. هدف، ارزیابی عملکرد آن‌ها و تعیین مدل موثرتر برای این وظیفه بود. پس از آزمایشات و تجزیه و تحلیل دقیق، مشاهده شد که مدل ResNet152 نسبت به دو مدل دیگر از نظر دقت، عملکرد بهتری داشت.

عملکرد برتر مدل ResNet152 نشان می‌دهد که این مدل برای تشخیص الگوها و ویژگی‌های پیچیده در داده‌های زبان اشاره فارسی موثر است. توانایی این مدل در دستیابی به نرخ دقت بالاتر، ظرفیت بهبود یافته برای تشخیص و تمایز در تفسیر زبان اشاره را نشان می‌دهد. با بهره‌گیری از یک ساختار عمیق و پیچیده‌تر، مدل ResNet152 توانایی بیشتری در یادگیری و کلی سازی از مجموعه داده دارد که در نتیجه عملکرد تشخیص برتری ارائه می‌دهد.

در این مطالعه، مقایسه‌ای از سه مدل در حوزه تشخیص زبان اشاره فارسی نشان داد که مدل ResNet152 بالاترین نرخ دقت برابر با ۹۶.۴٪ را داشت. این نتیجه به معنای اثبات کارایی مدل در دستیابی به جزئیات پیچیده حرکات زبان اشاره است. یافته‌های این مطالعه به پیشرفت تکنولوژی تشخیص زبان اشاره و ارائه بینش‌های ارزشمند برای تحقیقات آتی در حوزه بینایی ماشین و یادگیری عمیق کمک می‌کند. نتایج دو مدل ResNet18 و ViT در جدول ۲ آمده است.

جدول ۲- نتایج ارزیابی مدل ResNet18، ViT و ResNet152

مدل	دقت
ResNet18	۹۴.۹۷٪
ViT	۹۳.۳۴٪
ResNet152	۹۶.۴٪

۲-۶ آزمایش ۱ – استفاده از مدل Resnet18

این پژوهش، استفاده از مدل ResNet18 برای طبقه‌بندی حرکات زبان اشاره در مجموعه داده‌ای شامل ۴۰۷۰ تصویر را مورد بررسی قرار داد. این مجموعه داده شامل ۳۷ کلاس متمایز بود که هر کلاس حاوی ۱۱۰ تصویر بود. به منظور توازن در آموزش و ارزیابی، مجموعه داده را با استفاده از روش اعتبارسنجی holdout به دو بخش تقسیم کردیم: بخش آموزش شامل ۳۰۸۰ تصویر (۸۸ تصویر در هر کلاس) و بخش آزمون شامل ۹۹۰ تصویر (۲۲ تصویر در هر کلاس). هدف ما آموزش مدل ResNet18 برای طبقه‌بندی دقیق حرکات زبان اشاره در تصاویر بود.

مدل ResNet18 نشان داد که عملکرد برجسته‌ای دارد و با دقت ۹۴.۹۷٪ در بخش آزمون عملکرد بسیار خوبی داشت. این دقت بالا، نشانگر توانایی مدل در استخراج ویژگی‌های معنادار از تصاویر زبان اشاره و پیش‌بینی دقیق است. ساختار عمیق و لایه‌ای مدل ResNet18 اجازه می‌دهد الگوهای پیچیده را درک کند و نمایش‌های تمیزکاری یاد بگیرد که طبقه‌بندی قوی را ممکن می‌سازد.

یافته‌های این پژوهش پیامدهای علمی مهمی دارد. دقت بالای به دست آمده توسط مدل ResNet18، قابلیت تکنیک‌های یادگیری عمیق در تشخیص زبان اشاره را نشان می‌دهد. طبقه‌بندی دقیق حرکات زبان اشاره می‌تواند به طور قابل توجهی به افراد با نقص شنوایی کمک کند و ارتباط و یکپارچگی بهتری را فراهم آورد. علاوه بر این، این پژوهش به حوزه بینایی ماشین و یادگیری عمیق کمک می‌کند و کارآمدی مدل ResNet18 در وظایف پیچیده طبقه‌بندی تصاویر را نشان می‌دهد.


ماتریس اغتشاشگر^{۶۰} مدل ResNet18 در شکل ۱۲ آمده است. از طریق این ماتریس می‌توانیم متوجه شویم چه تعداد از داده‌ها و در کدام کلاس به صورت اشتباه پیش‌بینی شده‌اند و همچنین کلاسی خروجی اشتباهی را هم متوجه می‌شویم.

⁶⁰ Confusion Matrix

		مقدار حقیقی																																						
		0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26	27	28	29	30	31	32	33	34	35	36		
مقدار پیش‌بینی شده	0	21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
	1	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
	2	0	0	20	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
	3	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
	4	0	0	0	0	17	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
	5	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
	6	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
	7	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0		
	8	0	0	0	0	0	0	0	0	19	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
	9	0	0	0	0	0	0	0	0	3	19	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
	10	0	0	0	0	0	0	0	0	0	1	21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
	11	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
	12	0	0	2	0	0	0	0	0	0	0	0	0	0	17	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	2	0	0	
	13	0	0	0	0	0	0	0	0	0	0	0	0	0	1	22	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0
	14	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
	15	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
	16	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
	17	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	21	0	0	0	0	0	0	0	1	0	0	0	0	0	0	2	0	0	0	0	0	
	18	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
	19	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
	20	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	22	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	1	0
	21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
	22	0	0	0	0	3	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	18	0	0	0	0	0	1	0	0	0	0	0	1	0
	23	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	19	1	0	0	0	0	0	0	0	0	0	0	
	24	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	19	0	0	0	0	0	0	0	0	0		
	25	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0		
	26	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	
	27	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	0		
	28	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	20	0	0	1	0	0		
	29	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0		
	30	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	19	0	0	0	0		
	31	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0		
	32	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	
	33	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	
	34	0	0	0	0	0	0	0	0	0	0	0	0	0	4	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	19	0	0	
	35	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	20	0	
	36	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	

شکل ۱۲ - ماتریس اغتشاشگر مدل ResNet18

از نتایجی که بدست می‌آید درصد خطای بیشتر کلاس ۴، ۸ و ۱۲ که به ترتیب متعلق به حروف "او"، "ت" و "ح" است، نسبت به سایر کلاس‌ها بیشتر بوده است. در کلاس ۴ بیشترین پیش‌بینی خطا مربوط به کلاس ۲۲، در کلاس ۸ مربوط به ۹ و در کلاس ۱۲ مربوط به ۳۴ است. در شکل ۱۳ تصاویر این کلاس‌ها آمده است. همان‌طور که مشاهده می‌شود این کلاس‌ها شباهت بسیاری به یکدیگر دارند. برای همین نسبت به این شباهت می‌توان گفت این مقدار خطا قابل قبول است.



شکل ۱۳- کلاس‌های مشابه با درصد خطا بالاتر از میانگین در ResNet18

۳-۶ آزمایش ۲- استفاده از مدل ViT

در این مطالعه، ما به بررسی کارایی مدل ویژن ترانسفورمر (ViT) برای طبقه‌بندی حرکات زبان اشاره در مجموعه داده پرداختیم. هدف ما در این مطالعه، مقایسه عملکرد مدل ViT با مدل ResNet18 بود که قبلاً برای همین وظیفه استفاده شده بود.

مدل ViT دقتی برابر با ۹۳.۳۴٪ در بخش آزمون داشت که نشان‌دهنده توانایی آن در طبقه‌بندی حرکات زبان اشاره است. با این حال، مهم است به این نکته توجه کنیم که مدل ResNet18 که نیز در این مطالعه ارزیابی شده بود، با دقت بالاتری برابر با ۹۴.۹۷٪ عملکرد بهتری از مدل ViT از خود نشان داد. در حالی که مدل ViT عملکرد قوی‌ای را ارائه کرد، مدل ResNet18 توانایی‌های برتری در درک ویژگی‌های تمایزدهنده و دستیابی به پیش‌بینی‌های دقیق برای حرکات زبان اشاره از خود نشان داد.

نتایج این مطالعه به بهبود دانش درباره مدل‌های یادگیری عمیق برای تشخیص زبان اشاره کمک می‌کند. مقایسه بین مدل‌های ViT و ResNet18 اهمیت انتخاب‌های معماری را در دستیابی به عملکرد بهینه نشان

می‌دهد. مدل ViT، با وجود دقت کمتری که داشت، هنوز ظرفیت خود را در وظایف طبقه‌بندی تصاویر، به ویژه در حوزه تشخیص زبان اشاره، نشان می‌دهد.

می‌توان با انجام تحقیقات و بهینه‌سازی‌های بیشتر، عملکرد مدل ViT را بهبود داد. این ممکن است شامل تنظیم بهینه پارامترها، افزایش اندازه مجموعه داده یا بررسی استراتژی‌های پیش‌آموزش مختلف باشد. علاوه بر این، بررسی روش‌های ترکیبی که نقاط قوت مدل‌های مختلف، از جمله ViT و ResNet18 را ترکیب کنند، می‌تواند منجر به نتایج بهتری در طبقه‌بندی حرکات زبان اشاره شود.

مقدار حقیقی


مقدار پیش‌بینی شده

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26	27	28	29	30	31	32	33	34	35	36		
0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
1	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	
2	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
3	0	0	0	21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
4	0	0	0	0	19	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	3	1	0	0	0	0	1	0	0	0	0	0	0	0	0	0	
5	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
6	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
7	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	
8	0	0	0	0	0	0	0	0	20	2	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
9	0	0	0	0	0	0	0	0	2	20	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
10	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
11	0	0	0	0	0	0	0	0	0	0	0	1	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
12	0	0	0	0	0	0	0	0	0	0	0	0	0	16	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	3	0	0	
13	0	0	0	0	0	0	0	0	0	0	0	0	0	1	21	0	1	0	1	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
14	0	0	0	0	0	0	0	0	0	0	0	0	0	0	20	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
15	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
16	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	
17	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	1	19	0	0	0	0	0	1	1	0	0	0	0	0	0	0	0	0	0	0	0	
18	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
19	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
20	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	2	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	2	0
22	0	0	0	0	1	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	1	16	0	0	0	0	0	2	0	0	0	0	0	0	0	0	0
23	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	19	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0
24	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	19	0	0	0	0	0	0	0	0	0	0	0	0	0
25	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0	0	1	0	0	0	0	0	
26	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	0	0	0	0	0	0	0
27	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	
28	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	19	0	0	1	0	0	0	0	0	
29	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	
30	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	
31	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	
32	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0	
33	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	
34	0	0	0	0	0	0	0	0	0	0	0	0	0	5	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	19	0	0	
35	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	19	0
36	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22

شکل ۱۴ - ماتریس اغتشاشگر مدل ViT

ماتریس اغتشاشگر مدل ViT در شکل ۱۴ آمده است. به طریق مشابه، از این ماتریس می‌توانیم متوجه شویم چه تعداد از داده‌ها و در کدام کلاس به صورت اشتباه پیش‌بینی شده‌اند و همچنین کلاسی خروجی اشتباهی را هم متوجه می‌شویم.

از نتایجی که بدست می‌آید درصد خطای بیشتر کلاس ۱۶ و ۲۲ که به ترتیب متعلق به حروف "ر" و "ض" است، نسبت به سایر کلاس‌ها بیشتر بوده است. در کلاس ۱۶ بیشترین پیش‌بینی خطا مربوط به کلاس ۳۴، در کلاس ۲۲ مربوط به ۴ است. در شکل ۱۵ تصاویر این کلاس‌ها آمده است. همان‌طور که مشاهده می‌شود این کلاس‌ها شباهت بسیاری به یکدیگر دارند. برای همین نسبت به این شباهت می‌توان گفت این مقدار خطا قابل قبول است.



شکل ۱۵- کلاس‌های مشابه با درصد خطا بالاتر از میانگین در ViT

۴-۶ آزمایش ۳- استفاده از مدل ResNet152

مدل سومی که در این پژوهش استفاده شده، برای آموزش و آزمایش یک مجموعه داده متمرکز بر زبان اشاره فارسی، عملکرد برتری نسبت به سایر مدل‌ها نشان داد. با نرخ دقت ۹۶.۴٪، ResNet152 از مدل‌های ResNet18 و ViT پیشی گرفت.

ResNet152 یک معماری شبکه عصبی کانولوشنی عمیق است که به خاطر عمق و پیچیدگی خود برجسته است. با ۱۵۲ لایه، این مدل قدرت بیشتری برای درک الگوها و ویژگی‌های پیچیده در مجموعه داده زبان اشاره

فارسی دارد. افزایش عمق، ResNet152 را قادر می‌سازد تا نمایش‌های انتزاعی‌تری از داده ورودی یاد بگیرد و در نتیجه توانایی بهتری برای تمایز بین نمادهای زبان اشاره فارسی داشته باشد. با بهره‌گیری از ساختار پیشرفته خود، ResNet152 نرخ دقت بالاتری به دست می‌آورد و کارایی خود در تشخیص و تمایز نمادهای تفسیر زبان اشاره را نشان می‌دهد.

مقدار پیش‌بینی شده

مقدار حقیقی


	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26	27	28	29	30	31	32	33	34	35	36			
0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0			
1	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0			
2	0	0	22	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0			
3	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0			
4	0	0	0	0	18	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	4	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
5	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
6	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
7	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
8	0	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
9	0	0	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
10	0	0	0	0	0	0	0	0	0	0	20	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
11	0	0	0	0	0	0	0	0	0	0	0	1	21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
12	0	0	0	0	0	0	0	0	0	0	0	0	19	0	1	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	3	0	0	0		
13	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
14	0	0	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
15	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
16	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
17	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	21	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
18	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
19	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	1	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0		
20	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	
21	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	21	0	2	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
22	0	0	0	0	3	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	1	16	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0		
23	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	19	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
24	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	19	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
25	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0	1	0	0	0	0	0	0	0	0	
26	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0	0	0	0	0	0	0
27	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	0	0	0	0	0		
28	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	20	0	0	0	0	0	0	1	0	0		
29	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0	0	0	0	0		
30	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0	0			
31	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	21	0	0	0	0	0			
32	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0			
33	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	22	0	0	0	0		
34	0	0	0	0	0	0	0	0	0	0	0	3	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	19	0	0	0	0		
35	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	20	0	0			
36	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	22			

شکل ۱۶- ماتریس اغتشاشگر مدل ResNet152

ماتریس اغتشاشگر مدل ResNet152 در شکل ۱۶ آمده است. به طریق مشابه، از این ماتریس می‌توانیم متوجه شویم چه تعداد از داده‌ها و در کدام کلاس به صورت اشتباه پیش‌بینی شده‌اند و همچنین کلاسی خروجی اشتباهی را هم متوجه می‌شویم.

از نتایجی که بدست می‌آید درصد خطای بیشتر کلاس ۴، ۱۲، ۲۲ و ۳۴ که به ترتیب متعلق به حروف "ا"، "ح"، "ض" و "و" است، نسبت به سایر کلاس‌ها بیشتر بوده است. در کلاس ۴ بیشترین پیش‌بینی خطا مربوط به کلاس ۲۲، در کلاس ۱۲ مربوط به ۳۴، در کلاس ۲۲ مربوط به ۴ و در کلاس ۳۴ مربوط به ۱۲

است. در شکل ۱۷ تصاویر این کلاس‌ها آمده است. همان‌طور که مشاهده می‌شود این کلاس‌ها شباهت بسیاری به یکدیگر دارند. برای همین نسبت به این شباهت می‌توان گفت این مقدار خطا قابل قبول است.



شکل ۱۷- کلاس‌های مشابه با درصد خطا بالاتر از میانگین در ResNet152

۵-۶ مقایسه با نتایج تحقیقات پیشین

کارهای گذشته، سیستم‌های مختلفی برای تشخیص زبان اشاره فارسی ارائه می‌دهند. این سیستم‌ها از تکنیک‌های متنوعی مانند تبدیل موجک، شبکه‌های عصبی (NN)، روش‌های استخراج ویژگی مبتنی بر هسته و تبدیل موجکی گسسته (DWT) برای دستیابی به دقت طبقه‌بندی بالا با استفاده از مجموعه داده‌های تصویری زبان اشاره فارسی استفاده می‌کنند. از سوی دیگر، مقالات به سیستم‌هایی برای تشخیص زبان اشاره دینامیک فارسی می‌پردازند. این سیستم‌ها از تکنیک‌هایی مانند مدل مارکوف پنهان (HMM) و دستگاه‌های پوشیدنی با هزینه کمی مبتنی بر الکترومیوگرافی سطح (sEMG) و واحد اندازه‌گیری دورانی (IMU) استفاده می‌کنند. این سیستم‌ها از مجموعه داده‌های ویدئویی زبان اشاره فارسی استفاده می‌کنند و دقت طبقه‌بندی بالایی را به دست می‌آورند. هدف این سیستم‌ها، توسعه سیستم‌های تشخیص زبان اشاره (SLR) است که قادر به ترجمه زبان اشاره به گفتار یا متن باشند و ارتباط افراد ناشنوا را در جامعه تسهیل نمایند.

در حالی که مقالات و این پژوهش هر دو هدف تشخیص زبان اشاره فارسی را دنبال می‌کنند، در تکنیک‌ها و مجموعه داده‌های استفاده شده تفاوت دارند. مقالات بر تشخیص زبان اشاره استاتیک و دینامیک با استفاده از رویکردهای مختلف تمرکز دارند، در حالی که این مطالعه به طور خاص عملکرد مدل‌های مختلف در تشخیص حرکات زبان اشاره فارسی را مقایسه می‌کند. نتایج با تأکید بر کارایی مدل resnet152 در تشخیص زبان اشاره فارسی، به توسعه فناوری تشخیص زبان اشاره و به دست آوردن بینش‌های ارزشمند برای تحقیقات آینده در زمینه بینایی ماشین و یادگیری عمیق برای تحلیل زبان اشاره می‌پردازند.

علاوه بر این، مجموعه داده ساخته شده در این پژوهش به عنوان یک منبع ارزشمند برای تحقیقات آتی در شناسایی زبان اشاره خدمت می‌کند. پوشش جامع این مجموعه داده از حرکات زبان اشاره و توزیع متعادل کلاس‌ها آن را به یک معیار مناسب برای ارزیابی و مقایسه مدل‌های مختلف تبدیل می‌کند. در دسترس بودن چنین مجموعه داده‌هایی، به کمک تکرارپذیری کار و پیشرفت در این حوزه کمک می‌کند.

جدول ۳- مقایسه معیارهای ارزیابی ۳ مدل ResNet152، ViT، و ResNet18

Recall			Precision			F1			Accuracy		
ResNet152	ViT	ResNet18	ResNet152	ViT	ResNet18	ResNet152	ViT	ResNet18	ResNet152	ViT	ResNet18
1	1	0.954545455	1	0.956521739	1	1	0.977777778	0.976744186	1	0.998771499	0.998771499
1	1	1	0.956521739	1	1	0.977777778	1	1	0.998771499	1	1
1	1	0.863636364	0.88	0.956521739	0.863636364	0.936170213	0.977777778	0.863636364	0.996314496	0.998771499	0.992628993
0.954545455	0.954545455	1	1	1	1	0.976744186	0.976744186	1	0.998771499	0.998771499	1
0.863636364	0.772727273	0.772727273	0.791666667	0.772727273	0.772727273	0.826086957	0.772727273	0.772727273	0.99017199	0.987714988	0.987714988
1	1	1	1	0.956521739	1	1	0.977777778	1	1	0.998771499	1
1	1	1	1	1	1	1	1	1	1	1	1
1	1	1	1	0.956521739	0.956521739	1	0.977777778	0.977777778	1	0.998771499	0.998771499
1	0.954545455	0.909090909	1	0.954545455	1	1	0.954545455	0.952380952	1	0.997542998	0.997542998
1	0.954545455	1	1	0.954545455	0.916666667	1	0.954545455	0.956521739	1	0.997542998	0.997542998
0.954545455	0.954545455	0.954545455	1	0.954545455	1	0.976744186	0.954545455	0.976744186	0.998771499	0.997542998	0.998771499
0.909090909	0.909090909	0.863636364	1	0.952380952	1	0.952380952	0.930232558	0.926829268	0.997542998	0.996314496	0.996314496
0.863636364	0.772727273	0.772727273	0.791666667	0.80952381	0.85	0.826086957	0.790697674	0.80952381	0.99017199	0.988943489	0.99017199
1	1	1	0.916666667	0.88	0.916666667	0.956521739	0.936170213	0.956521739	0.997542998	0.996314496	0.997542998
0.954545455	0.863636364	0.954545455	1	1	0.954545455	0.976744186	0.926829268	0.954545455	0.998771499	0.996314496	0.997542998
0.954545455	0.909090909	1	0.954545455	0.952380952	0.956521739	0.954545455	0.930232558	0.977777778	0.997542998	0.996314496	0.998771499
0.954545455	0.909090909	0.954545455	1	0.909090909	1	0.976744186	0.909090909	0.976744186	0.998771499	0.995085995	0.998771499
0.954545455	0.954545455	0.954545455	0.913043478	0.807692308	0.875	0.933333333	0.875	0.913043478	0.996314496	0.992628993	0.995085995
1	1	1	1	1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1	1	1	1	1
1	1	1	0.956521739	0.814814815	0.916666667	0.977777778	0.897959184	0.956521739	0.998771499	0.993857494	0.997542998
0.954545455	0.909090909	0.954545455	0.954545455	0.952380952	1	0.954545455	0.930232558	0.976744186	0.997542998	0.996314496	0.998771499
0.772727273	0.772727273	0.772727273	0.888888889	0.695652174	0.80952381	0.8	0.711111111	0.790697674	0.99017199	0.984029484	0.988943489
0.863636364	0.818181818	0.863636364	0.95	0.9	0.904761905	0.904761905	0.857142857	0.88372093	0.995085995	0.992628993	0.993857494
0.863636364	0.818181818	0.909090909	1	0.947368421	1	0.926829268	0.87804878	0.952380952	0.996314496	0.993857494	0.997542998
1	0.954545455	1	0.916666667	0.954545455	0.956521739	0.956521739	0.954545455	0.977777778	0.997542998	0.997542998	0.998771499
1	0.954545455	1	1	0.954545455	1	1	0.954545455	1	1	0.997542998	1
1	1	1	1	1	1	1	1	1	1	1	1
1	0.863636364	0.954545455	0.88	1	0.913043478	0.936170213	0.926829268	0.933333333	0.996314496	0.996314496	0.996314496
1	1	1	1	0.956521739	1	1	1	0.977777778	1	1	0.998771499
0.954545455	0.954545455	0.909090909	1	1	0.952380952	0.976744186	0.976744186	0.930232558	0.998771499	0.998771499	0.996314496
0.909090909	0.909090909	0.954545455	1	0.952380952	1	0.952380952	0.976744186	0.976744186	0.997542998	0.996314496	0.998771499
1	0.954545455	1	1	0.956521739	1	1	0.976744186	0.977777778	1	0.998771499	0.998771499
1	1	0.954545455	1	1	1	1	1	0.976744186	1	1	0.998771499
0.863636364	0.909090909	0.909090909	0.826086957	0.740740741	0.740740741	0.844444444	0.816326531	0.816326531	0.991400491	0.988943489	0.988943489
0.954545455	0.909090909	0.954545455	1	1	1	0.976744186	0.952380952	0.976744186	0.998771499	0.997542998	0.998771499
1	0.954545455	1	0.956521739	1	1	0.977777778	0.976744186	1	0.998771499	0.998771499	1

در جدول ۳، سه مدل ResNet152، ViT و ResNet18 را با معیارهای ارزیابی صحت، دقت، پوشش و F1 مورد بررسی و مقایسه قرار داده‌ایم. همانطور که مشاهده می‌شود مدل ResNet152 در هر چهار معیار بهتر عمل کرده است.

فصل هفتم: نتیجه گیری و پیشنهادات

نتایج به دست آمده با استفاده از مدل ResNet152 برای دسته‌بندی حرکات دست در زبان اشاره فارسی (PSL) بسیار قابل توجه هستند. با دقت ۹۶.۴٪ و وجود ۳۷ کلاس مختلف، مدل توانسته است به خوبی حرکات دست را شناسایی و طبقه‌بندی کند. مجموعه داده مورد استفاده برای آموزش و آزمایش شامل ۴۰۷۰ نمونه است (تمامی دیتاها توسط دوربین دیجیتال، از ۳۶ کاربر آماده شده‌است. به طور متوسط از هر شخص ۳ تا ۴ عکس دریافت شده‌است) که هر کلاس شامل ۱۱۰ نمونه است. این نمونه‌ها به ۸۸ نمونه آموزش و ۲۲ نمونه آزمون تقسیم شده‌اند. این نتایج نشان می‌دهند که مدل ResNet152 همراه با مجموعه داده ارائه شده، قادر به دستیابی به دقت بالا در دسته‌بندی حرکات دست در زبان اشاره فارسی می‌باشد.

زبان اشاره نقش کلیدی در تسهیل ارتباط برای افراد با ناتوانی شنوایی دارد. دسته‌بندی حرکات دست در زبان اشاره به دلیل کاربردهای پتانسیل در سیستم‌های تشخیص زبان اشاره و فناوری‌های کمکی توجه قابل توجهی را به خود جلب کرده است. در این مطالعه، ما به‌طور خاص به دسته‌بندی حرکات دست در زبان اشاره فارسی (PSL) می‌پردازیم و استفاده از مدل ResNet152 را برای دستیابی به دقت بالا مورد بررسی قرار می‌دهیم.

مدل ResNet152 یک معماری یادگیری عمیق است که به خاطر توانایی در یادگیری ویژگی‌های پیچیده و دستیابی به عملکرد استثنایی در وظایف دسته‌بندی تصویر شناخته شده است. این مدل با استفاده از مجموعه داده جمع‌آوری شده آموزش داده می‌شود، به طوری که هر کلاس حرکت دست با ۱۱۰ نمونه نمایانگر آن نمایش داده می‌شود. نمونه‌های آموزشی به ۸۸ نمونه آموزشی و ۲۲ نمونه آزمون تقسیم می‌شوند تا عملکرد مدل ارزیابی شود. در طی فرایند آموزش، مدل ویژگی‌های تمایزی حرکات دست را در زبان اشاره فارسی یاد می‌گیرد و وزن‌ها را بهینه‌سازی می‌کند تا کاهشی در خطاهای دسته‌بندی ایجاد شود.

مدل پیشنهادی با دقت ۹۶.۴٪ در دسته‌بندی حرکات دست در زبان اشاره فارسی به دست آمده است. این سطح دقت، توانایی مدل را در تشخیص و طبقه‌بندی حرکات دست در برنامه‌های زمان واقعی نشان می‌دهد. دقت بالا به قابلیت استخراج ویژگی‌های قدرتمند مدل ResNet152 نسبت داده می‌شود که به مدل امکان تشخیص تفاوت‌های کوچک در حرکات دست و پیش‌بینی دقیق فراهم می‌کند. نتایج به دست آمده نشان‌دهنده پتانسیل مدل پیشنهادی برای استفاده در برنامه‌های واقعی از جمله سیستم‌های تشخیص زبان اشاره و فناوری‌های کمکی است.

- [1] Boureau, Y-Lan, Jean Ponce, and Yann LeCun. "A theoretical analysis of feature pooling in visual recognition." Proceedings of the 27th international conference on machine learning (ICML-10). 2010.
- [2] Scherer, Dominik, Andreas Müller, and Sven Behnke. "Evaluation of pooling operations in convolutional architectures for object recognition." International conference on artificial neural networks. Springer, Berlin, Heidelberg, 2010.
- [3] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun. " Deep Residual Learning for Image Recognition ", 2015
- [4] Taewan Kim; KyoungHo Oh; Jaeyoung Kim; Yeonjoon Lee; June Choi, "Development of ResNet152 UNet++-based segmentation algorithm for the tympanic membrane and affected areas", 2020
- [5] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, Neil Houlsby "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale", 2020
- [6] A. Karami, B. Zanj, A. Kiani Sarkaleh. "Persian sign language (PSL) recognition using wavelet transform and neural networks", 2011
- [7] Milad Moghaddam; Manoochehr Nahvi; Reza Hassanzadeh Pak, "Static Persian Sign Language Recognition Using Kernel-Based Feature Extraction", 2011
- [8] Azadeh Kiani Sarkaleh; Fereshteh Poorahangaryan; Bahman Zanj; Ali Karami, "A Neural Network based system for Persian sign language recognition", 2018
- [9] Saeideh Ghanbari Azar, Hadi Seyedarabi, "Trajectory-based recognition of dynamic Persian sign language using hidden Markov model", 2020
- [10] Sara Askari Khomami, Sina Shamekhi, "Persian sign language recognition using IMU and surface EMG sensors", 2021
- [11] https://huggingface.co/docs/transformers/model_doc/vit
- [12] <https://learnopencv.com/introduction-to-mediapipe>

Abstract

Sign language is a communication tool that enables deaf and hard-of-hearing individuals to establish connections with others. Relying on visual gestures, sign language allows deaf and hard-of-hearing individuals to communicate without the need for lip reading or written exchanges.

Sign language holds significant importance in various aspects, including communication and access to information. It serves as a means of communication between deaf and hard-of-hearing individuals and other members of society, enabling them to express their opinions and gain mutual understanding of their surrounding environment. Without sign language, these individuals face significant barriers in expressing their thoughts, needs, and emotions. Sign language empowers deaf individuals to participate in social activities, access education, seek employment, and engage in community events.

For deaf children, sign language is particularly crucial as it serves as their primary language and facilitates effective communication with teachers, peers, and other educational professionals. Sign language enables deaf children to access information, participate in classroom discussions, and fully engage in the learning process. Furthermore, sign language is of great importance in ensuring that deaf individuals can exercise their legal rights and citizenship. Without sign language, they may encounter difficulties in accessing justice and exercising their rights.

Unfortunately, despite the significant number of deaf and hard-of-hearing individuals in our country, this issue has not received adequate attention. However, recent advancements in artificial intelligence and convolutional neural networks in other countries have made remarkable progress in this field. Therefore, we have conceived the idea of implementing a tool to facilitate communication for these individuals.

In recent years, researchers have focused on sign language processing using various methods. These methods include image processing, developing translation tools, and creating intelligent gloves to facilitate automatic recognition of Persian sign language. Additionally, in recent years, with the remarkable advancement of deep neural networks, as well as the increased computational power of personal computers and the availability of neural networks in daily life, numerous studies have been conducted on hand detection and sign language recognition using deep learning.

In this regard, a systematic approach for recognizing static hand movements in the alphabet of Persian sign language has been proposed, and a dataset has been provided for training and implementing a sign language recognition infrastructure. This dataset, obtained using a digital camera, consists of 4070 cropped hand images. In order to generate this dataset, the collected images were preprocessed in a preprocessing phase and segmented using the MediaPipe hand tracker. Three models, namely Resnet18, Vit, and Resnet152, were trained using this dataset and evaluated using metrics such as accuracy, precision, recall, and F1 score. Among these models, Resnet152 achieved the highest accuracy. Further comparisons and quantitative evaluations will be discussed in the following sections.

Keywords: Persian sign language, PSL, MediaPipe, Resnet18, Resnet152, Vit, Image Classification



Babol Noshirvani University of Technology
Department of Electrical and Computer Engineering

A Thesis Submitted for Degree of Bachelor of Software
Engineering in Computer Engineering
Subject:
Sign language translation (deaf) using deep learning

By:
Yasamin Tavakoli

Supervisor:
Dr. Hesam Omranpour

June 2023