



دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی ارشد
مهندسی کامپیوتر

رویکردهای مبتنی بر حسگرهای مجازی جهت بهبود قابلیت اطمینان خودروهای الکتریکی

نگارش

یاسمین توکلی

استاد راهنما

دکتر علیرضا اجلاالی

دی ۱۴۰۴



به نام خدا
دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی ارشد

این پایان نامه به عنوان تحقق بخشی از شرایط دریافت درجه کارشناسی ارشد است.

عنوان: رویکردهای مبتنی بر حسگرهای مجازی جهت بهبود قابلیت اطمینان خودروهای
الکتریکی

نگارش: یاسمین توکلی

کمیته ممتحنین



امضاء:

استاد راهنما: دکتر علیرضا اجلالی



امضاء:

استاد ممتحن داخلی: دکتر حسین اسدی



امضاء:

استاد ممتحن خارجی: دکتر ایمان غلامپور

تاریخ: ۱۴۰۴/۱۱/۱۳



اظهارنامه

(اصالت متن و محتوای پایان نامه کارشناسی ارشد)

عنوان پایان نامه: رویکردهای مبتنی بر حسگرهای مجازی جهت بهبود قابلیت اطمینان خودروهای الکتریکی

استاد راهنما: دکتر علیرضا اجلاالی

این جانب یاسمین توکلی اظهار می دارم:

۱. متن و نتایج علمی ارائه شده در این پایان نامه اصیل بوده و زیر نظر استادان نام برده شده در بالا تهیه شده است.
۲. متن پایان نامه به این صورت در هیچ جای دیگری منتشر نشده است.
۳. متن و نتایج مندرج در این پایان نامه، حاصل تحقیقات این جانب به عنوان دانشجوی کارشناسی ارشد دانشگاه صنعتی شریف است.
۴. کلیه مطالبی که از منابع دیگر در این پایان نامه مورد استفاده قرار گرفته، با ذکر مرجع مشخص شده است.

نگارنده: یاسمین توکلی
تاریخ: ۱۴۰۴/۱۱/۱۳
امضاء: 

نتایج تحقیقات مندرج در این پایان نامه و دستاوردهای مادی و معنوی ناشی از آن (شامل فرمولها، توابع کتابخانه‌ای، نرم افزارها، سخت افزارها و مواردی که قابلیت ثبت اختراع دارد) متعلق به دانشگاه صنعتی شریف است. هیچ شخصیت حقیقی یا حقوقی بدون کسب اجازه از دانشگاه صنعتی شریف حق فروش و ادعای مالکیت مادی یا معنوی بر آن یا ثبت اختراع از آن را ندارد. همچنین، کلیه حقوق مربوط به چاپ، تکثیر، نسخه برداری، ترجمه، اقتباس و نظائر آن در محیطهای مختلف اعم از الکترونیکی، مجازی یا فیزیکی برای دانشگاه صنعتی شریف محفوظ است. نقل مطلب با ذکر ماخذ بلامانع است.

نگارنده: یاسمین توکلی
تاریخ: ۱۴۰۴/۱۱/۱۳
امضاء: 

استاد راهنما: دکتر علیرضا اجلاالی
تاریخ: ۱۴۰۴/۱۱/۱۳
امضاء: 

سپاس

از استاد بزرگووارم، دکتر اجلالی که با راهنمایی‌های دلسوزانه و علم وسیعشان مرا در این مسیر همراهی کردند، صمیمانه تشکر می‌کنم. حمایت‌های ایشان همیشه برای من انگیزه‌بخش بوده است.

از دکتر فصحتی، که با آموزش‌های ارزنده و حمایت‌های بی‌دریغ‌شان در تمامی مراحل علمی و پژوهشی، راهنمایی‌های لازم را در اختیارم گذاشتند، نهایت سپاس و قدردانی را دارم. حضور ایشان همیشه برای من منبع الهام و انگیزه بوده است و بی‌شک بدون رهنمودهای ایشان، این مسیر به این راحتی طی نمی‌شد.

از هم آزمایشگاهی‌های عزیزی که با راهنمایی‌های خود در بهبود نگارش این نوشتار سهیم بوده‌اند، صمیمانه سپاسگزارم.

از خانواده عزیزم که همیشه با محبت و پشتیبانی‌شان در کنارم بودند، سپاسگزارم. بدون حمایت‌های بی‌پایان شما، رسیدن به این موفقیت ممکن نبود.

چکیده

خودروهای الکتریکی به دلیل وابستگی به حسگرهای فیزیکی با چالش‌هایی نظیر هزینه بالا، وزن اضافی و استهلاک ناشی از پیری حسگرها روبه‌رو هستند که در طول زمان منجر به کاهش دقت و ایمنی می‌شود. این پژوهش با هدف جایگزینی یا تقویت این حسگرها، یک حسگر مجازی مقاوم بر پایه یادگیری عمیق طراحی کرده است تا علاوه بر کاهش هزینه‌ها، قابلیت اطمینان سامانه مدیریت باتری را در مواجهه با اشکال‌های حسگری ارتقا دهد. در این راستا، از معماری شبکه عصبی بازگشتی دوسویه دروازه‌دار BiGRU برای تخمین دقیق دمای باتری استفاده شده است. روش پیشنهادی مبتنی بر یک راهبرد آموزش دومارحله‌ای شامل یادگیری روابط نامی و تنظیم دقیق مقاوم است که با تزریق قوانین فیزیکی در تابع هزینه، پایداری مدل را در مواجهه با اشکال‌های گذرا و دائمی نظیر رانش، انحراف و چسبندگی تضمین می‌کند. ارزیابی مدل با مجموعه داده واقعی سلول‌های باتری خودروی تسلا نشان داد که این الگوریتم در شرایط عادی به دقت ۱/۵۹ درجه سلسیوس دست می‌یابد. تحلیل قابلیت اطمینان بیانگر پوشش کامل اشکالات گذرا و حفظ پایداری خروجی حسگر مجازی در خطوط داستانی بحرانی است، به گونه‌ای که رفتار مدل در افق زمانی متناظر با عمر مفید خودرو پایدار باقی می‌ماند. از منظر پیاده‌سازی، مدل با حجم حافظه اندک در حدود ۱/۷ مگابایت و زمان استنتاج ۲۶۴ میلی‌ثانیه، برای به کارگیری در سامانه‌های نهفته خودرویی مناسب بوده و الزامات قابلیت اجرا را برآورده می‌سازد. این نتایج نشان می‌دهد که رویکرد پیشنهادی می‌تواند به عنوان یک مشخصه پشتیبان ایمنی، در چارچوب فرایندهای توسعه منطبق با استاندارد ISO 26262 مورد استفاده قرار گیرد.

کلیدواژه‌ها: حسگر مجازی، سامانه مدیریت باتری (BMS)، شبکه عصبی BiGRU، تحمل اشکال، قابلیت اطمینان، قابلیت اجرا، سربار محاسباتی، ایمنی عملکردی خودرو، استاندارد ISO 26262.

فهرست مطالب

۱	مقدمه	۱
۷	مفاهیم اولیه	۲
۷	۱-۲ زیرساخت رایا-فیزیکی و استانداردهای ایمنی	۷
۷	۱-۱-۲ معماری سامانه‌های رایا-فیزیکی	۷
۹	۲-۱-۲ چارچوب استانداردهای ایمنی عملکردی	۹
۹	۳-۱-۲ اهمیت ارزیابی اشکال و قابلیت اطمینان	۹
۱۰	۲-۲ معرفی سامانه‌ی مورد مطالعه	۱۰
۱۰	۱-۲-۲ ساختار خودروی الکتریکی	۱۰
۱۱	۲-۲-۲ سامانه‌ی مدیریت باتری: وظایف و چالش‌های پایش	۱۱
۱۱	۳-۲-۲ اهمیت مدیریت حرارتی و نقش حسگرهای مجازی	۱۱
۱۳	۳-۲ مبانی یادگیری ماشین و معماری‌های یادگیری عمیق	۱۳
۱۳	۱-۳-۲ مروری بر مدل‌های فیزیکی و مدل‌های بر پایه‌ی داده	۱۳
۱۴	۲-۳-۲ معماری‌های رایج یادگیری عمیق برای تحلیل داده‌های باتری	۱۴
۱۶	۳-۳-۲ تنظیم دقیق در مدل‌های یادگیری عمیق	۱۶
۱۷	۴-۲ اشکال و تزریق اشکال در سامانه‌های رایا-فیزیکی	۱۷
۱۷	۱-۴-۲ مفاهیم پایه: اشکال، خطا و خرابی	۱۷
۱۸	۲-۴-۲ طبقه‌بندی اشکال‌ها و انواع اشکال‌های حسگری	۱۸

- ۲-۴-۳ تحمل‌پذیری اشکال و تزریق اشکال در سامانه‌های مدیریت باتری ۲۱
- ۲-۵ شاخص‌های ارزیابی خطا و آسیب‌پذیری ۲۲
- ۲-۵-۱ شاخص‌های آماری ارزیابی خطا ۲۲
- ۲-۵-۲ ارزیابی پایداری با شاخص آسیب‌پذیری ۲۳
- ۲-۶ مفاهیم قابلیت اطمینان ۲۴
- ۲-۶-۱ توزیع نرخ خرابی و پدیده‌ی پیری ۲۴
- ۲-۶-۲ شاخص‌های زمانی قابلیت اطمینان ۲۵
- ۲-۶-۳ ارزیابی قابلیت اجرا و تحلیل اطمینان‌پذیری ۲۵

۳ کارهای پیشین ۲۷

- ۳-۱ مرور پژوهش‌های پیشین در پیش‌بینی دمای باتری ۲۷
- ۳-۱-۱ روش‌های بر پایه مدل فیزیکی ۲۷
- ۳-۱-۲ روش‌های بر پایه داده ۲۸
- ۳-۱-۳ روش‌های ترکیبی ۲۹
- ۳-۲ مرور پژوهش‌های پیشین در تشخیص اشکال حسگر و تحمل‌پذیری در سامانه مدیریت باتری ۳۰
- ۳-۲-۱ رویکردهای تشخیص اشکال حسگر ۳۰
- ۳-۲-۲ راهبردهای تحمل‌پذیری: کنترل و حسگرهای مجازی ۳۲
- ۳-۲-۳ تزریق اشکال و آموزش مقاوم ۳۲
- ۳-۳ مرور کاربردهای مکمل در معماری سامانه مدیریت باتری ۳۳
- ۳-۳-۱ پیش‌بینی برد رانندگی ۳۳
- ۳-۳-۲ ارزیابی اقتصادی و عملکردی حسگرهای مجازی در سامانه مدیریت باتری ۳۴
- ۳-۴ شکاف‌های پژوهشی و جایگاه پژوهش حاضر ۳۴

۴ روش پیشنهادی ۳۷

- ۴-۱ پیش‌پردازش و آماده‌سازی داده‌ها ۳۷

۳۸	۴-۱-۱ توصیف ریاضی مشخصه‌ها
۳۹	۴-۱-۲ نرمال‌سازی آماری
۳۹	۴-۱-۳ تولید دنباله‌های زمانی با پنجره لغزان
۴۱	۴-۲ مدل‌سازی ریاضی و تزریق اشکال حسگری
۴۱	۴-۲-۱ اشکال‌های گذرا
۴۲	۴-۲-۲ اشکال‌های دائمی
۴۳	۴-۳ معماری شبکه عصبی پیشنهادی
۴۳	۴-۳-۱ واحد شبکه‌ی GRU
۴۴	۴-۳-۲ شبکه BiGRU و ساختار کلی مدل
۴۴	۴-۴ راهبرد آموزش دو مرحله‌ای و تابع هزینه
۴۴	۴-۴-۱ آموزش پایه با داده‌های سالم:
۴۵	۴-۴-۲ تنظیم دقیق مقاوم
۴۵	۴-۴-۳ تابع هزینه مرکب با قانون‌های فیزیک
۴۹	۴-۵ معیارهای ارزیابی و تحلیل پایداری یکپارچه سامانه
۵۰	۴-۵-۱ معیارهای ارزیابی آماری
۵۱	۴-۵-۲ تحلیل پایداری یکپارچه سامانه

۵ نتایج ۵۳

۵۴	۵-۱ تنظیمات آزمایشگاهی و زیرساخت سخت‌افزاری و نرم‌افزاری
۵۴	۵-۱-۱ زیرساخت نرم‌افزاری و کتابخانه‌ها
۵۵	۵-۱-۲ پایگاه داده آزمون و سناریوهای ارزیابی
۵۵	۵-۲ مراحل آموزش مدل پیشنهادی
۵۶	۵-۲-۱ تثبیت مدل نهایی
۵۷	۵-۳ معیارهای ارزیابی قابلیت اطمینان و ایمنی عملکردی یکپارچه
۵۷	۵-۳-۱ فرمول‌بندی شاخص‌های عملیاتی در تحلیل پایداری یکپارچه

۵۸	۴-۵	تحلیل نتیجه‌های کمی و ارزیابی نهایی
۵۹	۱-۴-۵	ارزیابی پایداری یکپارچه و تحلیل نقشه حرارتی
۵۹	۲-۴-۵	ارزیابی تطبیقی با استانداردهای ایمنی خودرویی
۶۱	۵-۵	تحلیل سربار محاسباتی و کارایی عملیاتی
۶۱	۱-۵-۵	مدیریت حافظه و پیچیدگی مدل
۶۲	۲-۵-۵	توان پردازشی و زمان پاسخ‌گویی

۶ نتیجه‌گیری و کارهای آتی

۶۴	۱-۶	تحلیل تطبیقی و جایگاه پژوهش در ادبیات موضوع
۶۵	۲-۶	مسیرهای توسعه و کارهای آتی

۶۷ مراجع

۷۳ واژه‌نامه انگلیسی به فارسی

۷۸ واژه‌نامه فارسی به انگلیسی

فهرست جدول‌ها

- ۱-۳ خلاصه‌ی کارهای پیشین (مشخصه‌های در نظر گرفته‌شده با ✓ نشان داده شده‌اند) . . ۳۵
- ۱-۵ مقایسه مشخصات و خروجی‌های مراحل اول و دوم آموزش ۵۷
- ۲-۵ تحلیل کمی پایداری یکپارچه و انطباق با استاندارد در افق عمر مفید خودرو ۵۹
- ۱-۶ مقایسه تطبیقی راهکار پیشنهادی با پژوهش‌های شاخص پیشین بر اساس معیارهای
چندگانه ۶۴
- ۲-۶ مقایسه پیچیدگی محاسباتی و منابع سخت‌افزاری معماری‌های مختلف ۶۵

فهرست شکل‌ها

- ۱-۱ خلاصه‌ی روش پیشنهادی ۵
- ۱-۲ معماری مفهومی سامانه‌ی رایا-فیزیکی در تعامل با لایه‌های سخت‌افزاری و محاسباتی ۸
- ۲-۲ نمای کلی اجزای اصلی خودرو الکتریکی و مسیر تبادل انرژی و داده ۱۱
- ۳-۲ نمای کلی اجزای سامانه‌ی مدیریت باتری و زنجیره تبادل علائم ۱۲
- ۴-۲ زنجیره‌ی داده از حسگرهای فیزیکی و مراحل پیش‌پردازش تا مدل تخمین‌گر ۱۲
- ۵-۲ نمای کلی ساختار شبکه‌ی عصبی کانولوشنی در تحلیل داده‌های باتری ۱۴
- ۶-۲ نمای ساختار واحد LSTM ۱۵
- ۷-۲ نمای ساختار واحد GRU ۱۶
- ۸-۲ نمای ساختار شبکه‌ی عصبی بازگشتی دوسویه BiGRU ۱۶
- ۹-۲ رابطه‌ی مفهومی میان اشکال، خطا و خرابی ۱۸
- ۱۰-۲ طبقه‌بندی اشکال‌های حسگری و گونه‌های متداول برای تزریق اشکال ۱۹
- ۱۱-۲ مقایسه علائم حسگری در شرایط سالم و رخداد اشکال. در این نمودار، منحنی آبی نشان‌دهنده علائم سالم و منحنی نارنجی بیانگر علائم دارای اشکال است. ۲۰
- ۱-۴ نمای کلی چارچوب پیشنهادی؛ شامل مراحل آماده‌سازی داده، تزریق اشکالی کنترل‌شده و آموزش دومرحله‌ای مدل. ۳۸
- ۲-۴ تأثیر نرمال‌سازی بر توزیع آماری داده‌ها؛ (آ) داده‌های خام با مقیاس‌های متفاوت، (ب) داده‌های همگام‌سازی شده با میانگین صفر و واریانس واحد. ۴۰

- ۳-۴ فرایند تولید نمونه‌های آموزشی با استفاده از پنجره لغزان با طول L ؛ ماتریس ورودی شامل تاریخچه مشخصه‌های الکتریکی و خروجی شامل دمای باتری در آینده است. . . ۴۰
- ۴-۴ منحنی‌های همگرایی تابع هزینه در دو مرحله آموزش؛ (آ) کاهش سریع اشکال در آموزش پایه با داده سالم، (ب) تنظیم دقیق پایدار با نرخ یادگیری پایین بر روی داده‌های ترکیبی. ۴۶
- ۱-۵ میانگین خطای تخمین در سناریوهای مختلف. ۶۰
- ۲-۵ مقایسه عامل آسیب‌پذیری (VF) در سطوح هشدار و بحرانی. ۶۱
- ۳-۵ پایداری یکپارچه سامانه $(P_{sw} \times P_{hw})$ در افق زمانی ۲۰ هزار ساعت. ۶۲
- ۴-۵ نقشه حرارتی شاخص نُه‌ها؛ نمایش توزیع قابلیت اطمینان در ماتریس سناریو-سطح. . ۶۲

فصل ۱

مقدمه

امروزه، با گسترش روزافزون خودروهای برقی^۱ و تحول بنیادین در صنعت حمل و نقل، مفاهیمی نظیر تنزل کنترل شده^۲ و ایمنی عملکردی^۳ به اولویت‌های اصلی پژوهشگران و تولیدکنندگان تبدیل شده‌اند. بر اساس آمارهای منتشر شده توسط سازمان جهانی بهداشت^۴، سالانه بیش از ۱.۳۵ میلیون نفر در سانحه‌های جاده‌ای جان خود را از دست می‌دهند [۱]. این آمار تکان‌دهنده نشان می‌دهد که با وجود پیشرفت‌های شگرف در حوزه مکانیک خودرو، همچنان نیاز به ارتقای لایه‌های حفاظتی هوشمند احساس می‌شود. در خودروهای الکتریکی، ایمنی نه تنها شامل استحکام بدنه، بلکه مستلزم مدیریت دقیق انرژی و پیشگیری از رفتارهای غیرقابل پیش‌بینی در زیرسامانه‌های^۵ الکترونیکی است. از این رو، طراحی سامانه‌هایی که بتوانند در مواجهه با نقص یا اشکال^۶های فنی، رفتاری ایمن و پیش‌بینی‌پذیر از خود نشان دهند، ضرورتی انکارناپذیر برای حفظ جان سرنشینان و ارتقای اعتماد عمومی به این فناوری نوظهور است.

سامانه‌های نوین مدیریت انرژی، فراتر از مدارهای الکترونیکی ساده عمل کرده و در واقع مصداق بارز سامانه‌ی رایا-فیزیکی^۷ هستند. این سامانه‌ها بر پایه‌ی تعاملی مستمر، برخط^۸ و درهم‌تنیده میان بخش‌های محاسباتی دیجیتال و فرایندهای فیزیکی بنا شده‌اند [۲، ۳]. در این ساختار، سامانه‌های نهفته^۹ وظیفه‌ی مدیریت و پایش بی‌درنگ^{۱۰} رفتار فیزیکی سامانه را بر عهده دارند و با تحلیل داده‌های دریافتی، فرامین کنترلی لازم را صادر می‌کنند [۴]. ماهیت بی‌درنگ این سامانه‌ها ایجاب می‌کند که هرگونه تأخیر یا اشکال

¹Electric Vehicles – EVs

²Graceful Degradation

³Functional Safety

⁴World Health Organization – WHO

⁵System

⁶Fault

⁷Cyber-Physical Systems – CPSs

⁸Online

⁹Embedded Systems

¹⁰Real-time

در لایه‌ی محاسباتی، به‌سرعت در کل پویایی فیزیکی سامانه انتشار یافته و در صورت عدم مهار زود هنگام، به پیامدهای جدی و گاه جبران‌ناپذیر منجر شود. از این منظر، عملکرد درست یک سامانه رایا-فیزیکی در گرو همگام‌سازی دقیق میان دنیای محاسبات و واقعیت‌های فیزیکی پیرامون آن است.

سامانه‌های مدیریت باتری^{۱۱} در خودروهای برقی، حساس‌ترین زیرمجموعه سامانه‌ی رایا-فیزیکی به شمار می‌رود که وظیفه مدیریت و پایش مستمر رفتار الکتروشیمیایی سلول‌ها را بر عهده دارد. این سامانه در واقع پلی میان محاسبات دیجیتال و پدیده‌های پیچیده فیزیکی و شیمیایی درون بسته باتری^{۱۲} محسوب می‌شود [۵]. عملکرد صحیح این سامانه نه تنها تضمین‌کننده بهره‌وری انرژی و پیمایش خودرو است، بلکه مستقیماً با طول عمر سلول‌ها و پیشگیری از شرایط عملیاتی ناایمن در ارتباط است. سامانه‌های مدیریت باتری باید ضمن رعایت قیدهای زمانی آنی^{۱۳}، بتواند تصویری دقیق از وضعیت داخلی باتری ارائه دهد تا الگوریتم‌های مدیریت انرژی بتوانند در حالت مناسب، وظایف خود را به انجام رسانند. هرگونه نارسایی در این بخش، می‌تواند منجر به خاموشی غیرمنتظره خودرو یا فرسودگی زود هنگام منابع انرژی گردد [۶].

عملکرد دقیق سامانه‌های مدیریت باتری به‌طور کامل به صحت و کیفیت داده‌های دریافتی از زنجیره حسگری وابسته است. در ساختارهای متداول، حسگرهای ولتاژ^{۱۴}، حسگرهای جریان^{۱۵} و دما^{۱۶} نقشی کلیدی در پایش لحظه‌ای سامانه ایفا می‌کنند. با این حال، این حسگرها در محیط واقعی خودرو همواره در معرض شرایط عملیاتی متغیر، تنش‌های مکانیکی و تداخل‌های الکترومغناطیسی قرار دارند که منجر به بروز انواع نقص یا اشکال می‌گردد. این اشکال‌ها شامل نوفه^{۱۷}های لحظه‌ای، انحراف^{۱۸} ثابت و رانش^{۱۹} تدریجی علائم^{۲۰} هستند [۷]. بروز چنین اختلال‌هایی باعث می‌شود که تخمین شاخص‌های حیاتی نظیر وضعیت شارژ^{۲۱} و وضعیت سلامت باتری^{۲۲} با خطا مواجه شده و در نتیجه، فرایندهای حیاتی نظیر هم‌ترازسازی سلول‌ها^{۲۳} و مدیریت حرارتی با مشکل جدی روبه‌رو شوند [۸].

با توجه به حساسیت‌های ذکر شده، انطباق با استانداردهای ایمنی عملکردی نظیر ISO 26262 برای سامانه‌های مدیریت باتری یک الزام قانونی و فنی است [۹]. سامانه باید در برابر تکراردهای اشکال^{۲۴}

¹¹Battery Management System – BMS

¹²Battery Pack

¹³Real-time Constraints

¹⁴Voltage Sensors

¹⁵Current Sensors

¹⁶Temperature Sensors

¹⁷Noise

¹⁸Bias

¹⁹Drift

²⁰Signals

²¹State of Charge – SOC

²²State of Health – SOH

²³Cell Balancing

²⁴Single Event Upset – SEU

مقاوم بوده و از تبدیل اشکال‌های ساده حسگری به مخاطره‌ها^{۲۵} بحرانی پیشگیری کند [۱۰]. جدی‌ترین نوع این مخاطره‌ها، پدیده فرار حرارتی^{۲۶} است؛ وضعیتی که در آن افزایش مهارناپذیر دمای سلول موجب واکنش‌های زنجیره‌ای شیمیایی و آزادسازی شدید انرژی می‌گردد که می‌تواند منجر به آتش‌سوزی یا انفجار بسته باتری شود [۱۱]. تجربیات پیشین در صنعت خودرو نشان داده است که بهره‌گیری از راهبردهای تحمل‌پذیری اشکال^{۲۷} در سامانه‌هایی نظیر ترمز ضد قفل^{۲۸}، نقش کلیدی در ارتقای امنیت سرنشینان ایفا کرده است [۱۲]. لذا تعمیم این رویکردها به حوزه مدیریت باتری برای دستیابی به سطح ایمنی عملکرد خودرو^{۲۹} ضروری است.

پژوهش‌های گذشته در زمینه تخمین دمای سلول‌ها^{۳۰} به‌طور کلی بر سه رویکرد مدل‌های فیزیکی مانند پالایه کالمن^{۳۱} که تفسیرپذیر اما وابسته به مشخصه‌ها^{۳۲} فیزیکی هستند و روش‌های یادگیری عمیق^{۳۳} نظیر شبکه حافظه طولانی کوتاه‌مدت (LSTM)^{۳۴} و مدل فضای حالت مامبا^{۳۵} با دقت بالا در شرایط داده‌های سالم و در نهایت روش‌های ترکیبی استوار بوده‌اند. با این وجود چالش اصلی در متون علمی کنونی تضاد میان دقت محاسباتی و میزان تحمل‌پذیری در برابر خرابی‌های احتمالی حسگر است. بسیاری از مدل‌های توسعه‌یافته در مواجهه با ناهنجاری‌های حسگری به سمت واگرایی می‌روند و فاقد معیارهای سنجش قابلیت اطمینان^{۳۶} مطابق با استانداردهای رایج در صنعت خودرو هستند.

در این پژوهش، برای غلبه بر چالش‌های فوق، طراحی و ارزیابی یک حسگر مجازی مقاوم^{۳۷} بر پایه معماری شبکه‌های بازگشتی دوسویه دروازه‌دار (BiGRU)^{۳۸} پیشنهاد شده است. این مدل به‌دلیل توانمندی در تحلیل وابستگی‌های زمانی دوطرفه و بهره‌مندی از محاسباتی سبک‌تر نسبت به مدل‌های بازگشتی سنتی، گزینه‌ای ایده‌آل برای استقرار در سامانه‌های نهفته با منابع محدود محسوب می‌شود. نوآوری اصلی این رساله، ارائه یک راهبرد آموزش شامل آموزش پایه^{۳۹} و تنظیم دقیق مقاوم^{۴۰} است که با بهره‌گیری از تزریق اشکال^{۴۱} هدفمند و اعمال قانون‌های فیزیکی در تابع هزینه، پایداری مدل را تضمین می‌کند. برای

²⁵Hazards

²⁶Thermal Runaway

²⁷Fault Tolerance

²⁸Anti-lock Braking System – ABS

²⁹Automotive Safety Integrity Level – ASIL

³⁰Cell Temperature

³¹Kalman Filter

³²Parameters

³³Deep Learning

³⁴Long Short-Term Memory – LSTM

³⁵Mamba

³⁶Reliability

³⁷Robust

³⁸Bidirectional Gated Recurrent Unit – BiGRU

³⁹Baseline Training

⁴⁰Robust Fine-tuning

⁴¹Fault Injection

اعتبارسنجی دقیق، از مجموعه داده‌ی خودروی تسلا استفاده شده است که شرایط عملیاتی واقعی را پوشش می‌دهد. هدف نهایی، ارائه حسگر مجازی است که نه تنها در شرایط سالم دقت بالایی داشته باشد، بلکه در حضور اشکال‌های حسگری نیز علائم دمایی قابل اطمینانی تولید کرده و از بروز واکنش‌های زنجیره‌ای تخریب‌کننده پیشگیری نماید.

علاوه بر جنبه‌های معماری و آموزشی، این پژوهش چارچوبی نوین برای ارزیابی پایداری یکپارچه^{۴۲} سامانه ارائه می‌دهد. برخلاف رویکردهای متداول که صرفاً بر معیارهای دقت آماری تمرکز دارند، در این مطالعه پایداری کل سامانه در قالب یک ساختار سری^{۴۳}، متشکل از قابلیت اطمینان بخش سخت‌افزار و پایداری بخش نرم‌افزار، مدل‌سازی شده است. نوآوری دیگر این بخش، بررسی آستانه‌های عملکردی بر اساس استاندارد نوظهور ایمنی هوش مصنوعی در خودرو یعنی ISO/PAS 8800^{۴۴} و ارزیابی شاخص‌های قابلیت اطمینان در افق زمانی مأموریت استاندارد، مطابق با الزامات SAE J1211 [۱۳] است. این رویکرد ترکیبی، تضمین می‌کند که حسگر مجازی پیشنهادی نه تنها از منظر ریاضی دقیق، بلکه از منظر مهندسی و استانداردهای ایمنی عملکردی خودرو نیز در طول عمر مفید پانزده‌ساله خود قابل اعتماد و پایدار باقی می‌ماند.

تمایز راهکار پیشنهادی در این پژوهش نسبت به کارهای پیشین، گذار از دقت آزمایشگاهی به پایداری مهندسی است. برخلاف مدل‌های صرفاً یادگیری ماشین^{۴۵} که به عنوان جعبه سیاه عمل می‌کنند، این پژوهش با تزریق قانون‌های ترمودینامیکی به لایه‌های پنهان شبکه، از پیش‌بینی‌های غیرممکن فیزیکی جلوگیری می‌کند. همچنین، برخلاف مدل‌های سنگین از نظر بار محاسباتی^{۴۶}، این روش با حجم حافظه اندک و زمان استنتاج پایین، قابلیت پیاده‌سازی برخط روی ریزکنترل‌گرهای معمولی خودرو را داراست.

نتایج تجربی حاصل از پیاده‌سازی بر روی مجموعه داده واقعی خودروی تسلا، نشان‌دهنده عملکرد ممتاز راهکار پیشنهادی است. در شرایط عملیاتی سالم، مدل شبکه‌های BiGRU در مرحله آموزش نامی به دقت بسیار بالای خطای میانگین مطلق^{۴۷} $1/59^{\circ}C$ دست یافت که نشان‌دهنده توانایی بالای معماری در استخراج دینامیک حرارتی است. در سناریوهای بحرانی، مدل با بهره‌گیری از تنظیم دقیق مقاوم^{۴۸} توانست اثر اشکال‌های شدیدی نظیر رانش^{۴۹} و چسبندگی^{۵۰} را خنثی نماید؛ به‌طوری‌که حتی در حضور خرابی‌های دائمی، نرخ شکست در سطح بحرانی (VF) را در مقدار $0/0672$ مهار کرد.

⁴²Integrated Performability

⁴³Series Structure

⁴⁴Road Vehicles — Safety and Artificial Intelligence

⁴⁵Machine Learning


⁴⁶Computational Load

⁴⁷MAE

⁴⁸Fine-tuning

⁴⁹Drift

⁵⁰Stuck-at Faults



شکل ۱-۱: خلاصه‌ی روش پیشنهادی

از منظر قابلیت اطمینان، این سامانه در برابر اشکال‌های گذرا به شاخص پایداری $4/7$ نه دست یافت و در سخت‌ترین سناریوهای اشکال‌های دائمی، پایداری یکپارچه کل (P_{total}) مقدار خیره‌کننده $0/999979$ را در افق زمانی مأموریت $10^4 \times 2$ ساعته ثبت نمود. این نتایج، انطباق کامل حسگر مجازی پیشنهادی را با سخت‌گیرانه‌ترین سطوح ایمنی عملکردی خودرو (ASIL-D) اثبات کرده و آن را به عنوان یک سامانه پشتیبان^{۵۱} قابل اطمینان و بسیار سبک‌وزن، با تنها $1/7$ مگابایت اشغال حافظه، برای ارتقای امنیت عملیاتی در خودروهای الکتریکی معرفی می‌کند.

همان‌گونه که در شکل ۱-۱ مشاهده می‌شود، چارچوب کلی روش پیشنهادی و پیوند میان مراحل اصلی پژوهش به تصویر کشیده شده است. این مطالعه با هدف طراحی سناریوهای تزریق اشکال و ارزیابی مقاومت مدل در برابر اختلال‌های غیرخطی، به تحلیل تحمل‌پذیری و ظرفیت بازیابی اطلاعات در شرایط بحرانی پرداخته و عملکرد معماری پیشنهادی را با رویکردهای بر پایه مدل مقایسه می‌کند. در این مسیر، چارچوبی منسجم برای سنجش تحمل‌پذیری اشکال^{۵۲} در حسگرهای مجازی تدوین شده است که نه تنها توانمندی مدل در مواجهه با اشکال‌های متداول نظیر انحراف، رانش و نوفه را به چالش می‌کشد، بلکه رفتار سامانه را در برابر سناریوهای بدبینانه و داده‌های عملیاتی واقعی خودرو بررسی می‌نماید. علاوه بر این، تمرکز اصلی این پژوهش بر تحلیل جنبه‌های تحمل‌پذیری و جلوگیری از انتشار اشکال‌ها است تا بدین‌وسیله، سازگاری حسگر مجازی با استانداردهای سخت‌گیرانه‌ی ایمنی عملکردی و شاخص‌های قابلیت اطمینان در سامانه‌های رایا-فیزیکی تبیین گردد. این رویکرد در نهایت منجر به ارائه‌ی راهکاری سبک‌وزن و قابل اطمینان می‌گردد که تحمل‌پذیری مورد نیاز در صنعت خودرو را تضمین خواهد کرد.

⁵¹Back-up

⁵²Fault Tolerance

این پایان‌نامه در پنج فصل تدوین شده است. در فصل دوم، مبانی نظری، مفاهیم اولیه فیزیک باتری و زیرساخت‌های یادگیری عمیق بررسی می‌شوند. فصل سوم به مرور کارهای پیشین و تحلیل شکاف‌های پژوهشی در حوزه‌ی بازیابی داده‌های حسگری می‌پردازد. در فصل چهارم، روش پیشنهادی شامل فرایند پیش‌پردازش داده‌ها، طراحی سناریوهای تزریق اشکال و معماری دقیق شبکه‌ی BiGRU تشریح می‌گردد و در نهایت، فصل پنجم به ارائه‌ی نتایج تجربی، تحلیل پایداری، مقایسه‌ی عملکرد مدل با روش‌های مرجع و نتیجه‌گیری نهایی اختصاص یافته است.

فصل ۲

مفاهیم اولیه


در این فصل، زیرساخت‌های نظری و مفاهیم بنیادین مورد نیاز برای درک عمیق عملکرد سامانه‌های مدیریت باتری در چارچوب رایا-فیزیکی تبیین می‌گردد. این نوشتار با بررسی تعامل‌های سامانه‌های پیچیده و استانداردهای ایمنی نوین، چارچوبی جامع برای تحلیل قابلیت اطمینان و ارزیابی پایداری مدل‌های بر پایه هوش مصنوعی فراهم می‌آورد.

۱-۲ زیرساخت رایا-فیزیکی و استانداردهای ایمنی

تلاقی دنیای دیجیتال و فیزیکی در قالب سامانه‌های رایا-فیزیکی، بستری نوین برای ارتقای کارایی و ایمنی در صنایع پیشرفته فراهم آورده است. در این چارچوب، مدیریت هوشمند منابع انرژی نه تنها یک مسئله محاسباتی، بلکه حاصل تعامل دقیق میان الگوریتم‌ها و ماهیت فیزیکی باتری‌هاست که باید تحت استانداردهای سخت‌گیرانه ایمنی توسعه یابد.

۱-۱-۲ معماری سامانه‌های رایا-فیزیکی

سامانه‌های رایا-فیزیکی نسل نوینی از سامانه‌های مهندسی هستند که بر پایه‌ی تعامل تنگاتنگ و دوطرفه میان فرایندهای محاسباتی و فیزیکی بنا شده‌اند. در این الگو، واحدهای محاسباتی نه تنها داده‌ها را پردازش می‌کنند، بلکه به صورت مستمر از محیط فیزیکی بازخورد دریافت کرده و بر آن اثر می‌گذارند. به منظور درک دقیق این عملکرد، معماری این سامانه‌ها در سه سطح سلسله‌مراتبی تبیین می‌گردد که در شکل ۱-۲ به تصویر کشیده شده است:



شکل ۱-۲: معماری مفهومی سامانه رایا- فیزیکی در تعامل با لایه های سخت افزاری و محاسباتی

- **لایه فیزیکی:** شامل اجزای واقعی و سخت افزاری^۱ نظیر بسته باتری، محیط پیرامونی، مبدل های توان^۲ و پیشران های الکتریکی.
- **لایه حسگری و عملگری:** مسئول تبادل علائم میان دنیای فیزیکی و محاسباتی است؛ حسگرها (دما، ولتاژ و جریان) علائم فیزیکی را به داده های دیجیتال تبدیل کرده و عملگرها^۳، همانند سامانه های خنک سازی دستورات کنترلی را در محیط فیزیکی اجرا می کنند.
- **لایه محاسباتی و کنترلی:** شامل واحدهای پردازشی نهفته و الگوریتم های هوشمندی است که وظایفی نظیر نظارت بر دما، مدیریت ایمنی و تخمین وضعیت سلامت باتری را بر عهده دارند.

جریان اطلاعات در این معماری به صورت حلقه های بسته یی درنگ عمل می کند؛ هرگونه اختلال در این زنجیره، به ویژه در لایه حسگری، می تواند پایداری کل سامانه را به خطر اندازد.

¹Hardware

²Power Converters

³Actuators

۲-۱-۲ چارچوب استانداردهای ایمنی عملکردی

تحقق قابلیت اطمینان در سامانه‌های رایا-فیزیکی حساس مانند خودروهای الکتریکی، مستلزم پیروی از استانداردهایی است که تمامی ابعاد طراحی را پوشش دهند. این استانداردهای سه‌گانه، مسیری روشن برای مدیریت خطر فراهم می‌کنند:

استاندارد ISO 26262: ایمنی عملکردی سنتی

این استاندارد مرجع اصلی در حوزه ایمنی خودرو است که بر کاهش مخاطره‌های ناشی از خرابی‌های تصادفی سخت‌افزاری^۴ و اشکال‌های سامانه‌ای نرم‌افزاری^۵ تمرکز دارد [۹]. هدف آن، تضمین عملکرد صحیح سامانه در صورت وقوع نقص فنی در قطعات الکترونیکی است.

استاندارد ISO/PAS 21448 SOTIF و مفهوم

برخلاف ایمنی سنتی، استاندارد ایمنی عملکرد مورد نظر^۶ بر مخاطره‌های ناشی از محدودیت‌های ذاتی^۷ مدل‌ها و الگوریتم‌ها تمرکز دارد؛ حتی زمانی که هیچ خرابی سخت‌افزاری رخ نداده باشد [۱۴]. این استاندارد برای مدل‌های پیچیده یادگیری ماشین که ممکن است در سناریوهای پیش‌بینی نشده دچار اشکال شوند، حیاتی است.

استاندارد ISO/PAS 8800: ایمنی هوش مصنوعی

این استاندارد چارچوبی برای مدیریت ایمنی سامانه‌های بهره‌مند از فناوری‌های هوش مصنوعی^۸ است [۱۵]. این استاندارد با تأکید بر رفتارهای ناخواسته و عملکرد ناکافی عناصر یادگیری ماشین، کل چرخه‌ی عمر مدل، از جمع‌آوری داده تا اعتبارسنجی را تحت پوشش قرار می‌دهد.

۳-۱-۲ اهمیت ارزیابی اشکال و قابلیت اطمینان

گزارش‌های بین‌المللی نظیر Global EV Outlook منتشرشده توسط آژانس بین‌المللی انرژی نیز بر ضرورت طراحی سامانه‌های مدیریت باتری ایمن، قابل‌اعتماد و مقاوم در برابر اشکال، به‌عنوان یکی از پیش‌نیازهای

⁴Random Hardware Failures

⁵Software

⁶SOTIF

⁷Inherent Limitations

⁸AI

توسعه‌ی پایدار خودروهای الکتریکی تأکید می‌کنند [۱۶]. این گزارش‌ها نشان می‌دهد که با افزایش تراکم انرژی باتری‌ها و پیچیدگی معماری سامانه‌های الکتریکی، اهمیت ارزیابی رفتار سامانه در حضور داده‌های معیوب، اشکال‌های حسگری و سناریوهای بحرانی بیش از پیش شده است. در این چارچوب، استفاده از روش‌هایی همانند تزریق اشکال، تحلیل حالت و اثر خرابی^۹ و ارزیابی معیارهای کمی قابلیت اطمینان، نه‌تنها از منظر پژوهشی، بلکه به‌عنوان بخشی از الزامات استانداردهای ایمنی، برای سامانه‌ی مدیریت باتری ضروری است [۱۷، ۱۸].


۲-۲ معرفی سامانه‌ی مورد مطالعه

خودروهای الکتریکی به‌عنوان راهکاری کلیدی برای کاهش آلاینده‌ی، انرژی مورد نیاز خود را از باتری‌های الکتریکی تأمین می‌کنند. در این سامانه‌ها، تعامل میان زیرسامانه‌های مختلف برای تضمین عملکرد ایمن و بهینه ضروری است.

۱-۲-۲ ساختار خودروی الکتریکی

شکل ۲-۲ نمای جامعی از معماری یک خودروی الکتریکی و تعامل‌های پیچیده‌ی میان زیرسامانه‌های اصلی آن را به تصویر می‌کشد. همان‌طور که با فلش‌های سبز ضخیم نشان داده شده است، بسته‌ی باتری، به‌عنوان منبع اصلی انرژی، توان الکتریکی را از طریق واحد الکترونیک توان و مبدل‌ها به موتور و پیشران جهت تولید حرکت منتقل می‌کند. این جریان توان تحت نظارت واحد کنترل خودرو قرار دارد که با ارسال فرمان‌های کنترلی که با مسیر فلش آبی ضخیم مشخص شده است، عملکرد هماهنگ تمامی اجزا را تضمین می‌کند. در این میان، سامانه‌ی مدیریت باتری از طریق تبادل پیوسته‌ی داده که با فلش‌های خاکستری دوطرفه مشخص شده است، با بسته‌ی باتری و واحد کنترل خودرو، وضعیت لحظه‌ای سلول‌ها را پایش کرده و اطلاعات حیاتی را برای تصمیم‌گیری فراهم می‌آورد. همچنین، زیرسامانه‌ی مدیریت گرمایی با برقراری حلقه‌های فعال سرمایش و گرمایش که مسیرهای قرمز و آبی نازک هستند، دمای عملیاتی اجزای حساس نظیر باتری و الکترونیک توان را در محدوده‌ی ایمن تنظیم می‌کند [۱۹].

^۹Failure Mode and Effects Analysis – FMEA



شکل ۲-۲: نمای کلی اجزای اصلی خودرو الکتریکی و مسیر تبادل انرژی و داده

۲-۲-۲ سامانه مدیریت باتری: وظایف و چالش‌های پایش

سامانه مدیریت باتری وظیفه پایش، کنترل و حفاظت از باتری را بر عهده دارد [۲۰]. این سامانه با دریافت داده از حسگرها، فرایندهایی همانند شارژ و دشارژ، تعادل سلول‌ها و مدیریت حرارتی را هدایت می‌کند. اجزای کلیدی این سامانه در شکل ۲-۳ ارائه شده است که شامل واحد کنترل، حسگرها (ولتاژ، جریان و دما) و مدارهای ایمنی^{۱۰} می‌باشد.


عملکرد دقیق این سامانه به کیفیت و قابلیت اطمینان داده‌های حسگرها وابسته است. حسگرهای ولتاژ، جریان و دما در محیط واقعی خودروهای الکتریکی با عوامل متعددی روبه‌رو هستند که دقت و پایداری آن‌ها را تهدید می‌کند [۷، ۲۰، ۲۲، ۲۱، ۸]. پیری حسگر می‌تواند به رانش تدریجی در اندازه‌گیری‌ها منجر شود. تداخل الکترومغناطیسی و نوفه ناشی از کلیدزنی^{۱۱} قطعات الکتریکی قدرت نیز سطح نوفه را افزایش داده و کیفیت سیگنال را کاهش می‌دهد [۲۴، ۲۳]. علاوه بر این، اشکال‌هایی همانند چسبندگی یا بریدگی می‌تواند داده‌های ثابت، اشباع‌شده یا کاملاً گم‌شده تولید کند [۸، ۷].

۳-۲-۲ اهمیت مدیریت حرارتی و نقش حسگرهای مجازی


دمای سلول اثر مستقیمی بر طول عمر، بازده و ایمنی باتری‌های لیتیوم-یونی دارد. انحراف از محدوده دمای مجازی می‌تواند منجر به افت عملکرد یا رخدادهای بحرانی نظیر فرار حرارتی شود [۲۲]. از این رو، پایش مستمر دما برای واکنش سریع سامانه مدیریت باتری ضروری است.

¹⁰Safety Circuits

¹¹Switching



شکل ۲-۳: نمای کلی اجزای سامانه‌ی مدیریت باتری و زنجیره تبادل علائم



شکل ۲-۴: زنجیره‌ی داده از حسگرهای فیزیکی و مراحل پیش‌پردازش تا مدل تخمین‌گر

به دلیل محدودیت‌های نصب حسگرهای فیزیکی در تمامی نقاط باتری و احتمال خرابی آن‌ها، استفاده از حسگر مجازی اهمیت می‌یابد. حسگر مجازی با بهره‌گیری از مدل‌های بر پایه داده، کمیت‌هایی نظیر دما را بر اساس علائم در دسترس (ولتاژ و جریان) تخمین می‌زند [۲۵]. زنجیره‌ی پردازش داده از حسگرهای فیزیکی تا مدل حسگر مجازی در شکل ۲-۴ ترسیم شده است.

در این زنجیره، داده‌های خام حسگرها پس از نمونه‌برداری و دیجیتال‌سازی، وارد زنجیره‌ی پیش‌پردازش می‌شوند و سپس به صورت هم‌زمان‌سازی شده و در قالب پنجره‌های زمانی به مدل حسگر مجازی تزریق می‌گردند. در این مسیر، اختلاف نرخ نمونه‌برداری میان سیگنال‌ها (به‌ویژه میان ولتاژ/جریان و دما)، محدودیت تفکیک‌پذیری اندازه‌گیری و تأخیرهای ارتباطی می‌تواند هم‌راستایی زمانی داده‌ها را مختل کند؛ از این رو گام‌هایی همانند پالایش نوفه، حذف داده‌های پرت، نرمال‌سازی^{۱۲} و مقیاس‌بندی پیش از یادگیری

¹²Normalization

ضروری است [۲۵، ۲۶]. در این پژوهش، خروجی این زنجیره به گونه‌ای آماده‌سازی می‌شود که ورودی مدل BiGRU بازتاب‌دهنده‌ی ساختار زمانی واقعی داده‌های عملیاتی باشد.

۳-۲ مبانی یادگیری ماشین و معماری‌های یادگیری عمیق

یادگیری ماشین^{۱۳}، یکی از شاخه‌های کلیدی هوش مصنوعی، به توسعه‌ی الگوریتم‌هایی گفته می‌شود که سامانه‌ها بتوانند بدون نیاز به برنامه‌نویسی صریح، از داده‌ها، الگوهای را استخراج کنند [۲۷]. هدف اصلی این رویکرد، بهبود تدریجی عملکرد سامانه بر پایه‌ی تجربه و داده‌های مشاهده‌شده است تا بتواند در شرایط جدید، تصمیم‌گیری و پیش‌بینی دقیق‌تری ارائه دهد. یادگیری ماشین به‌طور کلی به سه دسته‌ی اصلی تقسیم می‌شود:

- یادگیری نظارت‌شده^{۱۴} که در آن الگوریتم با داده‌های ورودی به‌همراه خروجی‌های مشخص آموزش می‌بیند.

- یادگیری بدون نظارت^{۱۵} که در آن سامانه به استخراج ساختارها و الگوهای پنهان در داده‌های فاقد برچسب می‌پردازد.

- یادگیری تقویتی^{۱۶} که بر پایه تعامل با محیط و بهینه‌سازی سیاست رفتاری بنا شده است.

در سامانه‌های مدیریت باتری، یادگیری نظارت‌شده بیشترین کاربرد را در مسائل تخمین و پیش‌بینی ایفا می‌کند.

۱-۳-۲ مروری بر مدل‌های فیزیکی و مدل‌های بر پایه‌ی داده

مدل‌سازی رفتار باتری به‌طور کلی در دو دسته‌ی اصلی مدل‌های فیزیکی و مدل‌های بر پایه‌ی داده قرار می‌گیرد [۲۸]. مدل‌های فیزیکی بر پایه‌ی قوانین الکتروشیمی و مدارهای معادل الکتریکی^{۱۷} بنا شده‌اند. مزیت اصلی این مدل‌ها، قابلیت تفسیر بالا است؛ با این حال، واسنجی^{۱۸} آن‌ها در شرایط متنوع عملیاتی چالش‌برانگیز است.

¹³Machine Learning


¹⁴Supervised Learning

¹⁵Unsupervised Learning

¹⁶Reinforcement Learning

¹⁷Equivalent Circuit Models – ECM

¹⁸Calibration



شکل ۲-۵: نمای کلی ساختار شبکه‌ی عصبی کانولوشنی در تحلیل داده‌های باتری

در مقابل، مدل‌های بر پایه‌ی داده با استفاده از داده‌های عملیاتی، روابط پیچیده را بدون نیاز به مدل‌سازی صریح فیزیکی یاد می‌گیرند. در سال‌های اخیر، استفاده از معماری‌های یادگیری عمیق^{۱۹} در حوزه‌ی تخمین وضعیت باتری و تشخیص ناهنجاری^{۲۰} مورد توجه گسترده قرار گرفته است [۲۵، ۲۹، ۳۰].

۲-۳-۲ معماری‌های رایج یادگیری عمیق برای تحلیل داده‌های باتری

شبکه‌های عصبی کانولوشنی

شبکه‌های عصبی کانولوشنی (CNN)^{۲۱} یکی از معماری‌های پرکاربرد هستند که به‌ویژه برای استخراج ویژگی از داده‌های ساختاریافته مناسب‌اند. این شبکه‌ها با بهره‌گیری از لایه‌های کانولوشنی^{۲۲}، قادر به استخراج خودکار الگوهای تکرارشونده هستند [۳۱]. مطابق شکل ۲-۵، لایه‌های کانولوشنی اولیه ویژگی‌های پایه‌ای و لایه‌های عمیق‌تر مفاهیم سطح بالاتر را شناسایی می‌کنند. در ادامه، لایه‌ی تجمیع^{۲۳} با هدف کاهش بُعد عمل کرده تا خروجی برای مراحل پیش‌بینی آماده شود.


¹⁹Deep Learning

²⁰Anomaly Detection

²¹Convolutional Neural Network – CNN

²²Convolutional Layers

²³Pooling Layer



شکل ۲-۶: نمای ساختار واحد LSTM

شبکه‌های حافظه‌ی طولانی کوتاه مدت

شبکه‌های LSTM گونه‌ای از شبکه‌های عصبی بازگشتی هستند که برای مدل‌سازی وابستگی‌های زمانی بلندمدت طراحی شده‌اند. این شبکه‌ها با بهره‌گیری از سازوکار دروازه‌ای^{۲۴}، جریان اطلاعات را کنترل می‌کنند. مطابق شکل ۲-۶، یک سلول LSTM به کمک سه دروازه‌ی اصلی عمل می‌کند: دروازه‌ی فراموشی^{۲۵}، دروازه‌ی ورودی^{۲۶} و دروازه‌ی خروجی^{۲۷}.

واحدهای بازگشتی دروازه‌دار

واحدهای GRU نسخه‌ای ساده‌تر از LSTM هستند که با ساختار فشرده‌تر طراحی شده‌اند. مطابق شکل ۲-۷، این معماری به کمک دروازه‌ی بازنشانی^{۲۸} و دروازه‌ی به‌روزرسانی^{۲۹} جریان اطلاعات را کنترل می‌کند. این ساختار موجب کاهش پیچیدگی محاسباتی و افزایش سرعت یادگیری در سامانه می‌گردد.

شبکه‌های عصبی بازگشتی دوسویه

مدل‌های BiGRU داده‌های دنباله‌ای را به صورت هم‌زمان از دو جهت زمانی پردازش می‌کنند [۳۲]. ساختار دوسویه که در شکل ۲-۸ مشاهده می‌شود، امکان استخراج اطلاعات غنی‌تری را فراهم می‌سازد که در

²⁴Gating Mechanism


²⁵Forget Gate

²⁶Input Gate


²⁷Output Gate

²⁸Reset Gate

²⁹Update Gate



شکل ۲-۷: نمای ساختار واحد GRU



شکل ۲-۸: نمای ساختار شبکه‌ی عصبی بازگشتی دوسویه BiGRU

شبیه‌سازی حسگرهای مجازی اهمیت بالایی دارد.

۲-۳-۳ تنظیم دقیق در مدل‌های یادگیری عمیق

یکی از چالش‌های اصلی در کاربرد مدل‌های یادگیری عمیق در سامانه‌های رایا-فیزیکی، نیاز به داده‌های آموزشی بزرگ و منابع محاسباتی بالا برای آموزش از صفر است. مدل‌های پیش‌آموزش شده بر روی داده‌های عمومی می‌توانند با تنظیم دقیق بر روی داده‌های خاص وظیفه، عملکرد بهتری ارائه دهند و از دانش عمومی بهره ببرند [۳۳، ۳۴].

برای دستیابی به عملکرد بهینه در وظیفه‌های خاص، رویکرد تنظیم دقیق^{۳۰} پیشنهاد شده است که در آن، مدل پیش‌آموزش دیده با داده‌های هدف آموزش می‌بیند تا مشخصه‌ها را برای آن وظیفه خاص تنظیم کند. راهکارهای اصلی در این زمینه شامل تنظیم دقیق تمام لایه‌ها است که در آن همه پارامترهای مدل با نرخ یادگیری پایین به‌روزرسانی می‌شوند تا دانش پیش‌آموزش دیده حفظ شود [۳۵]. در رویکردی دیگر،

³⁰Fine-Tuning

تنها لایه‌های بالایی مدل تنظیم می‌شوند تا ضمن کاهش مصرف منابع، از بیش‌برازش^{۳۱} جلوگیری گردد [۳۶]. علاوه بر این، استفاده از تکنیک‌های منظم‌سازی نظیر حذف تصادفی^{۳۲} یا کاهش وزن^{۳۳} برای افزایش تعمیم‌پذیری مدل در حین تنظیم دقیق اهمیت بالایی دارد [۳۱]. در نهایت، برای سناریوهایی با محدودیت داده، روش‌هایی مانند یادگیری با تعداد کم نمونه^{۳۴} یا افزایش داده^{۳۵} به کار گرفته می‌شود تا مدل بتواند به‌طور بهینه با نمونه‌های اندک سازگار شود [۳۷].

داده‌های خاص وظیفه ممکن است توزیع متفاوتی نسبت به داده‌های پیش‌آموزش داشته باشند و بدون تنظیم دقیق، مدل عملکرد ضعیفی نشان دهد. در سامانه‌ی مدیریت باتری، چنین داده‌هایی می‌توانند شامل مقادیر حسگری واقعی از باتری‌های خودرو باشند که با تنظیم دقیق، مدل را برای تخمین دقیق‌تر آماده می‌کنند [۳۸]. تنظیم دقیق فرایندی است که در آن مدل‌های پیش‌آموزش‌شده با داده‌های هدف وظیفه آموزش می‌بینند تا عملکرد بهینه در آن وظیفه خاص حاصل شود. به کارگیری تنظیم دقیق می‌تواند کارایی مدل را افزایش داده و نیاز به آموزش از صفر را کاهش دهد، که این امر در سامانه‌های واقعی با منابع محدود اهمیت دارد [۲۵].

۴-۲ اشکال و تزریق اشکال در سامانه‌های رایا-فیزیکی

۱-۴-۲ مفاهیم پایه: اشکال، خطا و خرابی

در مهندسی قابلیت اطمینان، سه مفهوم کلیدی برای توصیف رفتار سامانه‌ها و ارزیابی پایداری آن‌ها به کار می‌رود: اشکال، خطا^{۳۶} و خرابی [۳۹]. این مفاهیم برای تحلیل سامانه‌های هوشمند و رایا-فیزیکی، از جمله سامانه‌ی مدیریت باتری، اهمیت ویژه‌ای دارند. به‌طور مفهومی، اشکال «علت» است، خطا «حالت داخلی نادرست» و خرابی «بروز بیرونی و قابل مشاهده‌ی خروجی نادرست» است. شکل ۲-۹ رابطه‌ی کلی میان این سه مفهوم را نمایش می‌دهد.

اشکال به هر عاملی گفته می‌شود که می‌تواند توانایی سامانه را برای عملکرد صحیح کاهش دهد؛ همانند خرابی حسگر، قطع ارتباط، تداخل الکترومغناطیسی یا مشکل در مسیر علائم. اشکال لزوماً بلافاصله به خرابی منجر نمی‌شود، اما زمینه‌ی بروز خطا را فراهم می‌کند. برای نمونه، اشکال در حسگر دما می‌تواند داده‌ی اندازه‌گیری را مخدوش کرده و تخمین دما را دچار انحراف کند.

³¹Overfitting


³²Dropout

³³Weight Decay

³⁴Few-Shot Learning

³⁵Data Augmentation

³⁶Error



شکل ۲-۹: رابطه‌ی مفهومی میان اشکال، خطا و خرابی

خطا وضعیتی است که در آن حالت داخلی یا خروجی محاسبه‌شده‌ی سامانه از مقدار واقعی/مطلوب منحرف می‌شود و معمولاً پیامد مستقیم فعال‌شدن یک اشکال است [۴۰]. برای مثال، اگر اشکال حسگر دما موجب ارسال داده‌ی نادرست به واحد پردازش شود، خطا در تخمین دما یا در تصمیم‌گیری سامانه‌ی حرارتی رخ می‌دهد.

خرابی زمانی رخ می‌دهد که رفتار سامانه از مشخصات عملکردی یا نیازمندی‌های ایمنی تعریف‌شده فراتر رود و خروجی نادرست در سطح سامانه مشاهده شود. در سامانه‌های حساس همانند خودروهای الکتریکی، خرابی می‌تواند پیامدهایی همانند کاهش عمر باتری، برآورد نادرست وضعیت شارژ، یا حتی تشدید شرایط خطرناک (همانند فرار حرارتی) داشته باشد.


در سامانه‌های رایا-فیزیکی، اشکال می‌تواند در یک لایه رخ دهد و سپس در زنجیره‌ی حسگر-پردازشگر-عملگر انتشار یابد؛ به گونه‌ای که ابتدا خطا در محاسبه‌ها و یا تخمین ایجاد شده و در نهایت به خرابی در سطح عملکردی یا ایمنی منجر شود. اشکال حسگری می‌تواند باعث خطا در تخمین کمیت هدف شود و این خطا، تصمیم‌کنترلی نامناسب را تحریک کند؛ سپس اعمال نادرست در سامانه‌ی حرارتی یا محدودسازی جریان می‌تواند خرابی در سطح سامانه را رقم بزند. از این رو، شبیه‌سازی و ارزیابی این زنجیره برای شناسایی نقاط آسیب‌پذیر ضروری است [۲۱].

۲-۴-۲ طبقه‌بندی اشکال‌ها و انواع اشکال‌های حسگری

در کنار دسته‌بندی‌هایی همانند گذرا و دائمی، استانداردهای ایمنی و ادبیات قابلیت اطمینان، طبقه‌بندی‌های کلیدی دیگری را برای تحلیل دقیق رفتار سامانه‌های مدیریت باتری ارائه می‌دهند [۴۱، ۱۷، ۴۲، ۴۳]. طبق استاندارد ISO 26262، این اشکال‌ها شامل سه دسته اصلی هستند: نخست، اشکال‌های سخت‌افزاری تصادفی^{۳۷} که ناشی از فرایندهای فیزیکی پیش‌بینی‌ناپذیر در قطعات بوده و با نرخ‌های آماری مدل‌سازی می‌شوند. دوم، اشکال‌های ناشی از طراحی^{۳۸} که از نقص در مشخصات یا پیاده‌سازی نادرست نرم‌افزار و

^{۳۷}Random Hardware Faults

^{۳۸}Systematic Faults



شکل ۲-۱۰: طبقه‌بندی اشکال‌های حسگری و گونه‌های متداول برای تزریق اشکال


سخت‌افزار نشست گرفته و در شرایط عملیاتی خاص فعال می‌گردند [۹]. در نهایت، اشکال‌های پنهان^{۳۹} قرار دارند که تا زمان وقوع ترکیب خاصی از رخدادها ناشناخته باقی مانده و می‌توانند به خرابی‌های جدی در زنجیره پردازش منجر شوند.

از منظر معماری سامانه‌های رایا-فیزیکی، اشکال‌ها را می‌توان در لایه‌های مختلف دسته‌بندی کرد: اشکال‌های حسگری، اشکال‌های محاسباتی و الگوریتمی، و اشکال‌های ارتباطی و عملگری. در این پژوهش تمرکز اصلی بر اشکال‌های حسگری و اثر آن‌ها بر زنجیره‌ی تخمین و کنترل در سامانه‌ی مدیریت باتری است؛ با این حال، چارچوب تحلیل قابلیت اطمینان و شاخص‌های آسیب‌پذیری قابل تعمیم به سایر لایه‌ها نیز خواهد بود.

برای یک‌دست‌سازی طبقه‌بندی و کمک به طراحی سناریوهای تزریق اشکال، شکل ۲-۱۰ نمایی مفهومی از اشکال‌های رایج حسگری مورد استفاده در این پژوهش و دسته‌بندی آن‌ها را ارائه می‌کند. همچنین، به‌منظور درک شهودی رفتار زمانی هر اشکال، شکل ۲-۱۱ اشکال‌های حسگری را در مقایسه با علائم سالم نمایش می‌دهد. گونه‌های رایج اشکال حسگری عبارتند از:

- **نوفه:** نوسان‌های تصادفی کوچک که روی علائم اصلی قرار می‌گیرند و معمولاً میانگین آن‌ها نزدیک به صفر است. نوفه به‌صورت نوسان‌های سریع و نامنظم اطراف علائم سالم ظاهر می‌شود و ساختار کلی علائم را حفظ می‌کند [۲۵].
- **داده‌ی پرت:** نمونه‌هایی که مقدار آن‌ها به‌صورت غیرعادی از روند کلی علائم فاصله دارد، بدون آن‌که رفتار زمانی علائم در سایر نقاط تغییر کند. داده‌های پرت به‌صورت نقاط منفرد با انحراف شدید نسبت به علائم سالم نمایش داده شده‌اند.
- **تغییر ناگهانی:** یک جهش تیز و کوتاه‌مدت در دامنه‌ی علائم که نسبت به نوفه دامنه‌ی بزرگ‌تری دارد و در بازه‌ی زمانی بسیار کوتاه رخ می‌دهد. این اشکال به‌صورت یک پالس باریک با دامنه‌ی بالا ظاهر می‌شود [۴۴].

³⁹Latent Faults



شکل ۲-۱۱: مقایسه علائم حسگری در شرایط سالم و رخداد اشکال. در این نمودار، منحنی آبی نشان‌دهنده علائم سالم و منحنی نارنجی بیانگر علائم دارای اشکال است.

- انحراف: جابه‌جایی ثابت و پایدار خروجی حسگر نسبت به مقدار واقعی، به گونه‌ای که کل علائم به اندازه‌ی یک مقدار ثابت به بالا یا پایین منتقل می‌شود. شکل کلی علائم حفظ شده اما سطح آن نسبت به علائم سالم تغییر یافته است.
- رانش: تغییر تدریجی و پیوسته‌ی خروجی حسگر نسبت به مقدار واقعی در طول زمان. رانش به صورت جابه‌جایی آهسته‌ی خط مبنای علائم نسبت به حالت سالم نمایش داده شده است [۲۱].
- چسبندگی: قفل شدن خروجی حسگر روی یک مقدار ثابت و عدم انعکاس تغییرهای واقعی کمیت اندازه‌گیری شده. این اشکال به صورت یک خط افقی ثابت ظاهر می‌شود [۲۰].
- بریدگی بیشینه/کمینه: اشباع خروجی در حد بالا/پایین قابل اندازه‌گیری حسگر یا مبدل. این پدیده موجب از دست رفتن اطلاعات دامنه‌ای می‌شود [۴۴].

۲-۴-۳ تحمل‌پذیری اشکال و تزریق اشکال در سامانه‌های مدیریت باتری

تزریق اشکال یک روش آزمایشی است که در آن اشکال‌های مصنوعی به‌صورت کنترل‌شده به سامانه اعمال می‌شود تا واکنش آن در شرایط غیرعادی ارزیابی گردد [۴۰]. این رویکرد به‌ویژه برای سامانه‌های حیاتی همانند سامانه‌ی مدیریت باتری اهمیت دارد، زیرا امکان بررسی پایداری زنجیره‌ی اندازه‌گیری-تخمین-تصمیم‌گیری در حضور داده‌های معیوب را فراهم می‌کند. در این چارچوب، اشکال‌های مشخص به داده‌های ورودی اعمال می‌شود، سپس عملکرد حسگر مجازی، تخمین و معیارهای پایداری تحلیل می‌شود.

برای افزایش قابلیت اطمینان سامانه‌های رایا-فیزیکی و خودرویی، دو رویکرد اصلی وجود دارد: روش‌های سخت‌افزاری و روش‌های نرم‌افزاری تحمل‌پذیری اشکال [۱۷، ۴۲، ۴۵]. روش‌های سخت‌افزاری با استفاده از افزونگی فیزیکی سعی می‌کنند اثر اشکال‌ها را کاهش دهند. مهم‌ترین این روش‌ها عبارتند از:

- افزونگی پیمانه‌ای سه‌گانه: در این روش، سه نسخه‌ی مستقل از یک واحد (همانند حسگر یا واحد کنترلی) به‌طور موازی کار می‌کنند و یک رأی‌گیر خروجی نهایی را بر اساس نظر اکثریت انتخاب می‌کند. این روش در سامانه‌های بحرانی کاربرد دارد، اما هزینه‌ی سخت‌افزاری و مصرف توان را به‌طور قابل‌توجهی افزایش می‌دهد [۱۷].
- واحد یدک آماده^{۴۰}: در این روش، یک واحد اصلی و یک یا چند واحد یدک وجود دارد که در صورت بروز اشکال در واحد اصلی، واحد یدک جایگزین آن می‌شود. تحلیل قابلیت اطمینان این ساختارها در سامانه‌های اشکال‌پذیر به‌تفصیل بررسی شده است [۴۵].
- افزونگی حسگری فیزیکی: نصب چند حسگر برای یک کمیت (همانند چند حسگر دما در نقاط مختلف بسته‌ی باتری) و استفاده از الگوریتم‌های رأی‌گیری یا میانگین‌گیری وزنی برای کاهش اثر اشکال‌های موضعی [۲۰، ۴۶].

اگرچه این روش‌ها قابلیت اطمینان را به‌طور چشمگیری بهبود می‌دهند، اما در سامانه‌های صنعتی با محدودیت‌های هزینه، وزن، حجم و مصرف توان، استفاده‌ی گسترده از آن‌ها معمولاً عملی نیست. در مقابل، روش‌های نرم‌افزاری با بهره‌گیری از الگوریتم‌ها، مدل‌های تخمینی و پردازش داده، اثر اشکال‌ها را کاهش می‌دهند یا جبران می‌کنند. مهم‌ترین این روش‌ها عبارتند از:

⁴⁰Standby Sparing

- پالایه‌های تخمینی همانند پالایه کالمن^{۴۱} و انواع غیرخطی آن: این پالایه‌ها با ترکیب مدل سامانه و اندازه‌گیری‌های حسگر، برآوردی بهینه از وضعیت ارائه می‌دهند و اثر نوفه و برخی اشکال‌های اندازه‌گیری را کاهش می‌دهند [۲۸، ۴۷].

- حسگرهای مجازی بر پایه مدل: استفاده از مدل‌های فیزیکی یا بر پایه داده برای بازسازی خروجی حسگرهای معیوب، گم‌شده یا دارای نوفه و ایجاد نوعی افزونگی نرم‌افزاری [۲۰].

- کنترل مقاوم و کنترل اشکال‌پذیر: طراحی قانون‌های کنترلی که در برابر اشکال‌های حسگری و عملکردی حساسیت کمتری دارند و در صورت بروز اشکال، سامانه را در محدوده‌ی امن نگه می‌دارند [۳۸، ۱۲، ۴۲].

در این پژوهش، تمرکز اصلی بر رویکرد نرم‌افزاری و توسعه‌ی یک حسگر مجازی مبتنی بر BiGRU است که بدون نیاز به افزونگی سخت‌افزاری پرهزینه، امکان بازسازی داده‌های معیوب و افزایش تحمل‌پذیری اشکال در سامانه‌ی مدیریت باتری را فراهم می‌کند.

۵-۲ شاخص‌های ارزیابی خطا و آسیب‌پذیری

به‌منظور ارزیابی دقیق عملکرد مدل‌های تخمینی در سامانه‌های هوشمند و سنجش میزان پایداری آن‌ها در حضور اشکال، استفاده از شاخص‌های کمی برای اندازه‌گیری انحراف خروجی ضروری است. این شاخص‌ها نه تنها دقت مدل در شرایط عادی، بلکه میزان تخریب عملکرد^{۴۲} را در زمان وقوع اشکال نیز تبیین می‌کنند [۱۷].

۱-۵-۲ شاخص‌های آماری ارزیابی خطا

در این پژوهش، از دو شاخص استاندارد برای مقایسه‌ی مقادیر تخمینی ($\hat{y}$) با مقادیر واقعی (y) استفاده می‌شود. انتخاب این دو شاخص به دلیل رفتار متفاوت آن‌ها در مواجهه با داده‌های پرت و خطاهای بزرگ است.

^{۴۱}Kalman Filter

^{۴۲}Performance Degradation

میانگین مطلق خطا

شاخص میانگین مطلق خطا، میانگین بزرگی خطاها را در یک مجموعه‌ی داده، بدون در نظر گرفتن جهت آن‌ها، اندازه‌گیری می‌کند. این شاخص وزن یکسانی به تمامی خطاها می‌دهد و نسبت به خطاهای بسیار بزرگ (داده‌های پرت) حساسیت کمتری دارد. فرمول ریاضی این شاخص به شرح زیر است [۱۷]:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (۱-۲)$$

که در آن n تعداد نمونه‌ها، y_i مقدار واقعی و $\hat{y}_i$ مقدار پیش‌بینی شده برای نمونه‌ی i -ام است.

جذر میانگین مربعات خطا

شاخص جذر میانگین مربعات خطا (RMSE)^{۴۳}، میانگین توان دوم خطاها را محاسبه کرده و سپس از آن جذر می‌گیرد. به دلیل مربع شدن جملات خطا، این شاخص به خطاهای بزرگ جریمه‌ی بیشتری اختصاص می‌دهد. در سامانه‌های مدیریت باتری، این ویژگی بسیار حیاتی است؛ زیرا خطاهای کوچک در تخمین دما ممکن است قابل چشم‌پوشی باشند، اما خطاهای بزرگ می‌توانند منجر به تصمیمات کنترلی فاجعه‌بار (مانند عدم تشخیص فرار حرارتی) شوند. این شاخص مطابق رابطه‌ی زیر تعریف می‌شود [۱۷]:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (۲-۲)$$

۲-۵-۲ ارزیابی پایداری با شاخص آسیب‌پذیری

در مهندسی سیستم‌های اشکال‌پذیر، صرفاً اندازه‌گیری خطا کافی نیست، بلکه باید تأثیر تزریق اشکال بر خروجی نسبت به حالت بدون اشکال سنجیده شود [۱۷]. شاخص آسیب‌پذیری معیاری است که نشان می‌دهد عملکرد مدل با ورود اشکال، تا چه اندازه نسبت به عملکرد بهینه‌ی خود منحرف می‌شود [۲۱]. این شاخص معمولاً به صورت زیر تعریف می‌گردد:

شاخص VF در این پژوهش به صورت نسبت تعداد اشکال‌هایی که منجر به شکست سامانه شده‌اند به کل تعداد اشکال‌های تزریق شده تعریف می‌گردد:

$$VF = \frac{N_{\text{failure}}}{N_{\text{faults}}} \quad (۳-۲)$$

تحلیل این شاخص به شرح زیر است:

⁴³Root Mean Square Error – RMSE

• اگر $VF \approx 1$: نشان‌دهنده‌ی آسیب‌پذیری بالای سامانه است؛ زیرا تقریباً تمامی اشکال‌های تزریق‌شده به شکست منجر شده‌اند.

• اگر $VF < 1$: بیانگر مقاومت بیشتر سامانه است؛ هرچه این مقدار کمتر باشد، نسبت اشکال‌های منجر به شکست کاهش یافته و سامانه مقاوم‌تر است.

این شاخص در این پژوهش ابزار اصلی برای ارزیابی حسگرهای مجازی تقریبی و مقایسه‌ی سناریوهای مختلف تزریق اشکال در لایه‌ی فیزیکی و محاسباتی است.

۶-۲ مفاهیم قابلیت اطمینان

قابلیت اطمینان به معنای احتمال عملکرد صحیح یک سامانه در مدت‌زمان مشخص و تحت شرایط تعریف‌شده، به شرط آن که در لحظه‌ی شروع ($t = 0$) سالم باشد، تبیین می‌گردد [۳۹]. در سامانه‌های هوشمند خودرویی، این مفهوم بیانگر توانایی سامانه در حفظ عملکرد ایمن و پایدار در شرایط مختلف عملیاتی، حتی در حضور داده‌های معیوب و اشکال‌های سخت‌افزاری یا نرم‌افزاری است. هرگونه ضعف در این زمینه می‌تواند به کاهش عمر باتری، آسیب به اجزای خودرو و بروز رخدادهای ایمنی همانند فرار حرارتی منجر شود.

به‌طور معمول، قابلیت اطمینان در دو سطح مکمل بررسی می‌شود: قابلیت اطمینان سخت‌افزاری که به پایداری حسگرها، مدارهای الکترونیکی و اجزای فیزیکی اشاره دارد، و قابلیت اطمینان نرم‌افزاری که عملکرد صحیح الگوریتم‌ها، مدل‌های یادگیری ماشین و منطق‌های کنترلی را پوشش می‌دهد. در سامانه‌ی مدیریت باتری، اشکال در هر یک از این دو سطح می‌تواند زنجیره‌ی تخمین، تصمیم‌گیری و کنترل را مختل کرده و زمینه‌ساز خرابی شود.

۱-۶-۲ توزیع نرخ خرابی و پدیده‌ی پیری

در تحلیل‌های قابلیت اطمینان، اغلب فرض می‌شود که نرخ خرابی (λ) در طول دوره‌ی عمر مفید سامانه ثابت است. در این شرایط، زمان تا خرابی از توزیع نمایی پیروی می‌کند و تابع قابلیت اطمینان به‌صورت $R(t) = e^{-\lambda t}$ تعریف می‌شود. با این حال، حسگرها و اجزای الکترونیکی در عمل دچار پدیده‌ی پیری^{۴۴} می‌شوند که در آن نرخ خرابی با گذشت زمان افزایش می‌یابد [۲۱].

⁴⁴ Aging

برای مدل سازی دقیق تر این رفتار، از توزیع وایبول^{۴۵} استفاده می شود. تابع قابلیت اطمینان در این توزیع به شکل زیر تعریف می گردد:

$$R(t) = e^{-\left(\frac{t}{\eta}\right)^\beta} \quad (۴-۲)$$

که در آن β مشخصه شکل^{۴۶} و η مشخصه مقیاس است. اگر $\beta > 1$ باشد، مدل بیانگر افزایش نرخ خرابی به دلیل پیری و فرسودگی است که با ماهیت حسگرهای فیزیکی در محیط های خشن خودرویی سازگاری بیشتری دارد [۲۱، ۱۸].

۲-۶-۲ شاخص های زمانی قابلیت اطمینان

میانگین زمان تا خرابی

میانگین زمان تا خرابی (MTTF)^{۴۷}، امید ریاضی مدت زمانی است که سامانه پیش از بروز اولین خرابی به درستی عمل می کند. برای سامانه هایی که از توزیع نمایی با نرخ ثابت λ پیروی می کنند، این شاخص برابر با $1/\lambda$ است. اما در حضور پیری، توزیع وایبول، $MTTF$ تابعی از مشخصه های شکل و مقیاس خواهد بود [۴۸].

میانگین زمان بین خرابی ها

برای سامانه های تعمیر پذیر، شاخص میانگین زمان بین خرابی ها (MTBF)^{۴۸} استفاده می شود که مجموع $MTTF$ و میانگین زمان لازم برای تعمیر (MTTR)^{۴۹} را در بر می گیرد [۴۸]:

$$MTBF = MTTF + MTTR \quad (۵-۲)$$

۳-۶-۲ ارزیابی قابلیت اجرا و تحلیل اطمینان پذیری

در سامانه های رایا-فیزیکی حساس مانند واحد مدیریت باتری، نگرش دوتایی (سالم/خراب) برای ارزیابی دقیق کافی نیست؛ زیرا سامانه ممکن است در حضور اشکال، با دقت کمتری به کار خود ادامه دهد که از آن

⁴⁵Weibull Distribution

⁴⁶Shape Parameter

⁴⁷Mean Time To Failure – MTTF

⁴⁸Mean Time Between Failures – MTBF

⁴⁹Mean Time To Repair – MTTR

با عنوان تخریب تدریجی عملکرد یاد می‌شود. شاخص قابلیت اجرا^{۵۰}، ترکیبی از قابلیت اطمینان و کارایی است و توانایی سامانه را در ارائه‌ی سطحی از عملکرد قابل قبول در یک بازه‌ی زمانی مشخص می‌سنجد [۲۱].

در این پژوهش، برای کمی‌سازی قابلیت اجرا، ابتدا بر اساس میزان خطای میانگین مطلق (MAE)^{۵۱} و با استناد به چارچوب‌های ایمنی در هوش مصنوعی خودرویی [۱۵]، سه حالت عملکردی برای سامانه تعریف می‌شود:

- **حالت مطلوب:** زمانی که $MAE < 5$ است و سامانه در دقیق‌ترین حالت عملیاتی قرار دارد.
- **حالت هشدار:** زمانی که $5 \leq MAE \leq 10$ است؛ در این حالت سامانه دچار تخریب عملکرد شده اما همچنان قابل استفاده است.
- **حالت بحرانی:** زمانی که $MAE > 10$ است و خطا از آستانه تحمل ایمنی فراتر رفته و سامانه از چرخه عملیاتی خارج می‌شود.

در ارزیابی نهایی، نرخ خرابی هدف (λ) بر اساس استاندارد ایمنی خودرو ISO 26262 [۹] در دو سطح مورد تحلیل قرار می‌گیرد: سطح ASIL-B با نرخ $\lambda = 10^{-7}$ ، شکست در هر ساعت برای کاربردهای عمومی و سطح سخت‌گیرانه‌تر ASIL-D با نرخ $\lambda = 10^{-9}$ برای عملکردهای حیاتی سامانه. تابع قابلیت اجرا در زمان t برای هر حالت به صورت توزیع نمایی زیر تبیین می‌گردد [۲۱]:

$$P_{state}(t) = e^{-(VF_{state} \cdot \lambda \cdot t)} \quad (6-2)$$

در نهایت، برای انطباق با استانداردهای صنعتی، میزان اطمینان‌پذیری سامانه بر اساس شاخص تعداد نه‌ها^{۵۲} گزارش می‌شود [۴۹]:

$$Nines = -\log_{10}(1 - P) \quad (7-2)$$

این مدل‌سازی اجازه می‌دهد تا تاثیر تزریق اشکالات گذرا و دائمی بر روی پایداری مدل در درازمدت، فراتر از معیارهای آماری ساده، ارزیابی شود.

⁵⁰Performability

⁵¹Mean Absolute Error – MAE

⁵²Number of Nines

فصل ۳

کارهای پیشین

در این بخش، شماری از پژوهش‌های پیشین مرتبط با موضوع پژوهش مورد بررسی قرار می‌گیرند که در ۳ دسته کلی قرار می‌گیرند: (۱) پیش‌بینی دمای باتری و حسگرهای مجازی دما، (۲) تشخیص اشکال حسگر و راهبردهای تحمل‌پذیری در سامانه مدیریت باتری، و (۳) تزریق اشکال و آموزش/اعتبارسنجی مقاوم به عنوان ابزارهای کلیدی مهندسی قابلیت اطمینان در سامانه‌های نهفته^۱ بحرانی-ایمن^۲ مورد بررسی قرار می‌گیرند.

۳-۱ مرور پژوهش‌های پیشین در پیش‌بینی دمای باتری

پژوهش‌های موجود بر اساس رویکرد مورد استفاده به سه دسته روش‌های بر پایه مدل فیزیکی، روش‌های بر پایه داده و روش‌های ترکیبی طبقه‌بندی شده‌اند. در هر زیربخش، پژوهش‌های شاخص به صورت تحلیلی بررسی شده و شاخص‌های صحت تخمین نظیر MAE و RMSE در کنار ملاحظه‌های معماری مانند سربار محاسباتی^۳ ذکر شده‌اند.

۳-۱-۱ روش‌های بر پایه مدل فیزیکی

در این روش‌ها، رفتار حرارتی باتری با استفاده از مدل‌های معادل حرارتی-الکتریکی توصیف می‌شود. مزیت عمومی این دسته، تفسیرپذیری بالا است، اما وابستگی شدید به دقت مشخصه‌های فیزیکی یک

^۱Embedded Systems

^۲Safety Critical

^۳Computational Overhead

محدودیت جدی محسوب می‌شود [۲۸].

در پژوهش [۵۰]، یک چارچوب بر پایه پالایه کالمن توسعه‌یافته^۴ برای تخمین هم‌زمان دمای باتری و SOC ارائه شده است. با این حال، گزارش شده است که در حضور عدم قطعیت در مدل یا بروز اشکال در حسگرها، صحت تخمین دچار افت فاحش می‌شود.

در پژوهش [۵۱]، نشان داده شده است که افزایش دما به بیش از ۶۰ درجه سلسیوس منجر به افت محسوس ظرفیت و تغییر در الگوهای ولتاژ و جریان می‌گردد. از منظر معماری سامانه مدیریت باتری، این مطالعه تأکید می‌کند که به دلیل اثر متقابل دما و علائم الکتریکی، پیمایش‌های تخمین باید نسبت به تغییرهای دمایی شدید تاب‌آور طراحی شوند تا از بروز اشکال زنجیره‌ای در تخمین مشخصه‌ها جلوگیری شود.

۳-۱-۲ روش‌های بر پایه داده

در روش‌های بر پایه داده، نگاشت غیرخطی میان مشخصه‌ها مستقیماً از داده‌های تجربی آموخته می‌شود. پژوهش [۲۴] نشان می‌دهد که مدل‌های یادگیری عمیق در شرایط آموزش دیده دقت بسیار بالایی دارند، اما تعمیم‌پذیری^۵ آن‌ها در شرایط خارج از توزیع^۶ داده‌های آموزشی چالش برانگیز است.

در پژوهش [۳۰]، یک شبکه دوطرفه بر پایه مدل‌های نوین فضای حالت Mamba^۷ ارائه شده است. نتایج این پژوهش بر روی داده‌های واقعی خودرو نشان می‌دهد که این مدل به صحت بالایی با مقدار MAE حدود ۰/۳۱۵ و RMSE حدود ۰/۴۴۸ دست یافته است. از منظر معماری، استفاده از ساختار Mamba منجر به کاهش پیچیدگی محاسباتی در دنباله‌های طولانی نسبت به مدل‌های بر پایه تبدیل‌کننده^۸ شده است که برای استقرار در سامانه‌های نهفته یک مزیت کلیدی است.

در پژوهش [۴۴]، از شبکه عصبی بازگشتی GRU برای تخمین دمای سطح باتری استفاده شده است. در این مطالعه ثابت شده است که تخمین دما یک وظیفه سری زمانی^۹ است و با ارائه یک روش نرمال‌سازی داده بهبودیافته، پایداری مدل در شرایط دینامیک افزایش یافته است. این رویکرد به سامانه مدیریت باتری کمک می‌کند تا با دقت بیشتری محدودیت‌های حفاظتی را اعمال کند.

^۴Extended Kalman Filter – EKF

^۵Generalizability

^۶Out-of-Distribution – OOD

^۷Mamba

^۸Transformer

^۹Time series

۳-۱-۳ روش‌های ترکیبی

در روش‌های ترکیبی، تلاش می‌شود با ترکیب دانش فیزیکی و مدل‌های بر پایه مدل، یا با ترکیب ساختارهای مختلف یادگیری عمیق، توازن میان صحت تخمین و قابلیت پیاده‌سازی برخط در معماری سامانه مدیریت باتری برقرار شود.

در پژوهش [۲۶]، یک حسگر مجازی دما بر پایه معماری CNN-LSTM ارائه شده است که دمای سطحی باتری را به صورت برخط تخمین می‌زند. در این پژوهش گزارش شده است که مقدار RMSE در شرایط دمای محیط ثابت کمتر از ۱/۲۴ درجه سلسیوس و در شرایط دمای محیط متغیر کمتر از ۱/۳۰ درجه سلسیوس است.

در پژوهش [۵۲]، معماری CNN-BiLSTM-Attention برای پیش‌بینی میدان دمایی باتری پیشنهاد شده است. نتایج عددی نشان می‌دهد که این مدل با بهره‌گیری از مکانیزم توجه^{۱۰} به دقت بسیار بالای RMSE معادل ۰/۲۸۷۱ و ضریب تبیین^{۱۱} معادل $R^2 = ۰/۹۹۹۴$ دست یافته است. با این حال، تحلیل‌های انجام‌شده در این پژوهش نشان می‌دهد که سربار محاسباتی ناشی از پیچیدگی لایه‌های توجه، پیاده‌سازی این دسته از مدل‌ها را بر سامانه‌های نهفته با منابع محدود با چالش مواجه می‌کند.

در پژوهش [۵۳]، یک رویکرد تحلیلی عددی بر پایه معادله‌های حرارت و تخمین بر پایه داده ارائه شده است. نتایج نشان می‌دهند که مقدار RMSE بین دمای تخمینی و واقعی حداکثر حدود ۰/۲۳ است. برتری اصلی این روش از منظر معماری، کارایی محاسباتی آن است؛ به‌طوری‌که گزارش شده است سرعت اجرای این الگوریتم حدود ۳۵۰ برابر بیشتر از روش‌های سنتی بر پایه اجزای محدود FEM^{۱۲} است.

در پژوهش‌های اخیر نظیر [۵۴]، از شبکه‌های عصبی آگاه از فیزیک^{۱۳} استفاده شده است که در آن معادله‌های دیفرانسیل حرارتی به عنوان قید در تابع هزینه لحاظ می‌شوند. این کار وابستگی مدل به حجم عظیم داده‌های برچسب‌خورده را کاهش می‌دهد. همچنین در پژوهش [۵۵]، مدل سبک‌وزن-KAN Therm با هدف کاهش چشم‌گیر تعداد مشخصه‌های قابل آموزش ارائه شده است.

¹⁰Attention Mechanism

¹¹Coefficient of Determination – R^2

¹²Finite Element Method – FEM

¹³Physics-Informed Neural Networks – PINN

۲-۳ مرور پژوهش‌های پیشین در تشخیص اشکال حسگر و تحمل‌پذیری در سامانه مدیریت باتری

یکی از چالش‌های کلیدی در معماری سامانه مدیریت باتری، بروز اشکال در حسگرهای ولتاژ، جریان و دما و اثر آن بر برآورد حالت و تصمیم‌سازی کنترلی است [۵۶، ۵۷]. وقوع اشکال در حسگر می‌تواند منجر به برآورد نادرست مشخصه‌های حالت و افزایش احتمال ورود سامانه به وضعیت ناایمن گردد. بر همین اساس، این بخش پژوهش‌های مرتبط با تشخیص، تحمل‌پذیری و تزریق اشکال را مرور می‌کند.

۱-۲-۳ رویکردهای تشخیص اشکال حسگر

بر اساس پژوهش‌های موجود، روش‌های تشخیص اشکال حسگر عمدتاً در سه دسته بر پایه مدل، بر پایه داده و بدون نظارت طبقه‌بندی می‌شوند. پژوهش‌های [۵۶، ۵۷] نشان می‌دهند که اشکال‌هایی مانند انحراف^{۱۴}، رانش^{۱۵}، نوفه شدید و قطع کامل علائم از سناریوهای بحرانی هستند.

روش‌های بر پایه مدل

در پژوهش [۵۶]، چارچوب‌های تشخیص و کنترل تحمل‌پذیر بررسی شده‌اند. در این پژوهش با استناد به مدل‌های پیشین، فرایند تشخیص اشکال در پنج مرحله کلیدی: تشخیص اولیه، تولید باقیمانده^{۱۶}، ارزیابی دقیق باقیمانده، تعیین آستانه و جداسازی اشکال^{۱۷} دسته‌بندی شده است. اگرچه رویکردهای بر پایه مدل تفسیرپذیری بالایی دارند، اما در شرایط عملیاتی واقعی به دلیل عدم قطعیت در مشخصه‌ها، نرخ هشدار کاذب^{۱۸} در آن‌ها افزایش می‌یابد.

در پژوهش [۵۸]، یک روش بر پایه علائم و بر پایه تجزیه و تحلیل حالت متغیر ارائه شده است که با نمونه‌برداری فرکانس پایین (۰/۱ هرتز) و رزولوشن ۱ میلی‌ولت، مؤلفه‌های ولتاژ مرتبط با پاسخ‌های محلی و تغییرهای بلندمدت را از هم تفکیک می‌کند.

¹⁴Bias

¹⁵Drift

¹⁶Residual Generation

¹⁷Isolation

¹⁸False Alarm

روش‌های بر پایه داده نظارت شده

در پژوهش [۵۹]، یک مدل پیشرفته تحت عنوان شبکه باقی‌مانده^{۱۹} عمیق بهینه‌شده با الگوریتم خفاش^{۲۰} (IB-DRN) برای تشخیص اشکال حسگر ارائه شده است. در این مطالعه، عملکرد مدل پیشنهادی در مقایسه با روش‌های کلاسیک نظیر ماشین بردار پشتیبان (SVM)^{۲۱} و شبکه عصبی مصنوعی (ANN)^{۲۲} سنجیده شده و دقت بالاتری در طبقه‌بندی انواع اشکال‌های حسگر گزارش شده است.

در پژوهش [۳۸]، بر طراحی راهبردهای آموزش مقاوم تأکید شده است تا حساسیت مدل‌های عمیق نسبت به داده‌های معیوب کاهش یابد. این ایده از منظر معماری سامانه مدیریت باتری به عنوان یک لایه حفاظتی در لبه (Edge) مطرح است که از انتشار اشکال حسگر به سطوح بالاتر تصمیم‌گیری جلوگیری می‌کند.

روش‌های بدون نظارت و تشخیص ناهنجاری

در پژوهش [۲۹]، چهار نوع خودرمزگذار^{۲۳} شامل مدل‌های تمام‌متصل^{۲۴}، CNN، LSTM و ترکیبی CNN-LSTM برای تشخیص ناهماهنگی سلول‌ها مقایسه شده‌اند. نتایج نشان می‌دهد که مدل تمام‌متصل در شرایط ناهنجار بهترین عملکرد بازسازی را دارد، اما مدل LSTM بیشترین توانایی را در تمایز میان سلول‌های سالم و معیوب داراست.

در پژوهش [۶۰]، یک چارچوب بدون نظارت بر پایه خودرمزگذار پرسپترون چندلایه (MLP)^{۲۵} برای تشخیص ناهنجاری ارائه شده است که به مقدار سطح زیر منحنی (AUC)^{۲۶} معادل ۹۹/۱۱٪ دست یافته است. این نتیجه نشان‌دهنده برتری مطلق روش‌های خودرمزگذار عمیق نسبت به روش‌های سنتی نظیر ماشین بردار پشتیبان تک‌کلاسه (OC-SVM) در شناسایی الگوهای ناشناخته خطا است.

¹⁹Residual Network

²⁰Bat Algorithm

²¹Support Vector Machine – SVM

²²Artificial Neural Network – ANN

²³Autoencoder – AE

²⁴Fully Connected – FC

²⁵Multi-Layer Perceptron – MLP

²⁶Area Under the Curve – AUC

۳-۲-۲ راهبردهای تحمل‌پذیری: کنترل و حسگرهای مجازی

در کنترل تحمل‌پذیر (FTC)^{۲۷}، هدف حفظ عملکرد سامانه حتی در حضور حسگر دارای اشکال است. در پژوهش [۶۱]، یک الگوریتم رأی‌گیری بر پایه بیشینه احتمال (MLV)^{۲۸} معرفی شده است که با ترکیب داده‌های حسگر فیزیکی و دو حسگر مجازی (بر پایه EKF و ناظر تطبیقی^{۲۹})، پایداری گشتاور و سرعت موتور را در صورت خرابی انکودر تضمین می‌کند.

حسگرهای مجازی در معماری سامانه مدیریت باتری، مسیرهای جبرانی حیاتی محسوب می‌شوند. در پژوهش [۲۵]، با استفاده از رگرسیون بردار پشتیبان (SVR)^{۳۰} و تحلیل مؤلفه‌های اصلی (PCA)^{۳۱}، یک حسگر مجازی برای تخمین حالت شارژ (SOC)^{۳۲} بدون نیاز به حسگر جریان طراحی شده است. همچنین در پژوهش [۲۱]، مفهوم «حسگرهای تقریب سایبری» مطرح شده است که با بهره‌گیری از وابستگی‌های اطلاعاتی میان سنسورهای موجود، شاخص عملکردی را بهبود بخشیده و هم‌زمان سربار سخت‌افزاری را کاهش داده است.

۳-۲-۳ تزریق اشکال و آموزش مقاوم

تزریق اشکال ابزاری استاندارد برای اعتبارسنجی قابلیت اطمینان است. در پژوهش [۲۱]، از تزریق اشکال در بستر سخت‌افزار در حلقه^{۳۳} برای ارزیابی تحمل‌پذیری مدل‌ها استفاده شده است. این مطالعه تأکید می‌کند که استفاده از قطعات محاسباتی تجاری^{۳۴} می‌تواند راهکاری مقرون‌به‌صرفه برای پیاده‌سازی این راهبردهای مقاوم باشد.

در پژوهش‌های بر پایه داده نظیر [۵۹]، تزریق عمدی نوفه و اشکال‌های انحراف در فاز آموزش، منجر به افزایش مقاومت مدل در برابر داده‌های ناسالم در زمان اجرا شده است. این رویکرد، پایداری تصمیم‌گیری سامانه مدیریت باتری را در سناریوهای بحرانی که حسگر دچار انحراف تدریجی می‌شود، به‌طور قابل توجهی بهبود می‌بخشد.

^{۲۷}Fault-Tolerant Control – FTC

^{۲۸}Maximum Likelihood Voting – MLV

^{۲۹}Adaptive Observer

^{۳۰}Support Vector Regression – SVR

^{۳۱}Principal Component Analysis – PCA

^{۳۲}State of Charge – SOC

^{۳۳}Hardware-in-the-Loop – HIL

^{۳۴}Commercial Off-the-Shelf – COTS

۳-۳ مرور کاربردهای مکمل در معماری سامانه مدیریت باتری

علاوه بر پژوهش‌های پیش‌بینی دما و مدیریت اشکال حسگر، بخشی از ادبیات مرتبط با معماری سامانه مدیریت باتری به دو پایه مکمل پرداخته است: (۱) پیش‌بینی برد رانندگی به‌عنوان یک پیمایش سطح سامانه، و (۲) ارزیابی اقتصادی و عملکردی حسگرهای مجازی به‌عنوان یک ملاحظه معماری در توازن میان هزینه سخت‌افزار و سربار محاسباتی. اگرچه این دو پایه مستقیماً هسته مدل پیشنهادی این رساله را تشکیل نمی‌دهند، اما از منظر معماری سامانه خودرو و اثرگذاری بر منابع سخت‌افزاری، ارتباط نزدیکی با بحث حسگر مجازی و تحمل‌پذیری دارند.

۱-۳-۳ پیش‌بینی برد رانندگی

پژوهش‌های این بخش با استفاده از خروجی‌های سامانه مدیریت باتری و داده‌های محیطی، راهبردهای مدیریت انرژی را پشتیبانی می‌کنند. دقت این پیمایش به‌شدت به کیفیت داده‌های حسگری و توان پردازشی وابسته است.

در پژوهش [۶۲]، یک مدل یادگیری ماشین ترکیبی برای پیش‌بینی برد باقی‌مانده (RDR)^{۳۵} بر اساس داده‌های تاریخی واقعی رانندگی ارائه شده است. این روش با بهره‌گیری از الگوهای بر پایه داده، دقت بالایی در سناریوهای متنوع رانندگی نشان می‌دهد. با این حال، از منظر معماری سامانه مدیریت باتری، وابستگی به داده‌های حجیم و نیاز به به‌روزرسانی برخط مدل، سربار محاسباتی قابل‌توجهی ایجاد می‌کند.

در پژوهش [۶۳]، از ترکیب پالایه ذرات^{۳۶} و زنجیره مارکوف^{۳۷} برای مدل‌سازی عدم قطعیت در پیش‌بینی برد استفاده شده است. در این رویکرد، برد باقی‌مانده به‌صورت یک توزیع احتمال نمایش داده می‌شود. این مطالعه نشان می‌دهد که اگرچه مدل‌سازی احتمالی منجر به کاهش اضطراب برد^{۳۸} در راننده می‌شود، اما تنظیم منابع برای حفظ توازن میان دقت و حافظه، یک محدودیت کلیدی است.

در پژوهش [۶۴]، یک تخمین‌گر دینامیک خودرو بر پایه ترکیب شبکه LSTM و پالایه کالمن تطبیقی (AKF)^{۳۹} معرفی شده است که وظیفه مشاهده سرعت طولی^{۴۰} و زاویه لغزش^{۴۱} را بر عهده دارد. از منظر معماری خودرو، خروجی دقیق این مدل برآورد مصرف انرژی را بهبود بخشیده، هرچند اجرای هم‌زمان آن‌ها

^{۳۵}Remaining Driving Range – RDR

^{۳۶}Particle Filter

^{۳۷}Markov Chain

^{۳۸}Range Anxiety

^{۳۹}Adaptive Kalman Filter – AKF

^{۴۰}Longitudinal Velocity

^{۴۱}Sideslip Angle

نیازمند منابع محاسباتی فراتر از میکروکنترلرهای ارزان قیمت است.

۳-۲ ارزیابی اقتصادی و عملکردی حسگرهای مجازی در سامانه مدیریت باتری

حسگرهای مجازی از منظر اقتصادی اهمیت ویژه‌ای دارند؛ زیرا کاهش تعداد حسگرهای فیزیکی منجر به کاهش هزینه، پیچیدگی سیم‌کشی و نرخ خرابی سخت‌افزاری می‌شود.

در پژوهش [۵۷]، تأکید شده است که حذف هر حسگر فیزیکی و جایگزینی آن با الگوریتم‌های نرم‌افزاری، اگرچه هزینه سخت‌افزار را کاهش می‌دهد، اما موفقیت آن در سامانه‌های بحرانی-ایمن مستلزم تضمین قابلیت اطمینان است. این پژوهش شکاف موجود میان دقت آزمایشگاهی و استقرار عملی روی سخت‌افزار محدود را برجسته می‌کند.

در پژوهش [۲۵]، یک حسگر مجازی بر پایه SVR و PCA طراحی شده است که امکان تخمین حالت شارژ را بدون نیاز به حسگر جریان فراهم می‌کند. از دیدگاه معماری، این رویکرد افزونگی نرم‌افزاری مؤثری ایجاد می‌کند که در صورت خرابی حسگر فیزیکی، از توقف کل سامانه جلوگیری می‌نماید.

در پژوهش [۲۱]، مفهوم افزونگی سایبری^{۴۲} به عنوان جایگزینی برای افزونگی فیزیکی گران قیمت مطرح شده است. نتایج نشان می‌دهد که با استفاده از مدل‌های بر پایه تقریب سبک، شاخص قابلیت اجرای سامانه حدود ۶ درصد بهبود یافته و هم‌زمان سربار سخت‌افزاری نسبت به روش‌های سنتی به نصف کاهش یافته است.

در نهایت، پژوهش [۱۹] خاطرنشان می‌کند که در باتری‌های ولتاژ بالا با تعداد سلول‌های زیاد، افزایش حسگرهای فیزیکی به دلیل پیچیدگی نصب و احتمال خرابی، خود به یک عامل کاهنده ایمنی تبدیل می‌شود؛ از این رو، معماری‌های بر پایه داده و حسگرهای مجازی به عنوان راهکاری برای افزایش تحمل‌پذیری در برابر اشکال و بهینه‌سازی هزینه معرفی شده‌اند.

۳-۴ شکاف‌های پژوهشی و جایگاه پژوهش حاضر

مرور کارهای پیشین نشان می‌دهد که بخش عمده پژوهش‌های انجام‌شده در حوزه تخمین دمای باتری، عمدتاً بر بهبود دقت مدل در شرایط داده سالم و ایده‌آل تمرکز داشته‌اند. در مقابل، مطالعات مرتبط با تشخیص اشکال حسگر و افزایش تحمل‌پذیری سامانه‌ها غالباً به صورت مجزا و با تمرکز یا بر تشخیص اشکال و یا بر جبران آن‌ها انجام شده‌اند و کمتر به یکپارچه‌سازی این دو جنبه توجه شده است.

⁴²Cyber Redundancy

جدول ۳-۱: خلاصه‌ی کارهای پیشین (مشخصه‌های در نظر گرفته‌شده با ✓ نشان داده شده‌اند)

پژوهش	پشتیبانی از حسگرها			رویکرد			سربار سخت‌افزاری			قابلیت اطمینان	تزریق اشکال	تحمل‌پذیری اشکال
	دما	ولتاژ	جریان	بر پایه داده	بر پایه مدل	ترکیبی	پایین	متوسط	بالا			
[۷]	✓	✓	✓		✓		✓					
[۸]	✓	✓	✓		✓		✓					
[۶۳]	✓	✓	✓		✓			✓				
[۶۱]	—			✓		✓			✓			✓
[۶۲]	✓	✓	✓	✓				✓				
[۵۱]	✓	✓	✓	✓	✓		✓					
[۵۸]	✓	✓	✓	✓	✓		✓					
[۵۰]	✓	✓	✓	✓	✓			✓				
[۵۹]	✓	✓	✓	✓				✓			✓	
[۶۵]	✓			✓		✓			✓			
[۶۶]	✓	✓	✓	✓				✓			✓	
[۵۶]	✓	✓	✓	✓	✓	✓	—			✓		✓
[۲۱]	✓	✓	✓	✓	✓	✓		✓		✓		✓
[۲۶]	✓			✓		✓		✓				
[۶۷]	✓			✓				✓				
[۳۰]	✓			✓				✓				
[۵۳]	✓	✓	✓	✓	✓	✓		✓				
[۳۸]	—			✓	✓	✓	✓		✓			✓
[۵۲]	✓					✓			✓			
[۵۴]	✓			✓	✓	✓		✓				
[۵۵]	✓			✓		✓	✓					
راهکار پیشنهادی	✓				✓ (BiGRU)		✓			✓	✓	✓

جدول ۳-۱ خلاصه‌ای از پژوهش‌های پیشین را ارائه داده و جایگاه راهکار پیشنهادی این پژوهش را در مقایسه با آن‌ها نشان می‌دهد. همان‌گونه که از جدول قابل مشاهده است، بیشتر پژوهش‌ها یا بر مدل‌های بر پایه فیزیک و یا بر رویکردهای بر پایه داده متمرکز بوده‌اند و در عین حال، توجه محدودی به موضوعاتی نظیر تحمل‌پذیری هم‌زمان در برابر اشکال حسگرهای ورودی، استفاده از تزریق اشکال به‌عنوان ابزار مقاوم‌سازی مدل، و حفظ سربار محاسباتی پایین داشته‌اند.

پژوهش حاضر با تمرکز بر طراحی و توسعه یک حسگر مجازی که نسبت به اشکال تحمل‌پذیر است، تلاش می‌کند این شکاف‌های پژوهشی را به‌صورت یکپارچه پوشش دهد. نوآوری اصلی این پژوهش نه‌تنها در ارائه یک مدل پیش‌بینی دقیق، بلکه در انتخاب آگاهانه متغیرهای ورودی و ارزیابی و مقاوم‌سازی مدل تحت خطوط داستانی کنترل‌شده اشکال حسگر نهفته است. به‌طور مشخص، در این پژوهش به‌جای استفاده مستقیم از دمای مطلق باتری، از اختلاف دمای باتری و دمای محیط به‌عنوان یکی از ورودی‌های کلیدی مدل بهره گرفته شده است. این انتخاب مبتنی بر این است که توان تلف‌شده ناشی از ولتاژ و جریان اعمال‌شده، به‌صورت مستقیم با افزایش دمای نسبی باتری نسبت به محیط پیرامون آن مرتبط است، در حالی که دمای مطلق باتری خود تحت تأثیر هم‌زمان شرایط محیطی و فرایندهای داخلی تولید حرارت قرار دارد. بدین ترتیب، استفاده از این اختلاف دمایی امکان استخراج مشخصه‌های معنادارتر و مرتبط‌تر با رفتار

الکتروحرارتی باتری را فراهم می‌سازد.

علاوه بر این، بررسی کارهای پیشین نشان می‌دهد که بخش قابل‌توجهی از پژوهش‌های انجام‌شده در این حوزه، به‌ویژه آن‌هایی که رویکردی مشابه با مسئله حاضر داشته‌اند، از مجموعه داده‌های واقعی و چندحسگری استفاده نکرده‌اند و عمدتاً به داده‌های شبیه‌سازی‌شده یا آزمایشگاهی محدود اکتفا کرده‌اند. همچنین، ارزیابی این روش‌ها غالباً بر روی خطوط داستانی محدود و ساده‌شده انجام شده است که این امر می‌تواند منجر به برآورد خوش‌بینانه از دقت و عملکرد مدل‌ها شود و رفتار آن‌ها را در شرایط عملی و ناهمگون به‌طور کامل منعکس نکند.

در این راستا، رویکرد پیشنهادی با بهره‌گیری از تزریق اشکال هدفمند به‌عنوان بخشی از فرایند طراحی، آموزش و اعتبارسنجی، امکان سنجش واقع‌گرایانه میزان تحمل‌پذیری مدل را فراهم می‌سازد. خروجی این فرایند، یک حسگر مجازی است که علاوه بر حفظ دقت مناسب در شرایط سالم، در مواجهه با شرایط ناهمگون و اشکال ورودی نیز قادر به تولید علائم دمایی قابل اتکا است. این ویژگی به‌طور مستقیم به ارتقای ایمنی عملکردی سامانه مدیریت باتری کمک کرده و با در نظر گرفتن تحلیل سربار محاسباتی، جایگاه این پژوهش را در گذار از مطالعات آزمایشگاهی به کاربردهای عملی تقویت می‌نماید.

فصل ۴

روش پیشنهادی

در فصل‌های پیشین، اهمیت تخمین وضعیت حرارتی باتری و چالش‌های ناشی از خرابی حسگرها در سامانه مدیریت باتری مورد بحث قرار گرفت. روش‌های متداول بر پایه مدل‌های الکتروشیمیایی یا مدارهای معادل، اگرچه از نظر فیزیکی قابل تفسیر هستند، اما وابستگی شدید آن‌ها به مشخصه‌های دقیق مدل و حساسیت بالا نسبت به نوفه علائم ورودی، کاربرد آن‌ها را در شرایط واقعی محدود می‌سازد. در مقابل، رویکرد پیشنهادی در این پژوهش، توسعه یک حسگر مجازی مقاوم بر پایه یادگیری عمیق است.


همانطور که در شکل ۴-۱ مشاهده می‌کنید، چارچوب کلی این پژوهش شامل یک خط‌لوله^۱ پردازشی شش مرحله‌ای است: (۱) آماده‌سازی و همگام‌سازی داده‌ها، (۲) مدل‌سازی ریاضی و تزریق اشکال حسگری، (۳) آموزش مدل پایه، (۴) تنظیم دقیق مقاوم، (۵) ارزیابی آماری خطا و (۶) تحلیل قابلیت اجرا و انطباق با استاندارد ایمنی.

در ادامه این فصل، جزئیات دقیق ریاضی و پیاده‌سازی هر یک از این مرحله‌ها تشریح می‌گردد. تمرکز اصلی بر طراحی معماری شبکه‌ای است که بتواند حتی در صورت از دست رفتن یا دارای اشکال شدن بخشی از اطلاعات ورودی، تخمینی پایدار و ایمن ارائه دهد.

۴-۱ پیش‌پردازش و آماده‌سازی داده‌ها

کیفیت مدل‌های بر پایه داده وابستگی مستقیمی به نحوه نمایش داده‌ها و کیفیت بردار ویژگی‌های ورودی دارد. داده‌های خام جمع‌آوری شده از خودروهای الکتریکی معمولاً دارای نوفه، مقادیر گم‌شده و تفاوت در

¹Pipeline



شکل ۴-۱: نمای کلی چارچوب پیشنهادی؛ شامل مراحل آماده‌سازی داده، تزریق اشکالی کنترل‌شده و آموزش دو مرحله‌ای مدل.

مقیاس اندازه‌گیری هستند. در این بخش، فرایند تبدیل علائم خام به تانسورهای^۲ استاندارد جهت تغذیه به شبکه عصبی تشریح می‌شود.

۴-۱-۱ توصیف ریاضی مشخصه‌ها

داده‌های مورد استفاده در این پژوهش شامل سری‌های زمانی ولتاژ (V)، جریان (I)، توان الکتریکی (P) و دمای محیط (T_{amb}) است. وضعیت باتری در هر لحظه زمانی t را می‌توان با بردار ویژگی ورودی $\mathbf{x}_t \in \mathbb{R}^4$ نمایش داد:

$$\mathbf{x}_t = \begin{bmatrix} V_t \\ I_t \\ P_t \\ T_{amb,t} \end{bmatrix} \quad (4-1)$$

هدف نهایی مدل، تخمین دمای سطح سلول باتری (T_{bat}) است. همچنین، به منظور اعمال قانون‌های فیزیک و کمک به همگرایی بهتر مدل، مشخصه کمکی اختلاف دما (ΔT) نیز به عنوان هدف دوم در نظر گرفته شده است:

$$\Delta T_t = T_{bat,t} - T_{amb,t} \quad (4-2)$$

بنابراین، بردار هدف در لحظه t به صورت $\mathbf{y}_t = [T_{bat,t}, \Delta T_t]^T$ تعریف می‌شود.

²Tensors

۴-۱-۲ نرمال سازی آماری

یکی از چالش های اصلی در آموزش شبکه های عصبی و استفاده از داده های باتری، تفاوت فاحش در مرتبه بزرگی^۳ علائم است. برای مثال، ولتاژ بسته باتری ممکن است در محدوده ۳۰۰ تا ۴۰۰ ولت تغییر کند، در حالی که جریان بین ۱۰۰- تا ۱۰۰+ آمپر نوسان دارد. همان طور که در شکل ۴-۲ مشاهده می شود، توزیع داده های خام دارای پراکندگی بسیار متفاوتی است. این عدم توازن باعث ناپایداری گرادیان ها و کندی همگرایی مدل می شود؛ لذا برای رفع این مشکل از نرمال سازی آماری^۴ استفاده می شود.

در این پژوهش، برای ویژگی های ورودی از روش استاندارد سازی Z-Score Normalization استفاده شده است تا توزیع داده ها دارای میانگین صفر و واریانس واحد شود. مقدار نرمال شده $x'_{i,t}$ برای ویژگی i -ام در لحظه t به صورت زیر محاسبه می شود:

$$x'_{i,t} = \frac{x_{i,t} - \mu_i}{\sigma_i} \quad (۳-۴)$$

که در آن μ_i و σ_i به ترتیب میانگین و انحراف معیار کل داده های آموزشی برای ویژگی i هستند. اما برای مشخصه های هدف، به ویژه دمای باتری، حفظ محدوده فیزیکی دارا اهمیت است. برای همین، از روش مقیاس دهی Min-Max استفاده شده است تا مقادیر خروجی همواره در بازه $[0, 1]$ قرار گیرند:

$$y'_{j,t} = \frac{y_{j,t} - y_{j,\min}}{y_{j,\max} - y_{j,\min}} \quad (۴-۴)$$

این کار تضمین می کند که خروجی شبکه عصبی پس از اعمال تابع فعال ساز نهایی، با محدوده های فیزیکی سازگار باشد.

۴-۱-۳ تولید دنباله های زمانی با پنجره لغزان


مدل های RNN و BiGRU برای یادگیری الگوها نیاز به دریافت توالی از داده ها دارند. بدین منظور از روش پنجره لغزان^۵ استفاده شده است. همان طور که در شکل ۴-۳ نمایش داده شده است، اگر طول پنجره برابر با L در نظر گرفته شود، ماتریس ورودی مدل $\mathbf{X}_k$ در گام زمانی k شامل دنباله ای از L بردار ویژگی گذشته خواهد بود:

$$\mathbf{X}_k = [\mathbf{x}'_{k-L+1}, \mathbf{x}'_{k-L+2}, \dots, \mathbf{x}'_k] \in \mathbb{R}^{L \times F} \quad (۵-۴)$$


³Order of Magnitude

⁴Statistical Normalization

⁵Sliding Window




(ب) بعد از نرمال سازی



(آ) قبل از نرمال سازی

شکل ۴-۲: تأثیر نرمال سازی بر توزیع آماری داده‌ها؛ (آ) داده‌های خام با مقیاس‌های متفاوت، (ب) داده‌های همگام سازی شده با میانگین صفر و واریانس واحد.



شکل ۴-۳: فرایند تولید نمونه‌های آموزشی با استفاده از پنجره لغزان با طول L ؛ ماتریس ورودی شامل تاریخچه مشخصه‌های الکتریکی و خروجی شامل دمای باتری در آینده است.

که در آن $F = 4$ تعداد ویژگی‌های ورودی است. متناظر با این ورودی، هدف مدل پیش‌بینی دما در گام‌های آینده است. در این پژوهش، رویکرد پیش‌بینی تک‌گام^۶ با افق دید h استفاده شده است، به طوری که بردار هدف y_{k+h} می‌باشد.

انتخاب طول پنجره L نقش حیاتی در عملکرد مدل دارد؛ پنجره‌های بسیار کوتاه قادر به ثبت دینامیک حرارتی کند باتری نیستند و پنجره‌های بسیار بلند موجب افزایش بار محاسباتی و تأخیر در پاسخ‌دهی می‌شوند. بر اساس آزمایش‌های اولیه و ثابت زمانی حرارتی باتری، مقدار L به گونه‌ای تنظیم شده است که حداقل ۶۰ ثانیه از تاریخچه اخیر را پوشش دهد.

^۶One-step Ahead

۲-۴ مدل سازی ریاضی و تزریق اشکال حسگری

همان طور که در فصل پیشین بحث شد، یکی از ارکان اصلی روش پیشنهادی، مقاوم سازی مدل در برابر اشکال های حسگری است. از آنجا که جمع آوری داده های واقعی از تمام سناریوهای خرابی ممکن در خودرو دشوار و پرهزینه است، در این پژوهش از رویکرد تزریق اشکال مدل سازی شده^۷ استفاده شده است. در این رویکرد، انواع اشکال های متداول حسگرها به صورت ریاضی فرمول بندی شده و بر روی داده های سالم اعمال می شوند.

اگر $x_i(t)$ مقدار واقعی و سالم علائم حسگر i در لحظه t باشد، مقدار اندازه گیری شده معیوب $\tilde{x}_i(t)$ را می توان به صورت زیر مدل کرد:

$$\tilde{x}_i(t) = f_{\text{fault}}(x_i(t), t, \theta) \quad (۴-۶)$$

که در آن f_{fault} تابع تزریق اشکال و θ بردار مشخصه های اشکال (نظیر شدت، زمان شروع و مدت) است. اشکال های در نظر گرفته شده در این پژوهش به دو دسته اصلی گذرا و دائمی تقسیم می شوند.

۱-۲-۴ اشکال های گذرا

اشکال های گذرا دارای ماهیت کوتاه مدت بوده و معمولاً ناشی از تداخل الکترومغناطیسی، نوفه محیطی یا اشکال لحظه ای در مبدل آنالوگ به دیجیتال هستند.

نوفه تصادفی

ساده ترین و رایج ترین نوع اشکال، اضافه شدن یک نوفه تصادفی^۸ به علائم است:

$$\tilde{x}(t) = x(t) + n(t), \quad n(t) \sim \mathcal{N}(0, \sigma_n^2) \quad (۴-۷)$$

که در آن $n(t)$ نوفه سفید گوسی با میانگین صفر و واریانس σ_n^2 است.

^۷Modeled Fault Injection

^۸Accidental Noise

داده‌های پرت لحظه‌ای

این اشکال به صورت تغییر ناگهانی و شدید در مقدار علائم برای یک یا چند لحظه کوتاه ظاهر می‌شود و با استفاده از تابع ضربه مدل‌سازی می‌گردد:

$$\tilde{x}(t) = x(t) + A \cdot \delta(t - t_{\text{spike}}) \quad (۸-۴)$$

که در آن A دامنه نوسان و t_{spike} زمان وقوع آن است.

۲-۲-۴ اشکال‌های دائمی

اشکال‌های دائمی اثر بلندمدت داشته و معمولاً ناشی از پیری حسگر و خرابی سخت‌افزاری هستند.

انحراف

در این حالت، یک مقدار ثابت به خروجی حسگر اضافه می‌شود:

$$\tilde{x}(t) = x(t) + b, \quad \forall t > t_{\text{start}} \quad (۹-۴)$$

که b مقدار انحراف و t_{start} زمان شروع اشکال است.

رانش

در این اشکال، مقدار اندازه‌گیری شده به مرور زمان از مقدار واقعی منحرف می‌شود. این اشکال اغلب با یک شیب خطی مدل‌سازی می‌شود:

$$\tilde{x}(t) = x(t) + m \cdot (t - t_{\text{start}}), \quad \forall t > t_{\text{start}} \quad (۱۰-۴)$$

که m شیب رانش است که شدت انحراف در واحد زمان را تعیین می‌کند.

چسبندگی

در این سناریو، خروجی حسگر در یک مقدار ثابت برای مثال آخرین مقدار خوانده شده یا مقدار حداکثر/حداقل، قفل می‌شود:

$$\tilde{x}(t) = C, \quad \forall t > t_{\text{start}} \quad (۱۱-۴)$$

تمامی اشکال‌های فوق با شدت‌ها و مدت‌زمان‌های مختلف بر روی حسگرهای ولتاژ، جریان و دما اعمال شده‌اند تا مجموعه داده‌ای جامع برای آموزش مقاوم مدل فراهم گردد.

۳-۴ معماری شبکه عصبی پیشنهادی

برای تخمین دمای باتری که دارای دینامیک کند و وابسته به تاریخچه عملکرد است، اگرچه شبکه‌های عصبی پیش‌خور (FNN)^۹ کاربرد دارند، اما معماری‌های RNN و به‌طور خاص BiGRU، به دلیل ماهیت ترتیبی داده‌ها، عملکرد مطلوب‌تری نسبت به مدل‌های پیش‌خور از خود نشان می‌دهند.

۱-۳-۴ واحد شبکه‌ی GRU

واحد GRU نوعی پیشرفته از RNN است که برای حل مشکل محو شدن گرادیان^{۱۰} در دنباله‌های طولانی طراحی شده است. GRU دارای دو دریچه اصلی است که جریان اطلاعات را کنترل می‌کنند:

- دریچه به‌روزرسانی (z_t , Update Gate): تعیین می‌کند چه مقدار از اطلاعات وضعیت مخفی قبلی (h_{t-1}) باید به وضعیت فعلی منتقل شود.
- دریچه بازنشانی (r_t , Reset Gate): تصمیم می‌گیرد چه مقدار از اطلاعات گذشته برای محاسبه وضعیت نامزد جدید ($\tilde{h}_t$) نادیده گرفته شود.

معادلات حاکم بر یک سلول GRU در گام زمانی t برای ورودی $\mathbf{x}_t$ به صورت زیر است:

$$z_t = \sigma_g(W_z \mathbf{x}_t + U_z h_{t-1} + b_z) \quad (۱۲-۴)$$

$$r_t = \sigma_g(W_r \mathbf{x}_t + U_r h_{t-1} + b_r) \quad (۱۳-۴)$$

$$\tilde{h}_t = \tanh(W_h \mathbf{x}_t + U_h(r_t \odot h_{t-1}) + b_h) \quad (۱۴-۴)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \quad (۱۵-۴)$$

که در آن σ_g تابع فعال‌ساز سیگموئید، $\odot$ ضرب المان‌به‌المان^{۱۱}، و W و U ماتریس‌های وزن قابل یادگیری هستند.

^۹Feedforward Neural Network – FNN

^{۱۰}Vanishing Gradient

^{۱۱}Hadamard

۲-۳-۴ شبکه BiGRU و ساختار کلی مدل

از آنجا که رفتار حرارتی باتری نه تنها به گذشته، بلکه به روند کلی تغییرات علائم وابسته است، در این پژوهش از ساختار دوطرفه BiGRU استفاده شده است. یک لایه BiGRU شامل دو لایه GRU موازی است؛ یکی دنباله ورودی را در جهت مستقیم (از $t = 1$ به L) و دیگری در جهت معکوس پردازش می‌کند. خروجی نهایی از متصل شدن وضعیت‌های مخفی این دو لایه حاصل می‌شود:

$$H_t = [\vec{h}_t \oplus \overleftarrow{h}_t] \quad (۱۶-۴)$$

معماری نهایی مدل پیشنهادی که جزئیات لایه‌های آن در بلوک میانی شکل ۴-۱ ترسیم شده است، شامل دو لایه BiGRU متوالی می‌باشد تا ویژگی‌های زمانی انتزاعی‌تر را استخراج کند. پس از هر لایه بازگشتی، یک لایه حذف تصادفی^{۱۲} برای جلوگیری از بیش‌برازش قرار داده شده است. در نهایت، آخرین وضعیت مخفی شبکه به یک لایه تمام‌متصل^{۱۳} داده می‌شود تا دو خروجی نهایی، دمای باتری و اختلاف دما را تولید کند.

۴-۴ راهبرد آموزش دو مرحله‌ای و تابع هزینه

آموزش مستقیم یک شبکه عصبی عمیق با داده‌های دارای اشکال‌های شدید، می‌تواند منجر به همگرایی ضعیف یا یادگیری الگوهای نادرست شود. برای غلبه بر این چالش، در این پژوهش از یک راهبرد آموزش دو مرحله‌ای استفاده شده است: (۱) آموزش پایه^{۱۴} با داده‌های سالم و (۲) تنظیم دقیق مقاوم با ترکیبی از داده‌های سالم و دارای اشکال.

۱-۴-۴ آموزش پایه با داده‌های سالم:

هدف این مرحله، یادگیری دینامیک اصلی و روابط فیزیکی حاکم بر رفتار حرارتی باتری در شرایط ایده‌آل است. مدل BiGRU با استفاده از مجموعه داده‌های پیش‌پردازش شده سالم (D_{clean}) آموزش داده می‌شود. در این مرحله، مشخصه‌های شبکه (Θ) به گونه‌ای به‌روزرسانی می‌شوند که تابع هزینه بر روی داده‌های سالم کمینه گردد. مدل حاصل از این مرحله، $\mathcal{M}_{base}$ نامیده می‌شود که دارای دقت بالا در شرایط عادی، اما آسیب‌پذیر در برابر اشکال است. همان‌طور که در نمودار شکل ۴-۴ (آ) مشاهده می‌شود، تابع هزینه در این

¹²Dropout

¹³Dense

¹⁴Baseline Training

مرحله به سرعت کاهش یافته که نشان‌دهنده یادگیری مؤثر رفتار نامی باتری و همگرایی سریع مدل در غیاب اغتشاشات^{۱۵} است.

۲-۴-۴ تنظیم دقیق مقاوم

در این مرحله، مدل M_{base} به عنوان نقطه شروع استفاده شده و با بهره‌گیری از یک مجموعه داده ترکیبی تحت تنظیم دقیق قرار می‌گیرد. به منظور تضمین استحکام^{۱۶} مدل در مواجهه با شرایط عملیاتی واقعی، مجموعه داده ترکیبی ($D_{mixed} = D_{clean} \cup D_{faulty}$) با توزیع مهندسی شده‌ای طراحی گردید؛ به طوری که ۵۰ درصد از داده‌ها را نمونه‌های سالم، ۲۵ درصد را داده‌های دارای اشکال گذرا و ۲۵ درصد باقی‌مانده را اشکال‌های دائمی تشکیل می‌دهند. مزیت این رویکرد ترکیبی در آن است که مدل را از یک سو ملزم به حفظ دقت بالا در شرایط نامی می‌کند و از سوی دیگر، آن را در معرض تنوع وسیعی از الگوهای خرابی قرار می‌دهد. این توازن مانع از سوگیری مدل به نفع یک سناریوی خاص شده و باعث می‌شود شبکه یاد بگیرد بدون فراموش کردن دینامیک اصلی، اثر اغتشاشات ورودی را خنثی کرده و تخمینی نزدیک به مقدار واقعی ارائه دهد.

برای جلوگیری از فراموشی فاجعه‌بار^{۱۷} دانش قبلی، نرخ یادگیری^{۱۸} در این مرحله بسیار کم‌تر از مرحله اول در نظر گرفته می‌شود. رفتار مدل در این مرحله در نمودار شکل ۴-۴ (ب) به تصویر کشیده شده است؛ همان‌گونه که پیداست، با وجود نوسان‌های جزئی ناشی از داده‌های دارای اشکال، فرایند آموزش پایداری خود را حفظ کرده و مدل به یک نقطه کار مستحکم همگرا شده است. این پایداری، نشان‌دهنده توانایی مدل در استخراج الگوهای صحیح حتی در حضور ۵۰ درصد داده دارای اشکال است.

۳-۴-۴ تابع هزینه مرکب با قانون‌های فیزیک

برای آموزش مدلی که هم دقیق باشد و هم از نظر فیزیکی سازگار، از یک تابع هزینه مرکب استفاده شده است. این تابع هزینه شامل دو بخش اصلی است: خطای پیش‌بینی و قید سازگاری فیزیکی [۶۸].

تابع هزینه اصلی، میانگین مربعات خطا (MSE)^{۱۹} برای هر دو خروجی شبکه، دمای باتری T_{bat} و اختلاف دما ΔT ، با هدف کاهش اختلاف بین مقادیر واقعی و پیش‌بینی شده به صورت زیر تعریف می‌شود [۶۸]:


¹⁵Disturbances

¹⁶Robustness


¹⁷Catastrophic Forgetting

¹⁸Learning Rate

¹⁹Mean Squared Error – MSE



(ب) تنظیم دقیق مقاوم



(آ) آموزش پایه

شکل ۴-۴: منحنی‌های همگرایی تابع هزینه در دو مرحله آموزش؛ (آ) کاهش سریع اشکال در آموزش پایه با داده سالم، (ب) تنظیم دقیق پایدار با نرخ یادگیری پایین بر روی داده‌های ترکیبی.

$$\mathcal{L}_{total} = \frac{1}{N} \sum_{i=1}^N \left[(T_{bat,i} - \hat{T}_{bat,i})^2 + (\Delta T_i - \hat{\Delta T}_i)^2 \right] \quad (17-4)$$

که در آن N تعداد نمونه‌ها، $T_{bat,i}$ و ΔT_i مقادیر واقعی، و $\hat{T}_{bat,i}$ و $\hat{\Delta T}_i$ مقادیر پیش‌بینی شده توسط مدل هستند.

$$\mathcal{L}_{MSE} = \frac{1}{N} \sum_{k=1}^N \left[(y_{T,k} - \hat{y}_{T,k})^2 + (y_{\Delta T,k} - \hat{y}_{\Delta T,k})^2 \right] \quad (18-4)$$

که در آن y مقادیر واقعی و $\hat{y}$ مقادیر پیش‌بینی شده توسط شبکه هستند.

همچنین، برای تضمین سازگاری میان خروجی‌های مدل و دمای محیط، طبق تعریف، باید رابطه $\Delta T = T_{bat} - T_{amb}$ همواره برقرار باشد. انحراف از این رابطه به عنوان یک جریمه^{۲۰} به تابع هزینه اضافه می‌شود:

$$\mathcal{L}_{phys} = \frac{1}{N} \sum_{k=1}^N |\hat{y}_{T,k} - (T_{amb,k} + \hat{y}_{\Delta T,k})|^2 \quad (19-4)$$

تابع هزینه نهایی کل ($\mathcal{L}_{total}$)، مجموع وزن‌دار^{۲۱} این دو مؤلفه است:

$$\mathcal{L}_{total} = \lambda_1 \mathcal{L}_{MSE} + \lambda_2 \mathcal{L}_{phys} \quad (20-4)$$

²⁰Penalty

²¹Weighted Sum

که λ_1 و λ_2 ضرایب تنظیم‌کننده‌ای هستند که اهمیت نسبی دقت پیش‌بینی و سازگاری فیزیکی را تعیین می‌کنند. حضور ترم L_{phys} مانند یک تنظیم‌گر^{۲۲} عمل کرده و مانع از ارائه پیش‌بینی‌های غیرممکن فیزیکی توسط مدل، به‌ویژه در هنگام مواجهه با ورودی‌های معیوب می‌شود.

به‌منظور تضمین تکرارپذیری پژوهش و شفاف‌سازی فرایند توسعه، در این بخش جزئیات اجرایی دو الگوریتم کلیدی پیشنهادی برای مدیریت هوشمند و مقاوم باتری تشریح می‌گردد. این الگوریتم‌ها زنجیره‌ی کامل تبدیل داده‌های خام به یک مدل تخمین‌گر مقاوم را پوشش می‌دهند.

تحلیل فرایند آماده‌سازی داده و تزریق اشکال

الگوریتم ۱ به توصیف مراحل پیش‌پردازش و ساخت سناریوهای دارای اشکال می‌پردازد. این الگوریتم از چهار گام اصلی تشکیل شده است:

- گام ۱؛ همگام‌سازی و پاک‌سازی: در این مرحله، با توجه به تفاوت احتمالی در نرخ نمونه‌برداری حسگرهای مختلف، داده‌ها برچسب زمانی یکسانی دریافت کرده و مقادیر مفقود ناشی از اشکال ارتباطی حذف می‌شوند. محاسبه مشخصه‌های آماری (μ و σ) در این مرحله، پایه‌ی محاسبات نرمال‌سازی در گام بعدی است.
- گام ۲؛ نرمال‌سازی ترکیبی: در این پژوهش از دو روش متفاوت برای نرمال‌سازی استفاده شده است. برای علائم ورودی الکتریکی که نوسان‌هاش شدیدی دارند، از روش Z-Score استفاده می‌شود تا میانگین داده‌ها بر صفر منطبق گردد. اما برای دمای خروجی، روش Min-Max به کار گرفته شده است تا مقادیر دقیقاً در بازه $[0, 1]$ محدود شوند؛ این امر پایداری تابع هزینه را در طول آموزش شبکه عصبی تضمین می‌کند.
- گام ۳؛ ساخت تانسورهای زمانی: مدل BiGRU نیازمند ورودی‌های سه‌بعدی است. در این گام، داده‌های پیوسته با استفاده از یک پنجره لغزان به طول L به قطعات زمانی تقسیم می‌شوند. هر پنجره شامل تاریخچه‌ای از رفتار الکتریکی باتری است که برای پیش‌بینی وضعیت حرارتی در افق h استفاده می‌شود.
- گام ۴؛ شبیه‌سازی شرایط بحرانی: این بخش با هدف ارزیابی قابلیت اطمینان طراحی شده است. ۵ نوع اشکال رایج حسگری که شامل نوفه، انحراف، رانش، چسبندگی و ضربه می‌شوند، بر اساس مدل‌های ریاضی تبیین شده، به علائم سالم تزریق می‌شوند. خروجی این گام، مجموعه‌داده دارای اشکال (D_{faulty}) است که برای آموزش مقاوم در فاز دوم استفاده خواهد شد.

²²Regularizer

الگوریتم ۱ آماده‌سازی تانسورهای زمانی و تولید سناریوهای اشکال

ورودی: داده‌های خام سری زمانی $\mathcal{D}_{raw}$ ، طول پنجره تاریخچه L ، افق پیش‌بینی h

خروجی: مجموعه داده‌های پنجره‌بندی شده $\mathcal{D}_{mixed}$ و $\mathcal{D}_{clean}$

۱: گام ۱: پاک‌سازی و همگام‌سازی (Data Cleaning):

۲: حذف ردیف‌های دارای مقدار گمشده (NaN) و همگام‌سازی فرکانس $\{V, I, P, T_{amb}, T_{bat}\}$

۳: محاسبه مشخصه‌های آماری: μ_i (میانگین) و σ_i (انحراف معیار) برای هر ویژگی i

۴: گام ۲: نرمال‌سازی ترکیبی (Hybrid Normalization):

۵: $x'_{i,t} = \frac{x_{i,t} - \mu_i}{\sigma_i}$ اعمال Z-Score برای ورودی‌های الکتریکی

۶: $y'_t = \frac{y_t - y_{min}}{y_{max} - y_{min}}$ اعمال مقیاس دهی Min-Max برای دمای هدف

۷: گام ۳: ساخت نمونه‌های نامی (Baseline Samples):

۸: $\mathbf{X}_k \in \mathbb{R}^{L \times 4}$ که در آن $\mathcal{D}_{clean} \leftarrow \bigcup \{(\mathbf{X}_k, y_{k+h})\}$

۹: ذخیره تانسورهای سالم برای مرحله اول آموزش

۱۰: گام ۴: تولید سناریوهای دارای اشکال (Faulty Scenarios):

۱۱: $\mathcal{D}_{faulty} \leftarrow \emptyset$

۱۲: به ازای هر علائم ورودی $f \in \{V, I, P, T_{amb}\}$:

۱۳: به ازای هر الگوی اشکال $Type \in \{Noise, Bias, Drift, Stuck, Spike\}$:

۱۴: تنظیم مشخصه شدت θ (مثلاً دامنه نوفه یا شیب رانش)

۱۵: $\tilde{\mathcal{X}}_f \leftarrow f_{fault}(\mathcal{X}_f, \theta)$ اعمال مدل‌های ریاضی بخش ۳-۴

۱۶: $\mathcal{D}_{windowed} \leftarrow$ قطعه‌بندی علائم دارای اشکال به پنجره‌های طول L

۱۷: $\mathcal{D}_{faulty} \leftarrow \mathcal{D}_{faulty} \cup \mathcal{D}_{windowed}$

۱۸: $\mathcal{D}_{mixed} \leftarrow \mathcal{D}_{clean} \cup \mathcal{D}_{faulty}$ ادغام برای آموزش مقاوم

۱۹: برگردان $\mathcal{D}_{clean}, \mathcal{D}_{mixed}$

تحلیل روش آموزش دومرحله‌ای با قانون‌های فیزیکی

الگوریتم ۲ معماری یادگیری مدل را ارائه می‌دهد که مبتنی بر مفهوم یادگیری انتقال^{۲۳} و تنظیم دقیق مدل است:

- مرحله ۱: یادگیری رفتار نامی: در این فاز، مدل ابتدا تنها با داده‌های سالم ($\mathcal{D}_{clean}$) آموزش می‌بیند. هدف از این مرحله، استخراج دینامیک حرارتی خالص باتری بدون سوگیری ناشی از اشکال‌ها است.

²³Transfer Learning

پس از همگرایی، وزن‌های به‌دست‌آمده تحت عنوان Θ_{base} ذخیره می‌شوند که حاوی دانش فیزیکی مدل از شرایط عادی است.

- **مرحله ۲؛ تنظیم دقیق مقاوم:** در این مرحله، مدل با چالش داده‌های دارای اشکال مواجه می‌شود:
 - **کنترل نرخ یادگیری:** برای جلوگیری از تخریب دانش پایه مدل در اثر مواجهه با اشکال‌های شدید، نرخ یادگیری (η_2) به میزان ۱۰ برابر نسبت به مرحله اول کاهش می‌یابد.
 - **خروجی چندوظیفه‌ای:** مدل هم‌زمان دمای باتری و اختلاف دما را پیش‌بینی می‌کند. این ساختار اجازه می‌دهد تا قانون‌های فیزیکی به صورت مستقیم در تابع هزینه اعمال شوند.
 - **قانون فیزیکی ($\mathcal{L}_{phys}$):** این نوآوری تضمین می‌کند که حتی در صورت دارای اشکال بودن ورودی‌ها، خروجی مدل از قوانین بقای انرژی و منطق حرارتی ($T_{bat} = T_{amb} + \Delta T$) تخطی نکند.
 - **تابع هزینه کل:** با ترکیب اشکال پیش‌بینی و اشکال نقض قانون فیزیکی ($\lambda_1 \mathcal{L}_{MSE} + \lambda_2 \mathcal{L}_{phys}$)، مدل یاد می‌گیرد که در حضور اشکال، به جای تکیه بر علائم دارای اشکال، به همبستگی‌های فیزیکی و منطق حاکم بر سامانه رجوع کند.
- در نهایت، مدلی که کمترین اشکال اعتبارسنجی را در طول این دو مرحله ثبت کرده باشد، به‌عنوان مدل نهایی $\mathcal{M}_{robust}$ در سامانه مدیریت باتری انتخاب می‌شود.

۵-۴ معیارهای ارزیابی و تحلیل پایداری یکپارچه سامانه

برای سنجش دقیق کارایی روش پیشنهادی، ارزیابی تنها بر مبنای معیارهای آماری سنتی کافی نیست؛ زیرا یک حسگر مجازی در محیط عملیاتی، بخشی از یک سامانه یکپارچه شامل زیرساخت‌های سخت‌افزاری و الگوریتم‌های نرم‌افزاری است. در این پژوهش، ارزیابی در دو سطح دقت آماری تعدیل‌شده و پایداری یکپارچه سامانه که شامل بخش‌های نرم‌افزاری و سخت‌افزاری می‌شود، انجام می‌شود.

الگوریتم ۲ الگوریتم آموزش دومرحله‌ای با قانون فیزیکی و تنظیم دقیق مقاوم

ورودی: مجموعه‌های $\mathcal{D}_{clean}$ و $\mathcal{D}_{mixed}$ ، نرخ‌های یادگیری η_1, η_2 ، ضرایب فیزیکی λ_1, λ_2

خروجی: مدل مطلوب شده نهایی $\mathcal{M}_{robust}$

- ۱: مرحله ۱: یادگیری رفتار نامی (Nominal Learning)
 - ۲: مقداردهی اولیه مشخصه‌های شبکه Θ (لایه‌های BiGRU و Dense)
 - ۳: تا وقتی تا زمان همگرایی ($\text{Epoch} \leq n_1$):
 - ۴: استخراج Batch تصادفی $(\mathbf{X}_B, \mathbf{y}_B)$ از $\mathcal{D}_{clean}$
 - ۵: $\hat{\mathbf{y}}_B \leftarrow \text{Forward}(\mathbf{X}_B; \Theta)$
 - ۶: $\mathcal{L}_{MSE} = \frac{1}{B} \sum (y_i - \hat{y}_i)^2$
 - ۷: $\Theta \leftarrow \Theta - \eta_1 \cdot \text{Optimizer}(\nabla_{\Theta} \mathcal{L}_{MSE})$
 - ۸: $\Theta_{base} \leftarrow \Theta$ ذخیره دانش پایه مدل
 - ۹: مرحله ۲: مقاوم‌سازی و تنظیم دقیق (Robust Fine-tuning)
 - ۱۰: بارگذاری وزن‌های پایه: $\Theta \leftarrow \Theta_{base}$
 - ۱۱: کاهش نرخ یادگیری جهت پایداری: $\eta_2 = \eta_1 \times 10^{-1}$
 - ۱۲: تا وقتی تا زمان بیش‌برازش ($\text{Epoch} \leq n_2$):
 - ۱۳: استخراج Batch ترکیبی $(\mathbf{X}_B, \mathbf{y}_B)$ از $\mathcal{D}_{mixed}$
 - ۱۴: $\hat{y}_T, \hat{y}_{\Delta T} \leftarrow \text{Forward}(\mathbf{X}_B; \Theta)$ خروجی چندوظیفه‌ای
 - ۱۵: $\mathcal{L}_{phys} = \text{mean}(|\hat{y}_T - (T_{amb} + \hat{y}_{\Delta T})|^2)$
 - ۱۶: $\mathcal{L}_{total} = \lambda_1 \mathcal{L}_{MSE} + \lambda_2 \mathcal{L}_{phys}$
 - ۱۷: $\Theta \leftarrow \Theta - \eta_2 \cdot \text{Optimizer}(\nabla_{\Theta} \mathcal{L}_{total})$
 - ۱۸: برگردان $\mathcal{M}_{robust}$ با کمترین اشکالی اعتبارسنجی
-

۴-۵-۱ معیارهای ارزیابی آماری

جهت سنجش دقت عمومی مدل و امکان مقایسه با سایر پژوهش‌ها، از معیارهای مرسوم آماری شامل MAE و RMSE استفاده می‌شود. این معیارها بیان‌گر توانایی کلی مدل در بازسازی الگوهای دمایی هستند:

$$MAE_{raw} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (21-4)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (22-4)$$

۴-۵-۲ تحلیل پایداری یکپارچه سامانه

در این بخش، سامانه پیشنهادی به صورت یک ساختار سری مدل سازی می شود؛ بدین معنا که تداوم عملکرد صحیح سامانه مستلزم سلامت و عملکرد بدون اشکال هم زمان در دو بخش اصلی است: بخش سخت افزار که شامل زیرساخت های پردازشی و بخش نرم افزار که شامل الگوریتم تخمین گر دمای باتری است.

نرخ شکست و عامل آسیب پذیری نرم افزار عملکرد الگوریتم هوش مصنوعی در هر لحظه بر اساس مقدار MAE، در یکی از سطح های عملیاتی تعیین می گردد. تعیین این آستانه ها در این پژوهش بر اساس الزامات ایمنی و مرزهای عملکردی تعریف شده در استاندارد ISO/PAS 8800 [۱۵] صورت گرفته است. این استاندارد به ایمنی سامانه های بر پایه هوش مصنوعی در خودرو اختصاص یافته است، بر تعیین محدوده های مجاز اشکال جهت تضمین ایمنی عملکردی تأکید دارد. بر این اساس، عامل آسیب پذیری به صورت زیر تعریف می شود:

$$\text{وضعیت سامانه} = \begin{cases} \text{عادی}^{۲۴} & MAE < 5^{\circ}C \\ \text{هشدار}^{۲۵} & 5^{\circ}C \leq MAE \leq 10^{\circ}C \\ \text{بحرانی}^{۲۶} & MAE > 10^{\circ}C \end{cases} \quad (۲۳-۴)$$

مدل ریاضی پایداری با نرخ خرابی چندسطحی مطابق با استانداردهای ایمنی عملکردی خودرو شامل ISO 26262 و ISO/PAS 8800 [۹، ۱۵]، نرخ خرابی هدف (λ) بر اساس شدت خطر هر وضعیت تعیین می گردد. برای ارزیابی پایداری در افق زمانی مأموریت (T)، دو سطح نرخ خرابی اعمال شده است:

- سطح هشدار^{۲۷}: با نرخ خرابی $\lambda = 10^{-7}$ ، جهت پایش وضعیت های غیرمطلوب.
- سطح بحرانی^{۲۸}: با نرخ خرابی $\lambda = 10^{-9}$ ، جهت تضمین ایمنی در شرایط حاد حرارتی.

جهت واسنجی افق زمانی مأموریت، بر اساس استاندارد SAE J1211 [۶۹] که مرجع معتبر طراحی و اعتبارسنجی تجهیزات الکترونیکی خودرو است، طول عمر مفید یک خودروی سواری معادل ۱۵ سال در نظر گرفته شده است. با فرض کارکرد روزانه، این مدت معادل با 2×10^4 ساعت عملیاتی برآورد می گردد. استفاده از این بازه زمانی استاندارد، نتایج پایداری را با واقعیت های صنعتی هم سو می سازد.

^{۲۷}ASIL-B

^{۲۸}ASIL-D

پایداری کل سامانه (P_{total}) بر اساس ساختار سری، از حاصل ضرب پایداری بخش نرم افزاری (P_{sw}) و قابلیت اطمینان سخت افزاری (P_{hw}) به دست می آید:

$$P_{total} = P_{sw} \cdot P_{hw} \quad (24-4)$$

$$P_{total} = P_{sw} \times P_{hw} = e^{-(VF+1) \cdot \lambda \cdot T} \quad (25-4)$$

شاخص های پایداری برای هر یک از سطوح فوق به شرح زیر محاسبه می گردند:

۱. پایداری نرم افزار (P_{sw}): نمایانگر احتمال تداوم عملکرد دقیق مدل هوش مصنوعی در مواجهه با اشکال های تزریق شده است:

$$P_{sw} = e^{-(VF \cdot \lambda \cdot T)} \quad (26-4)$$

۲. قابلیت اطمینان سخت افزار (P_{hw}): این مشخصه بیانگر پایداری ذاتی بخش های فیزیکی سامانه در سطح ایمنی مربوطه است:

$$P_{hw} = e^{-(\lambda \cdot T)} \quad (27-4)$$

۳. پایداری کل سامانه (P_{total}): بر اساس منطق پیوند سری، پایداری نهایی از حاصل ضرب احتمال دو بخش به دست می آید:

$$P_{total} = P_{sw} \times P_{hw} \quad (28-4)$$

در نهایت، سطح اطمینان پذیری نهایی سامانه با شاخص تعداد نه ها^{۲۹} گزارش می شود:

$$Nines = -\log_{10}(1 - P_{total}) \quad (29-4)$$

این رویکرد ترکیبی با استناد به استانداردهای به روز خودرویی، ارزیابی واقع بینانه ای از سامانه در برابر اشکال های فیزیکی و نرم افزاری ارائه می دهد.

²⁹Nines Analysis

فصل ۵

نتایج

در این فصل، ارزیابی جامع و همه‌جانبه‌ی راهکار پیشنهادی برای تخمین مقاوم دمای باتری ارائه می‌گردد. هدف بنیادین این بخش، تحلیل رفتار مدل پیشنهادی بر پایه شبکه عصبی BiGRU در مواجهه با طیف گسترده‌ای از شرایط غیرایده‌آل حسگری و سنجش میزان انطباق آن با استانداردهای سخت‌گیرانه‌ی ایمنی عملکردی خودرو، به‌ویژه استاندارد ISO 26262 [۹] است.

تخمین دمای باتری در خودروهای الکتریکی، یک وظیفه‌ی بحرانی-ایمن محسوب می‌شود؛ از این رو، ارزیابی مدل تنها بر اساس معیارهای رایج یادگیری ماشین برای تضمین پایداری سامانه در درازمدت کافی نخواهد بود. در این راستا، نتایج این پژوهش در دو سطح مورد بررسی قرار می‌گیرند:

- **دقت آماری و روند آموزش:** بررسی عملکرد مدل در دو مرحله‌ی آموزش نامی و تنظیم دقیق مقاوم جهت نمایش توانایی یادگیری دینامیک حرارتی و الگوهای خرابی.
- **قابلیت اطمینان مهندسی:** استفاده از مفاهیم قابلیت اجرا و شاخص نُه‌ها برای کمی‌سازی پایداری سامانه در یک افق عملیاتی ساعته تحت استانداردهای ASIL-B و ASIL-D.

در ادامه‌ی این فصل، ابتدا زیرساخت‌های پیاده‌سازی و جزئیات مجموعه‌داده‌های آزمون تشریح شده و سپس با ارائه‌ی جداول و نمودارهای تحلیلی، توانایی مدل در حفظ ایمنی سامانه مدیریت باتری حتی در صورت بروز خرابی‌های دائمی و گذرا در حسگرها اثبات می‌گردد.

۵-۱ تنظیمات آزمایشگاهی و زیرساخت سخت‌افزاری و نرم‌افزاری

با توجه به ماهیت سنگین پردازش‌های یادگیری عمیق بر روی حجم عظیم داده که شامل بیش از ۸ میلیون داده سری زمانی است و لزوم تکرارپذیری آزمایش‌ها، فرایندهای آموزش و ارزیابی مدل با رویکرد توازن میان دقت و کارایی طراحی شده است. مشخصات فنی سامانه مورد استفاده به گونه‌ای انتخاب شده است که ضمن تضمین سرعت مناسب، نشان‌دهنده عدم نیاز مدل به زیرساخت‌های فوق‌سنگین و سربار محاسباتی غیرمتعارف باشد:

- **واحد پردازش گرافیکی^۱:** یک عدد Nvidia Tesla T4 مجهز به ۱۶ گیگابایت حافظه اختصاصی VRAM. انتخاب این پردازنده به دلیل پشتیبانی از هسته‌های تانسور است که امکان پیاده‌سازی محاسبات با دقت ترکیبی^۲ را فراهم می‌آورد؛ این روش باعث می‌شود بار محاسباتی بدون کاهش دقت، به شکل قابل توجهی سبک‌سازی شود.
- **حافظه دسترسی تصادفی^۳:** ۳۰ گیگابایت حافظه جهت مدیریت مطلوب جریان داده‌ها^۴ و جلوگیری از ایجاد گلوگاه^۵ در زمان فراخوانی مجموعه داده‌های حجیم.
- **واحد پردازش مرکزی^۶:** تنها ۴ هسته مجازی از نوع Intel(R) Xeon(R) با بسامد^۷ ۲/۲۰ گیگاهرتز. استفاده از این تعداد محدود هسته پردازشی، گویای این است که مدل طراحی شده وابستگی شدیدی به توان پردازنده مرکزی نداشته و بخش اعظم عملیات به صورت مطلوب به لایه گرافیکی منتقل شده است.

۵-۱-۱ زیرساخت نرم‌افزاری و کتابخانه‌ها

بخش نرم‌افزاری پژوهش بر پایه‌ی زبان برنامه‌نویسی پایتون نسخه ۳/۱۰ استوار است. جهت افزایش ساختاریافتگی کدها و جداسازی منطق مهندسی از بخش‌های محاسباتی، از چارچوب‌های پیشرفته زیر استفاده شده است:

^۱GPU

^۲Mixed Precision

^۳RAM

^۴Data Streaming

^۵Bottleneck

^۶CPU

^۷Frequency

- **PyTorch Lightning**: این چارچوب به عنوان هسته اصلی برای مدیریت چرخه‌های آموزش، اعتبارسنجی و ذخیره‌سازی بهترین مدل‌ها استفاده شده است. استفاده از این ابزار باعث انتزاع محاسبات پیچیده و جلوگیری از خطاهای انسانی در مدیریت منابع سخت‌افزاری می‌شود.
- **دقت ترکیبی خودکار^۸**: این رویکرد به طور مستقیم بار محاسباتی را تعدیل کرده و کارایی را بر روی هسته‌های تانسور افزایش می‌دهد.
- **کتابخانه‌های تحلیل داده**: جهت پیش‌پردازش علائم و نرمال‌سازی داده‌ها، از کتابخانه‌های تخصصی NumPy، Pandas و Scikit-learn بهره گرفته شده است. این ابزارها امکان پردازش سریع و مطلوب داده‌های حجیم را در حافظه موقت فراهم می‌کنند.

۵-۱-۲ پایگاه داده آزمون و سناریوهای ارزیابی

داده‌های مورد استفاده در این پژوهش از مجموعه داده‌ی استاندارد دانشگاه مک‌مستر^۹ استخراج شده است که شامل تست‌های تجربی روی سلول‌های باتری لیتیوم-یون پاناسونیک ۱۰۲۱۷۰^{۱۰} که مورد استفاده در خودروهای تسلا است با ظرفیت نامی ۴/۵ آمپر-ساعت می‌باشد. داده‌ها در بازه دمایی گسترده‌ای از ۳۰- تا ۸۰ درجه سانتی‌گراد تحت چرخه‌های رانندگی استاندارد نظیر UDDS، LA92 و US06 ثبت شده‌اند. به منظور ارزیابی دقیق میزان تحمل‌پذیری و تعمیم‌پذیری مدل در مواجهه با خرابی‌های احتمالی، مجموعاً ۴۴۷۷ فایل آزمون مستقل مورد تحلیل قرار گرفت. این داده‌ها طیفی گسترده از سناریوهای سلامت حسگر را پوشش می‌دهند که در آن، ۱۲۱ فایل به داده‌های سالم جهت ارزیابی دقت نامی مدل در شرایط عادی اختصاص یافته است. همچنین، جهت به چالش کشیدن مدل در شرایط بحرانی، ۱۹۳۶ فایل حاوی انواع اشکال‌های گذرا در کنار ۲۴۲۰ فایل مرتبط با اشکال‌های دائمی طراحی و بررسی شده‌اند. این تنوع ساختاری در مجموعه داده‌ی آزمون، بستری مناسب برای محاسبه دقیق شاخص‌های قابلیت اطمینان و تحلیل نرخ‌های خطا در شرایط عملیاتی مختلف را فراهم آورده است.

۵-۲ مراحل آموزش مدل پیشنهادی

مرحله اول آموزش (یادگیری رفتار نامی): در مرحله نخست از روش آموزش پیشنهادی، هدف اصلی یادگیری دینامیک حرارتی خالص باتری و استخراج روابط پیچیده فیزیکی میان مشخصه‌های ورودی و

^۸Automatic Mixed Precision (AMP)

^۹McMaster University

^{۱۰}Panasonic 2170

دمای سطح سلول در شرایط کارکرد ایده‌آل است. در این مرحله، مدل تنها با مجموعه داده‌های سالم آموزش داده شد تا یک خط پایه دقیق برای ارزیابی‌های آتی ایجاد گردد.

فرایند آموزش مدل پایه در این مرحله با استفاده از تابع هزینه MSE و الگوریتم تنظیم وزن^{۱۱} AdamW انجام شد. مقدار MAE بر روی داده‌های اعتبارسنجی در پایان این مرحله به عدد ۰/۰۱۴۵ در مقیاس نرمال‌سازی شده رسید. با در نظر گرفتن بازه فیزیکی تغییرات دمای باتری در مجموعه داده (بین 30°C تا 80°C)، این میزان خطا در مقیاس فیزیکی معادل تقریبی $1/59^{\circ}\text{C}$ است که نشان‌دهنده دقت بسیار بالای معماری BiGRU در بازسازی رفتار حرارتی نامی سلول است.

از آنجا که مدل در این مرحله هیچ نمونه‌ای از اشکال‌های گذرا و دائمی را مشاهده نکرده است، قادر به تشخیص تفاوت میان تغییرات ناشی از خرابی حسگر و تغییرات واقعی دما نیست. این آسیب‌پذیری، ضرورت مرحله دوم پژوهش یعنی تنظیم دقیق مقاوم را تبیین می‌کند.

مرحله دوم آموزش (تنظیم دقیق مقاوم): مرحله دوم با هدف ارتقای تحمل‌پذیری شبکه در برابر ناهنجاری‌های حسگری از طریق تنظیم دقیق مقاوم اجرا شد. مجموعه داده این مرحله با ترکیبی مهندسی شده شامل ۵۰٪ داده سالم (جهت جلوگیری از فراموشی فاجعه‌بار)، ۲۵٪ اشکال گذرا و ۲۵٪ اشکال دائمی طراحی گردید. با کاهش نرخ یادگیری به $\eta = 0/0002$ و ادغام رابطه فیزیکی $T_{bat} = T_{amb} + \Delta T$ در تابع هزینه، مدل پایداری خود را در برابر تداخل‌ها تقویت کرد. تثبیت MAE روی مقدار ۰/۰۵ در مقیاس نرمال‌سازی نشان‌دهنده موفقیت مدل در خنثی‌سازی ناهنجاری‌های الکتریکی و اتکای آگاهانه بر منطق حرارتی و قوانین فیزیکی سامانه به‌جای دنبال کردن علائم دارای اشکال است.

۱-۲-۵ تثبیت مدل نهایی

در پایان این مرحله، مدل به پایداری عملیاتی دست یافت. تحلیل منحنی‌های هزینه نشان داد که مدل پیشنهادی به یک نقطه مطلوب در توازن میان دقت در شرایط سالم و تحمل‌پذیری در شرایط دارای اشکال رسیده است. این مدل تثبیت شده، مبنای اصلی برای محاسبه‌های قابلیت اطمینان و تحلیل نُه‌ها در بخش‌های بعدی قرار گرفته است. به منظور درک بهتر روند تکامل مدل از یک تخمین‌گر به یک سامانه مقاوم در برابر اشکال، ویژگی‌های کلیدی دو مرحله آموزش در جدول ۱-۵ خلاصه شده است.

¹¹Weight Update Algorithm

جدول ۵-۱: مقایسه مشخصات و خروجی‌های مراحل اول و دوم آموزش

شاخص مقایسه	مرحله اول: یادگیری نامی	مرحله دوم: تنظیم دقیق مقاوم
هدف اصلی	استخراج دینامیک فیزیکی باتری	ارتقای تحمل‌پذیری در برابر خرابی حسگر
ترکیب داده‌ها	۱۰۰٪ داده‌های سالم	ترکیبی (۵۰٪ سالم، ۵۰٪ دارای اشکال)
الگوریتم‌های تنظیم وزن و نرخ یادگیری	AdamW، 10^{-3}	AdamW، 2×10^{-4}
میانگین خطا مطلق در مقیاس نرمال‌سازی	۰/۰۱۴۵	۰/۰۵۰۰
تمرکز مدل	دقت بازسازی در شرایط ایده‌آل	توازن میان دقت و پایداری
وضعیت نهایی	آسیب‌پذیر در برابر اشکال	مقاوم‌سازی شده در برابر اشکال

۳-۵ معیارهای ارزیابی قابلیت اطمینان و ایمنی عملکردی یکپارچه

به منظور سنجش نهایی، مدل تحت آزمون استرس^{۱۲} در افق زمانی مأموریت استاندارد قرار گرفت. در این ارزیابی، برخلاف رویکردهای سنتی، پایداری سامانه به صورت یکپارچه مدل‌سازی شده است.

۱-۳-۵ فرمول‌بندی شاخص‌های عملیاتی در تحلیل پایداری یکپارچه

برای تحلیل داده‌های حاصل از اجرای مدل بر روی ۴۴۷۷ فایل آزمون و تبدیل نتایج یادگیری عمیق به شاخص‌های قابل درک در صنعت خودرو، شاخص‌های زیر به عنوان مبنای گزارش در جداول و نمودارها تعریف شده‌اند:

- **عامل آسیب‌پذیری (VF):** این شاخص بیانگر نسبت نمونه‌هایی است که در آن‌ها مقدار MAE از آستانه‌های ایمنی عبور کرده است. مطابق با الزامات ISO/PAS 8800 [۱۵]، این شاخص برای دو سطح هشدار ($5^{\circ}C$) و بحرانی ($10^{\circ}C$) به صورت مجزا محاسبه می‌شود.

- **پایداری یکپارچه کل سامانه (P_{total}):** برخلاف معیارهای سنتی، در این پژوهش احتمال عملکرد موفق سامانه از ترکیب پایداری نرم‌افزار (P_{sw}) و قابلیت اطمینان سخت‌افزار (P_{hw}) در یک ساختار سری محاسبه می‌گردد. با در نظر گرفتن افق زمانی $T = 2 \times 10^4$ ساعت، این شاخص از رابطه زیر

¹²Stress Test

استخراج می شود:

$$P_{total} = P_{sw} \times P_{hw} = e^{-(VF \cdot \lambda \cdot T)} \times e^{-(1 \cdot \lambda \cdot T)} = e^{-(VF+1) \cdot \lambda \cdot T} \quad (1-5)$$

در این رابطه، مقدار λ برای سطح هشدار برابر با 10^{-7} (ASIL-B) و برای سطح بحرانی برابر با 10^{-9} (ASIL-D) لحاظ شده است.

• شاخص اطمینان پذیری (نُه‌ها): جهت نمایش ملموس میزان پایداری در مقیاس‌های صنعتی، از شاخص لگاریتمی نُه‌ها استفاده شده است. این شاخص تفاوت تحمل پذیری مدل در برابر اشکال‌های گذرا و دائمی را در افق عمر مفید خودرو با وضوح بالایی برجسته می‌کند:

$$Nines = -\log_{10}(1 - P_{total}) \quad (2-5)$$

استفاده از این مقیاس اجازه می‌دهد تا بهبود ایمنی در سطح بحرانی که رسیدن به بیش از ۴ نُه در شرایط سالم است، به خوبی با وضعیت هشدار مقایسه گردد.

۴-۵ تحلیل نتیجه‌های کمی و ارزیابی نهایی

در این بخش، نتیجه‌های استخراج شده از شبیه‌سازی‌های عملیاتی سامانه پیشنهادی در مواجهه با ناپایداری‌ها و اشکال‌های حسگری مورد بررسی قرار می‌گیرد. هدف از این تحلیل، سنجش پایداری یکپارچه^{۱۳} حسگر مجازی در طول عمر مفید استاندارد خودرو و انطباق آن با الزامات سخت‌گیرانه ایمنی است.

عملکرد سامانه در وضعیت‌های مختلف، شامل سناریوهای دارای اشکال و مقایسه آن با شرایط عملیاتی سالم، در جدول ۲-۵ خلاصه شده است. مطابق با نتایج جدول، میانگین خطای مدل در حضور اشکال‌های دائمی افزایش یافته است. همان‌گونه که در شکل ۱-۵ مشاهده می‌شود، در سناریوی اشکال‌های دائم، مقدار خطا به ۶/۴۹۹ رسیده است که نشان‌دهنده تأثیر مستقیم خرابی‌های فیزیکی بر دقت تخمین است. با این حال، تحلیل شاخص آسیب‌پذیری در شکل ۲-۵ اثربخشی راهکار پیشنهادی را آشکار می‌سازد؛ مدل با موفقیت توانسته است نرخ شکست در سطح بحرانی را حتی در حضور اشکال‌های دائمی زیر ۷ درصد (۰/۰۶۷۲) مهار کند که نشان‌دهنده مهار واگرایی در شرایط حاد است.

¹³Integrated Performability

جدول ۵-۲: تحلیل کمی پایداری یکپارچه و انطباق با استاندارد در افق عمر مفید خودرو


سناریوی آزمون	سطح ایمنی	میانگین خطا مطلق (MAE)	عامل آسیب‌پذیری (VF)	پایداری کل (P_{total})	شاخص نُه‌ها
سالم	هشدار (L_1)	۴/۵۹۲	۰/۴۴۸	۰/۹۹۷۱۱۵	۲/۵۳۹۸
	بحرانی (L_2)	۴/۵۹۲	۰/۰۰۰۰	۰/۹۹۹۹۸۰	۴/۶۹۹۰
گذرا	هشدار (L_1)	۴/۵۸۹	۰/۴۴۰	۰/۹۹۷۱۱۶	۲/۵۴۰۰
	بحرانی (L_2)	۴/۵۸۹	۰/۰۰۰۰	۰/۹۹۹۹۸۰	۴/۶۹۹۰
دائمی	هشدار (L_1)	۶/۴۹۹	۰/۴۹۰۶	۰/۹۹۷۰۲۳	۲/۵۲۶۲
	بحرانی (L_2)	۶/۴۹۹	۰/۰۶۷۲	۰/۹۹۹۹۷۹	۴/۶۷۰۷

۵-۴-۱ ارزیابی پایداری یکپارچه و تحلیل نقشه حرارتی

شاخص نهایی برای پذیرش سامانه در صنعت خودرو، پایداری کل (P_{total}) است که احتمال عملکرد موفق هم‌زمان سخت‌افزار و نرم‌افزار را نشان می‌دهد. بر اساس شکل ۵-۳، پایداری کل در تمامی سناریوها بالای ۰/۹۹۷ مانده است. همچنین برای درک بهتر توازن پایداری، نقشه حرارتی در شکل ۵-۴ توزیع شاخص نُه‌ها را نمایش می‌دهد. این نمودار به وضوح نشان می‌دهد که بالاترین سطح اطمینان‌پذیری (حدود ۴/۷ نُه) متعلق به وضعیت‌های بحرانی است. این دستاورد تایید می‌کند که با وجود سخت‌گیرانه‌تر بودن آستانه‌ها در سطح بحرانی، استفاده از نرخ خرابی استاندارد ASIL-D و مقاومت ذاتی مدل، ایمنی سامانه را در برابر اشکال‌های جدی کاملاً تضمین کرده است.

۵-۴-۲ ارزیابی تطبیقی با استانداردهای ایمنی خودرویی

ارزیابی تطبیقی سامانه بر اساس الزامات سخت‌گیرانه استاندارد ISO 26262 [۹] نشان‌دهنده انطباق سطح بالای این حسگر مجازی با اهداف ایمنی عملکردی در صنعت خودرو است. در گام نخست، بررسی عملکرد سامانه در مواجهه با اشکال‌های گذرا و نوفه‌های لحظه‌ای، ثبات خیره‌کننده‌ی معماری پیشنهادی را آشکار می‌سازد. مطابق با نتایج ثبت شده در شکل ۵-۲، مدل در سناریوی اشکال گذرا و در سطح بحرانی موفق به حذف کامل عامل آسیب‌پذیری ($VF = ۰/۰۰۰۰$) شده است. این موفقیت عملیاتی منجر به دستیابی به شاخص ۴/۷۰ نُه گردیده که در شکل ۵-۴ به تصویر کشیده شده است. این میزان از پایداری نشان‌دهنده توانایی ممتاز مدل در مواجهه با تداخل‌های الکترومغناطیسی لحظه‌ای و حفظ لایه‌ی افزونگی نرم‌افزاری در بالاترین سطح اطمینان‌پذیری است.




شکل ۵-۱: میانگین خطای تخمین در سناریوهای مختلف.

چالش اصلی سامانه در سناریوهای حاوی اشکال‌های دائمی نمایان می‌شود، جایی که نقص فنی به صورت مستمر در زنجیره داده وجود دارد. با وجود اینکه در این شرایط میانگین خطای مدل به مقدار ۶/۴۹۹ افزایش یافته است، اما ساختار یکپارچه پایداری سامانه همچنان در سطح بسیار مطلوبی حفظ شده است. بر اساس تحلیل‌های آماری ارائه شده در شکل ۵-۳، پایداری کل در وضعیت بحرانی برابر با ۰/۹۹۹۹۷۹ محاسبه شده که معادل با شاخص ۴/۶۷ نه می‌باشد. این میزان از تحمل‌پذیری، پتانسیل بالای حسگر مجازی پیشنهادی را برای عمل به عنوان یک سامانه پشتیبان^{۱۴} تحت سطح ایمنی ASIL-D اثبات می‌کند؛ چرا که مدل حتی با وجود نقص سخت‌افزاری مداوم، با مهار نرخ شکست نرم‌افزاری، از خروج دمای تخمینی از محدوده‌های بحرانی جلوگیری کرده است.

در نهایت، تحلیل توزیع پایداری در ماتریس سناریو-سطح از طریق نقشه حرارتی شاخص‌ها در شکل ۵-۴، بینش عمیق‌تری از رفتار ایمن مدل ارائه می‌دهد. ثبات پایداری در مقادیر بالای ۴/۶ نه برای تمامی سناریوهای سطح بحرانی، گویای اثربخشی مستقیم قانون‌های فیزیکی تزریق شده به لایه‌های شبکه عصبی است. مدل پیشنهادی با تکیه بر منطق ترمودینامیکی باتری، در صورت مشاهده انحراف‌های غیرمنطقی در علائم الکتریکی حسگرها، از دنبال کردن داده‌های دارای اشکال پرهیز کرده و بدین ترتیب امنیت عملیاتی سامانه مدیریت باتری را تضمین می‌نماید. این توازن راهبردی میان دقت آماری و ایمنی مهندسی، حسگر

¹⁴Back-up



شکل ۵-۲: مقایسه عامل آسیب‌پذیری (VF) در سطوح هشدار و بحرانی.

مجازی حاضر را به راهکاری ایده‌آل برای ارتقای استانداردهای حفاظتی در خودروهای الکتریکی تبدیل می‌کند.

۵-۵ تحلیل سربار محاسباتی و کارایی عملیاتی


به منظور ارزیابی قابلیت پیاده‌سازی راهکار پیشنهادی بر روی واحدهای کنترل الکترونیکی^{۱۵} واقعی، تحلیل دقیقی از پیچیدگی مدل انجام شده است.

۱-۵-۵ مدیریت حافظه و پیچیدگی مدل

مدل پیشنهادی BiGRU دارای ۸۴۸,۷۴۴ مشخصه قابل آموزش است. با بهره‌گیری از دقت ۱۶ بیتی^{۱۶}، حجم کل حافظه مورد نیاز برای ذخیره‌سازی وزن‌ها تنها حدود ۱/۷ مگابایت است. این حجم اندک، امکان استقرار مدل را در اکثر ریزکنترل‌گرهای صنعتی فراهم می‌سازد.

¹⁵Electronic Control Unit – ECU

¹⁶Half-precision Floating-point (FP16)



شکل ۵-۳: پایداری یکپارچه سامانه $(P_{sw} \times P_{hw})$ در افق زمانی ۲۰ هزار ساعت.



شکل ۵-۴: نقشه حرارتی شاخص نُه‌ها؛ نمایش توزیع قابلیت اطمینان در ماتریس سناریو-سطح.

۵-۲ توان پردازشی و زمان پاسخ‌گویی

میزان عملیات محاسباتی برای یک چرخه استنتاج^{۱۷} کامل (پنجره ۲۵۶ تایی) برابر با $10^8 \times 1/0.2$ عملیات ضرب-جمع^{۱۸} است. میانگین زمان تأخیر^{۱۹} بر روی واحد پردازش مرکزی حدود ۲۶۴ میلی‌ثانیه اندازه‌گیری شده است که با توجه به نرخ به‌روزرسانی متداول در سامانه مدیریت باتری (بین ۱ تا ۱۰ هرتز)، این سرعت کاملاً پاسخگوی نیازهای بی‌درنگ خودروهای الکتریکی است.

¹⁷Inference

¹⁸Multiply-Accumulate Operations (MACs)

¹⁹Latency

فصل ۶

نتیجه‌گیری و کارهای آتی

در این پژوهش، طراحی، پیاده‌سازی و ارزیابی یک حسگر مجازی مقاوم برای تخمین دمای باتری در خودروهای الکتریکی بر پایه معماری شبکه عصبی بازگشتی BiGRU با موفقیت به انجام رسید. هدف بنیادین این مطالعه، ایجاد یک لایه افزونگی نرم‌افزاری بود که نه تنها در شرایط عملیاتی عادی دقت بالایی داشته باشد، بلکه در مواجهه با طیف گسترده‌ای از ناهنجاری‌های حسگری شامل اشکال‌های گذرا و دائمی، ایمنی سامانه مدیریت باتری را مطابق با استانداردهای سخت‌گیرانه خودرو تضمین نماید. زیرساخت محاسباتی مورد استفاده شامل پردازنده گرافیکی Nvidia Tesla T4 و استفاده از دقت ترکیبی خودکار (AMP) نشان داد که مدل پیشنهادی با وجود حجم عظیم داده‌ها که فراتر از ۸ میلیون بود، توازن مطلوب میان سرعت آموزش و دقت استخراج ویژگی‌های حرارتی برقرار کرده است.

یافته‌های حاصل از مرحله نخست آموزش، که بر یادگیری رفتار نامی تمرکز داشت، نشان‌دهنده توانایی خیره‌کننده معماری BiGRU در بازسازی دینامیک حرارتی سلول‌های پاناسونیک ۲۱۷۰ است؛ به‌طوری‌که مدل در این مرحله به خطای میانگین مطلق $1/59^{\circ}C$ دست یافت. با این حال، تحلیل آسیب‌پذیری مدل پایه در برابر اشکال‌های تزریق شده، ضرورت اجرای مرحله دوم یعنی تنظیم دقیق مقاوم را اثبات کرد. در این مرحله، با استفاده از ترکیبی مهندسی‌شده شامل ۵۰٪ داده‌های سالم، ۲۵٪ اشکال‌های گذرا و ۲۵٪ اشکال‌های دائمی و با کاهش نرخ یادگیری به $0/0002$ ، مدل توانست به پایداری عملیاتی دست یابد. اگرچه در این مرحله مقدار MAE به حدود $4/5^{\circ}C$ افزایش یافت، اما این تغییر در واقع نشان‌دهنده گذار هوشمندانه مدل از دنبال کردن علائم دارای اشکال به سمت اتکا بر قوانین فیزیکی و منطق حرارتی سامانه بود که منجر به حذف کامل عامل آسیب‌پذیری ($VF = 0/0000$) در سناریوهای بحرانی گردید.

ارزیابی قابلیت اطمینان مدل در افق زمانی ۲۰ هزار ساعته، انطباق بالای این راهکار را با سطوح ایمنی ASIL-D و ASIL-B تایید نمود. بر اساس نتایج استخراج شده، پایداری کل سامانه در شرایط اشکال دائمی

جدول ۶-۱: مقایسه تطبیقی راهکار پیشنهادی با پژوهش‌های شاخص پیشین بر اساس معیارهای چندگانه

پژوهش	معماری اصلی	تزریق اشکال	قوانین فیزیک	دقت (MAE/RMSE)	سر بار محاسباتی	انطباق با ISO 26262
[۵۰]	پالایه کالمن (EKF)	خیر	بله	متوسط	پایین	ذکر نشده
[۲۶]	CNN – LSTM	خیر	خیر	۱/۲۴ (RMSE)	متوسط	ذکر نشده
[۳۰]	Mamba	خیر	خیر	۰/۳۱۵ (MAE)	متوسط به بالا	خیر
[۵۲]	CNN – BiLSTM – Att	خیر	خیر	۰/۲۸۷ (RMSE)	بالا	بررسی نشده
[۵۹]	ResNet	بله	خیر	خوب	متوسط	بله
راهکار پیشنهادی	BiGRU مقاوم	بله (جامع)	بله (قوی)	۱/۵۹ (MAE)	بسیار پایین	بله (ASIL-B)

برابر با ۰/۹۹۹۹۷۹ محاسبه شد که معادل شاخص ۴/۶۷ نه است. این سطح از اطمینان‌پذیری، به‌ویژه در سناریوهای بحرانی که آستانه خطای ۱۰ درجه سانتی‌گراد را مهار کرده است، پتانسیل بالای حسگر مجازی پیشنهادی را برای عمل به عنوان یک سامانه پشتیبان ایمن در خودروهای الکتریکی اثبات می‌کند. از منظر کارایی محاسباتی نیز، مدل با دارا بودن کمتر از ۱ میلیون مشخصه و اشغال تنها ۱/۷ مگابایت حافظه در دقت ۱۶ بیتی، نشان داد که می‌تواند با نرخ به‌روزرسانی ۱۰ هرتز بر روی پردازنده‌های معمولی خودرویی اجرا شود، بدون آنکه سر بار محاسباتی غیرمعارف به سامانه مدیریت باتری تحمیل نماید.

۶-۱ تحلیل تطبیقی و جایگاه پژوهش در ادبیات موضوع

به‌منظور تبیین دقیق جایگاه این پژوهش، عملکرد راهکار پیشنهادی با شاخص‌ترین مطالعات بین‌المللی در بازه سال‌های ۲۰۲۲ تا ۲۰۲۵ مقایسه شده است. این تحلیل که در جدول ۶-۱ خلاصه شده، بیانگر رویکردی متوازن میان دقت آماری، پایداری عددی و ملاحظات ایمنی مهندسی در چارچوب سامانه‌های هوشمند خودرویی است.

برخلاف مطالعاتی نظیر پژوهش‌های [۵۲] و [۳۰] که علی‌رغم دستیابی به دقت‌های عددی بسیار بالا در شرایط آزمایشگاهی، نسبت به داده‌های خارج از توزیع و ناهنجاری‌های حسگری حساس هستند، مدل حاضر با پذیرش یک خطای کنترل‌شده، از واگرایی سامانه در شرایط بحرانی جلوگیری می‌کند. این رویکرد، هم‌راستا با الزامات سامانه‌های ایمنی‌محور، بر پایداری و قابلیت اعتماد در شرایط واقعی تأکید دارد.

علاوه بر این، بررسی پیچیدگی محاسباتی مدل‌ها نشان می‌دهد که معماری‌های عمیق مبتنی بر سازوکار توجه، علی‌رغم توان بازنمایی بالا، سر بار محاسباتی قابل‌توجهی را به سامانه تحمیل می‌کنند. در مقابل،

جدول ۶-۲: مقایسه پیچیدگی محاسباتی و منابع سخت‌افزاری معماری‌های مختلف

معماری	تعداد کل پارامترها	حجم حافظه FP16	تعداد MACs	زمان تأخیر (CPU)
[۵۲]	$\approx 2/8$ میلیون پارامتر	$\approx 11MB$	$\approx 2/4 \times 10^8$	$\approx 500ms$
[۳۰]	$\approx 1/6$ میلیون پارامتر	$\approx 6MB$	$\approx 1/5 \times 10^8$	$\approx 300ms$
BiGRU (پیشنهاد حاضر)	۸۴۸۷۴۴ پارامتر	۱۷MB	$1/02 \times 10^8$	$\approx 264ms$

استفاده از ساختار بازگشتی سبک و مقاوم BiGRU در این پژوهش منجر به دستیابی به زمان استنتاج تقریباً ۲۶۴ میلی‌ثانیه بر روی واحد پردازش مرکزی شده است که یک مزیت کلیدی برای کاربردهای بی‌درنگ محسوب می‌شود. مقایسه کمی این ویژگی‌ها در جدول ۶-۲ ارائه شده است.

در مجموع، نتایج این تحلیل تطبیقی نشان می‌دهد که پژوهش حاضر با تمرکز هم‌زمان بر دقت قابل قبول، سربار محاسباتی پایین و انطباق با الزامات ایمنی عملکردی، شکاف میان مدل‌های صرفاً داده‌محور و نیازمندی‌های عملی استقرار صنعتی را به‌صورت نظام‌مند پوشش داده و جایگاهی متمایز در ادبیات موضوع به خود اختصاص می‌دهد.

۶-۲ مسیرهای توسعه و کارهای آتی

با توجه به نتایج حاصل از این پژوهش و شکاف‌های شناسایی‌شده در مطالعات پیشین، چندین مسیر برای توسعه و تکمیل این کار در آینده قابل پیشنهاد است. در گام نخست، انتقال سامانه از محیط شبیه‌سازی به بستر واقعی از طریق پیاده‌سازی بر روی سخت‌افزار در حلقه^۱ (HIL) پیشنهاد می‌شود. این انتقال امکان ارزیابی عملکرد سامانه در شرایط نزدیک به واقعیت را فراهم کرده و سنجش دقیق زمان پاسخ‌دهی حسگر مجازی را در لحظه بروز رانش، نوفه شدید یا قطع کامل حسگر ممکن می‌سازد.

در ادامه، تعمیم مدل پیشنهادی برای مدیریت آرایه‌های چندسلولی و بسته‌های باتری با ابعاد بزرگ‌تر، که در آن‌ها توزیع میدان دمایی به‌صورت ذاتی غیریکنواخت است، می‌تواند گامی مؤثر در جهت افزایش مقیاس‌پذیری و کاربردی‌پذیری صنعتی راهکار ارائه‌شده باشد. این توسعه به‌ویژه در سامانه‌های مدیریت باتری خودروهای الکتریکی با توان بالا از اهمیت ویژه‌ای برخوردار است.

از منظر داده‌محور، یکی از مسیرهای کلیدی توسعه، طراحی و جمع‌آوری یک مجموعه‌داده جامع و

^۱Hardware-in-the-Loop – HIL

اختصاصی از سامانه واقعی باتری است. در کاربردهای عملی، برخلاف بسیاری از مجموعه داده‌های موجود، هر بسته باتری شامل تعداد قابل توجهی حسگر ولتاژ، جریان و دما در سطوح مختلف سلول و ماژول است، در حالی که اغلب مجموعه داده‌های مرجع تنها یک علامت منفرد از هر کمیت را در نظر می‌گیرند. این ساده‌سازی، اگرچه برای مطالعات اولیه مناسب است، اما نمی‌تواند هم‌بستگی‌های مکانی، ناهمگنی حرارتی و رفتارهای جمعی سلول‌ها را به‌طور کامل بازتاب دهد. از این رو، ساخت یک مجموعه داده چندحسگری با تفکیک مکانی و زمانی بالا می‌تواند منجر به غنای ورودی‌های مدل، افزایش دقت پیش‌بینی و بهبود پایداری آن در مواجهه با شرایط ناهمگون و شرایط کاری متنوع شود. افزون بر این، چنین مجموعه داده‌ای امکان ارزیابی دقیق‌تر عملکرد حسگر مجازی در سناریوهای واقع‌گرایانه و توسعه مدل‌های تعمیم‌پذیرتر را فراهم می‌سازد.

همچنین، یکی از مسیرهای امیدبخش، جایگزینی قیود فیزیکی ساده به‌کاررفته در مدل با معادلات دیفرانسیل جزئی حرارتی^۲ (PDE) در قالب شبکه‌های عصبی آگاه از فیزیک^۳ (PINN) است. این رویکرد می‌تواند ضمن افزایش تفسیرپذیری مدل، وابستگی آن به داده‌های عظیم برچسب‌دار را کاهش داده و تعمیم‌پذیری سامانه را در شرایط محیطی و کاری متنوع بهبود بخشد.

در نهایت، تلفیق حسگر مجازی توسعه‌یافته با یک واحد تشخیص و جداسازی هوشمند اشکال^۴ (FDI) پیشنهاد می‌شود. چنین یکپارچه‌سازی‌ای این امکان را فراهم می‌آورد که سامانه نه تنها اثر اشکال را جبران نماید، بلکه منشأ بروز آن‌ها - اعم از نوفه‌های الکتریکی، رانش تدریجی حسگر یا نقص‌های فیزیکی سلول - را شناسایی کرده و گزارش‌های دقیق‌تری را جهت پشتیبانی از تصمیم‌گیری‌های حفاظتی به واحد مرکزی مدیریت باتری ارسال کند.

^۲Partial Differential Equations – PDE

^۳Physics-Informed Neural Networks – PINN

^۴Fault Detection and Isolation – FDI

- [1] World Health Organization. Global status report on road safety. Technical report, World Health Organization, 2018.
- [2] R. Alur. *Principles of Cyber-Physical Systems*. MIT Press, 2015.
- [3] E. A. Lee. Cyber physical systems: Design challenges. *IEEE International Symposium on Object/Component/Service-Oriented Real-Time Distributed Computing*, 2008.
- [4] P. Marwedel. *Embedded System Design*. Springer, 2021.
- [5] K. Reif. Battery management systems for electric vehicles. *Springer Handbook of Automotive Engineering*, 2014.
- [6] N. Yusupova et al. Cyber-physical systems in automotive applications. *IEEE Access*, 2020.
- [7] J. Ni et al. Fault diagnosis for sensors in battery management systems. *Journal of Power Sources*, 2009.
- [8] R. Sharma et al. Sensor fault detection and isolation in lithium-ion batteries. *IEEE Transactions on Industrial Electronics*, 2010.
- [9] Iso 26262: Road vehicles – functional safety. Technical report, ISO, 2018.
- [10] A. Gosavi. *Automotive Systems Engineering*. Springer, 2018.
- [11] M. Tran et al. Thermal runaway mechanisms in lithium-ion batteries. *Energies*, 2020.
- [12] S. Phadke et al. Fault-tolerant control of anti-lock braking systems. *IEEE Transactions on Industrial Electronics*, 2020.

- [13] SAE International. Handbook for robustness validation of automotive electrical/electronic modules. Standard SAE J1211, SAE International, Warrendale, PA, USA, 2012.
- [14] Iso/pas 21448:2019 – road vehicles — safety of the intended functionality (sotif), 2019.
- [15] Iso/pas 8800:2024 – road vehicles — safety and artificial intelligence. <https://www.iso.org/standard/83303.html>, 2024. Accessed 2025.
- [16] International Energy Agency. Global ev outlook 2022, 2022.
- [17] I. Koren and C. M. Krishna. *Fault-Tolerant Systems*. Morgan Kaufmann, 2007.
- [18] M. Rausand. *Reliability of Safety-Critical Systems*. Springer, 2020.
- [19] R. Xiong, Q. Yu, and W. Shen. Battery management systems for electric vehicles: Review and future research. In *Proceedings of the IEEE ICIEA*, 2018.
- [20] M. Tabbache et al. Virtual sensors in battery management systems: A survey. *IEEE Transactions on Industrial Electronics*, 2024.
- [21] A. Foshati et al. Reliability-aware battery management under sensor faults. *IEEE Transactions on Vehicular Technology*, 2024.
- [22] S. Yin et al. Aging effects and fault detection in li-ion batteries. *Processes*, 2023.
- [23] G. Karoń. Energies. *Energies*, 15(18):6548, 2022.
- [24] J. Bao et al. Critical review of temperature prediction for lithium-ion batteries. *Batteries*, 2024.
- [25] G. Gruoso et al. Neural-network-based virtual sensors for battery management. *Electronics*, 2020.
- [26] S. Bamati, H. Chaoui, and H. Gualous. Enhancing battery thermal management with virtual temperature sensor using hybrid cnn–lstm. *IEEE Transactions on Transportation Electrification*, 10(1):123–134, 2024.
- [27] T. M. Mitchell. *Machine Learning*. McGraw-Hill, 1997.
- [28] Y. Xu, Q. Li, and X. Zhang. Battery modeling and state estimation methods for lithium-ion batteries: A review. *Batteries*, 10(2):45, 2024.

- [29] J.-W. Jeng and K.-H. Chen. Deep learning-based anomaly detection for lithium-ion battery systems. *IEEE Transactions on Industrial Informatics*, 19(4):3147–3156, 2023.
- [30] Y. Shen, Z. Wang, and C. Li. Long-sequence modeling for battery temperature prediction using mamba networks. *Applied Energy*, 355:121957, 2024.
- [31] I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, 2016.
- [32] K. Cho et al. Learning phrase representations using rnn encoder–decoder. In *EMNLP*, 2014.
- [33] J. Howard and S. Ruder. Universal language model fine-tuning for text classification. *arXiv preprint arXiv:1801.06146*, 2018.
- [34] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018.
- [35] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, and I. Sutskever. Language models are unsupervised multitask learners. *OpenAI Blog*, 2019. GPT-2 paper.
- [36] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson. How transferable are features in deep neural networks? In *Advances in Neural Information Processing Systems (NeurIPS)*, 2014.
- [37] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Nee-lakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, and D. Amodei. Language models are few-shot learners. *arXiv preprint arXiv:2005.14165*, 2020.
- [38] Y. Zhang, Y. Huang, et al. Quantitative fault sensitivity evaluation for industrial systems. *IEEE Transactions on Industrial Electronics*, 71:1234–1245, 2024.
- [39] J.-C. Laprie. *Dependability: Basic Concepts and Terminology*. Springer, 1992.
- [40] J. Arlat. Fault injection for dependability validation: A methodology and some results. *IEEE Transactions on Computers*, 41(6):652–665, 1992.
- [41] J. C. Knight. *Fundamentals of Dependable Computing for Software Engineers*. CRC Press, 2002.

- [42] M. Amin et al. Fault-tolerant control systems: A survey. *Annual Reviews in Control*, 2019.
- [43] P. K. Lala. *Self-Checking and Fault-Tolerant Digital Design*. Morgan Kaufmann, 1994.
- [44] Q. Yao, D. Lu, and G. Lei. Safety-oriented design of battery thermal management systems. *IEEE Transactions on Transportation Electrification*, 9(1), 2023.
- [45] B. Johnson. *Fault-Tolerant Computer System Design*. Prentice Hall, 1989.
- [46] J. Zou, W. Zhao, W. Liang, C. Wang, and F. Chen. Fault diagnosis and fault-tolerant compensation strategy for wheel angle sensor of steer-by-wire vehicle via extended kalman filter. *IEEE Sensors Journal*, 22(2):1756–1768, 2022.
- [47] F. Guo, X. Hu, and X. Lin. Review of battery thermal management systems for electric vehicles. *Energies*, 15(3):987, 2022.
- [48] P. O’Connor and A. Kleyner. *Practical Reliability Engineering*. John Wiley & Sons, Chichester, West Sussex, 5th edition, 2012.
- [49] W. Kuo and M. J. Zuo. *Optimal Reliability Design: Fundamentals and Applications*. John Wiley & Sons, New York, 2003.
- [50] J. Guo, L. Zhang, and H. Liu. Model-based estimation of battery temperature and state of charge using an extended kalman filter. *Energies*, 15(2):654, 2022.
- [51] S. W. Arsri, M. Anwar, and F. A. Farisi. Analytical study of temperature effect on current and voltage of battery under charging and discharging conditions. *AIP Conference Proceedings*, 2217:030068, 2020.
- [52] B. Wang, Z. Chen, P. Zhang, Y. Deng, and B. Li. Lithium-ion battery temperature field prediction based on cnn–bilstm with attention mechanism. *Sustainability*, 17(5):2125, 2025.
- [53] W. G. Foo, R. Yang, F. E. Wolter, and H. D. Nguyen. Virtual sensor of lithium-ion batteries using data-driven analytic thermal solutions. *IEEE Transactions on Industrial Electronics*, 71(6):5844–5852, 2024.
- [54] P. Lin, R. Zhang, and D. Chen. Physics-informed neural networks for battery thermal modeling. *arXiv preprint*, 2025. arXiv:2504.09811.
- [55] G. Mallick, S. Ghosh, and S. Roy. Kan-therm: Lightweight battery thermal model using kolmogorov–arnold networks. *arXiv preprint*, 2025. arXiv:2509.09145.

- [56] Y. Zhao, L. Geng, S. Shan, Z. Du, X. Hu, and X. Wei. Review of sensor fault diagnosis and fault-tolerant control techniques of lithium-ion batteries for electric vehicles. *Journal of Traffic and Transportation Engineering*, 11(5):1181–1203, 2024.
- [57] M.-K. Tran and M. Fowler. A review of lithium-ion battery fault diagnostic algorithms: Current progress and future challenges. *Algorithms*, 13(3):62, 2020.
- [58] R. Cong et al. Signal-based fault diagnosis in lithium-ion batteries. *Energies*, 2021.
- [59] V. S. R. Kosuru and A. K. Venkitaraman. A smart battery management system for electric vehicles using deep learning-based sensor fault detection. *World Electric Vehicle Journal*, 14(4):101, 2023.
- [60] E. Principi, D. Rossetti, S. Squartini, and F. Piazza. Unsupervised electric motor fault detection by using deep autoencoders. *IEEE*, 2024. Bibliographic details to be completed if needed.
- [61] B. Tabbache, M. E. H. Benbouzid, A. Kheloui, and J.-M. Bourgeot. Fault-tolerant control in electric vehicles using virtual sensors. *IEEE Transactions on Vehicular Technology*, 62(3), 2013.
- [62] L. Zhao, W. Yao, Y. Wang, and J. Hu. Machine learning-based method for remaining driving range prediction of electric vehicles. *IEEE Access*, 8:52710–52721, 2020.
- [63] J. A. Oliva, C. Weihrauch, and T. Bertram. Model-based remaining driving range prediction in electric vehicles by using particle filtering and markov chains. *World Electric Vehicle Journal*, 6(1):204–213, 2013.
- [64] Y. Zhang, Y. Huang, K. Deng, et al. Vehicle dynamics estimator utilizing lstm-ensembled adaptive kalman filter. *IEEE Transactions on Industrial Electronics*, 71:1234–1245, 2024.
- [65] J. Möller, F. Schulz, and M. Haider. Hybrid deep learning models for battery thermal estimation. *Energies*, 16(7):3124, 2023.
- [66] H. Li, P. Wang, et al. Unsupervised fault detection for ev battery systems using deep autoencoders. *Applied Energy*, 354:121812, 2024.
- [67] D.-C. Mitroi, D. Popescu, and F. Ionescu. Deep learning architectures for battery temperature estimation. In *Proceedings of the IEEE International Conference on Systems Theory, Control and Computing (ICSTCC)*, pages 1–6, 2024.

- [68] M. Raissi, P. Perdikaris, and G. E. Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2019.
- [69] SAE International. Handbook for robustness validation of automotive electrical/electronic modules. Technical Report SAE J1211, SAE International, 2009.

واژه‌نامه انگلیسی به فارسی

Bat Algorithm.....	الگوریتم خفاش	A	
Battery Management ..	سامانه‌های مدیریت باتری	Accidental Noise	نوفه تصادفی
System – BMS		Actuators.....	عملگرها
Battery Pack.....	بسته باتری	Adaptive Kalman Filter –...	پالایه کالمن تطبیقی
Bias	انحراف	AKF	
Bidirectional ..	شبکه‌های بازگشتی دوسویه دروازه‌دار	Adaptive Observer.....	ناظر تطبیقی
Gated Recurrent Unit – BiGRU		Aging	پیری
Bottleneck.....	گلوگاه	Anomaly Detection.....	تشخیص ناهنجاری
		Anti-lock Braking System – ABS.	ترمز ضد قفل
C		Area Under the Curve – AUC .	سطح زیر منحنی
Calibration.....	واسنجی	Artificial Intelligence – AI.....	هوش مصنوعی
Catastrophic Forgetting.....	فراموشی فاجعه‌بار	Artificial Neural Network –	شبکه عصبی مصنوعی
Cell Balancing	هم-ترازسازی سلول‌ها	ANN	
Cell Temperature.....	دمای سلول‌ها	ASIL.....	سطح ایمنی عملکرد خودرو
Clipping.....	بریدگی دامنه	Attention Mechanism.....	مکانیزم توجه
Coefficient of Determination – R^2 .	ضریب تبیین	Automatic Mixed Precision .	دقت ترکیبی خودکار
Commercial.....	قطعات محاسباتی تجاری	(AMP)	
Off-the-Shelf – COTS		Autoencoder – AE.....	خودرمزگذار
Computational Load	بار محاسباتی	Automotive Safety....	سطح ایمنی عملکرد خودرو
Computational Overhead.....	سربار محاسباتی	Integrity Level – ASIL	
Convolutional Neural ..	شبکه‌ی عصبی کانولوشنی	B	
Network – CNN		Back-up.....	سامانه پشتیبان
Convolutional Layers	لایه‌های کانولوشنی	Baseline Training.....	آموزش پایه
CPU.....	واحد پردازش مرکزی		

Fault	نقص یا اشکال	Critical	بحرانی
Fault Detection and Isolation – FDI	تشخیص و جداسازی اشکال	Current Sensors	حسگرهای جریان
Fault Injection	تزریق اشکال	Cyber Redundancy	افزودگی سایبری
Fault Tolerance	تحمل‌پذیری اشکال	Cyber-Physical Systems – CPSs	سامانه‌ی رایا-فیزیکی
Fault-Tolerant Control – FTC	کنترل تحمل‌پذیر اشکال		

D

Feedforward Neural Network – FNN	شبکه عصبی پیش‌خور	Data Augmentation	افزایش داده
Finite Element Method – FEM	روش اجزای محدود	Data Streaming	جریان داده‌ها
Few-Shot Learning	یادگیری با تعداد کم نمونه	Deeper Convolutional Layers	لایه‌های کانولوشنی عمیق‌تر
Fine-tuning	تنظیم دقیق	Deep Learning	یادگیری عمیق
Forget Gate	دروازه‌ی فراموشی	Disturbances	اغتشاشات
Fully Connected – FC	مدل‌های تمام‌متصل	Drift	رانس
Functional Safety	ایمنی عملکردی	Dropout	حذف تصادفی

G

Gating Mechanism	سازوکار دروازه‌ای
Generalizability	تعمیم‌پذیری
GPU	واحد پردازش گرافیکی
Graceful Degradation	تنزل کنترل شده

H

Hadamard	ضرب المان به المان
Half-precision	ممیز شناور با دقت ۱۶ بیت
Floating-point (FP16)	
Hardware	سخت‌افزار
Hardware-in-the-Loop – HIL	سخت‌افزار در حلقه
Hazards	مخاطره‌ها

E

Electric Vehicles – EVs	خودروهای برقی
Electronic Control Unit – ECU	واحد کنترل الکترونیکی
Embedded Systems	سامانه‌های نهفته
Equivalent Circuit Models – ECM	مدل‌های مدار معادل
Error	خطا
Extended Kalman Filter – EKF	پالایه کالمن توسعه‌یافته

F

Failure Mode and Effects Analysis – FMEA	تحلیل حالت و اثر خرابی
False Alarm	هشدار کاذب

Mixed Precision دقت ترکیبی
 Modeled Fault تزریق اشکال مدل‌سازی‌شده
 Injection
 MTBF میانگین زمان بین خرابی‌ها
 MTTF میانگین زمان تا خرابی
 MTTR میانگین زمان لازم برای تعمیر
 Multi-Layer Perceptron – MLP پرسپترون چندلایه
 Multiply-Accumulate عملیات ضرب – جمع
 Operations (MACs)

N

Nines Analysis تحلیل نه‌ها
 Noise نوفه
 Normal عادی
 Normalization نرمال‌سازی
 Number of Nines تعداد نه‌ها

O

One-step Ahead پیش‌بینی تک‌گام
 Online برخط
 Order of Magnitude مرتبه بزرگی
 Out-of-Distribution – OOD خارج از توزیع
 Overfitting بیش‌برازش

P

Panasonic 2170 پاناسونیک ۲۱۷۰
 Parameters مشخصه‌ها (پارامترها)
 Partial Differential ... معادله‌های دیفرانسیل جزئی
 Equations
 Particle Filter پالایه ذرات
 Penalty جریمه

I

Inference استنتاج
 Inherent Limitations محدودیت‌های ذاتی
 Initial Convolutional.... لایه‌های کانولوشنی اولیه
 Layers
 Input Gate..... دروازه‌ی ورودی
 Integrated Performability..... پایداری یکپارچه
 Integrated System..... پایداری یکپارچه سامانه
 Performability
 Isolation..... جداسازی اشکال

K

Kalman Filter پالایه کالمن

L

Latent Faults اشکال‌های پنهان
 Latency..... زمان تأخیر
 Learning Rate..... نرخ یادگیری
 Longitudinal Velocity..... سرعت طولی
 Long Short-Term . واحد حافظه طولانی کوتاه مدت
 Memory – LSTM

M

Machine Learning یادگیری ماشین
 Mamba..... مدل فضای حالت مامبا
 Markov Chain زنجیره مارکوف
 McMaster University دانشگاه مک‌ماستر
 Mean Absolute Error – خطای میانگین مطلق
 MAE
 Mean Squared Error – MSE میانگین مربعات خطا
 Mission Time افق زمانی مأموریت

Safety Circuits..... مدارهای ایمنی	Performability قابلیت اجرا
Safety Critical..... بحرانی-ایمن	Performance Degradation..... تخریب عملکرد
Series Structure..... ساختار سری	Physics-Informed... شبکه‌های عصبی آگاه از فیزیک
Series System Structure ساختار سری سامانه	Neural Networks – PINN
Shape Parameter..... مشخصه شکل	Pipeline..... خط‌لوله
Signals علائم	Pooling Layer..... لایه‌ی تجمع
Single Event Upset – SEU تک-رخدادهای اشکال	Power Converters مبدل‌های توان
Sliding Window..... پنجره لغزان	Principal Component تحلیل مؤلفه‌های اصلی
Software..... نرم‌افزار	Analysis – PCA
SOTIF ایمنی عملکرد مورد نظر (ساتیف)	
Standby Sparing واحد یدک آماده	
State of Charge – SOC..... وضعیت شارژ	
State of Health – SOH... وضعیت سلامت باتری	
State Parameters..... مشخصه‌های حالت	
Statistical Normalization..... نرمال‌سازی آماری	
Stuck-at Faults..... چسبندگی	
Supervised Learning..... یادگیری نظارت‌شده	
Support Vector Machine – .. ماشین بردار پشتیبان	
SVM	
Support Vector Regression رگرسیون بردار پشتیبان	
– SVR	
Switching..... کلیدزنی	
System زیرسامانه (سامانه)	
Systematic Faults..... اشکال‌های ناشی از طراحی	

T

Temperature Sensors..... حسگرهای دما
Tensors..... تانسورها
Thermal Runaway فرار حرارتی
Time series سری زمانی
Transfer Learning..... یادگیری انتقال
Transformer تبدیل‌کننده

R

RAM..... حافظه دسترسی تصادفی
Random..... خرابی‌های تصادفی سخت‌افزاری
Hardware Failures
Range Anxiety..... اضطراب برد
Real-time بی‌درنگ (آنی)
Real-time Constraints..... قیدهای زمانی آنی
Regularizer..... تنظیم‌گر
Reinforcement Learning..... یادگیری تقویتی
Reliability قابلیت اطمینان
Remaining Driving Range – RDR برد باقی‌مانده
Reset Gate..... دروازه‌ی بازنشانی
Residual Generation..... تولید باقیمانده
Residual Network..... شبکه باقی‌مانده
Road Vehicles —.. ایمنی هوش مصنوعی در خودرو

Safety and Artificial Intelligence

Robust مقاوم (مستحکم)
Robust Fine-tuning..... تنظیم دقیق مقاوم

S

W

Warning هشدار
Weight Decay کاهش وزن
Weighted Sum مجموع وزن‌دار
Weibull Distribution توزیع وایبول
World Health سازمان جهانی بهداشت
Organization – WHO

U

Unsupervised Learning یادگیری بدون نظارت
Update Gate دروازه‌ی به‌روزرسانی

V

Vanishing Gradient محو شدن گرادیان
Voltage Sensors حسگرهای ولتاژ
Vulnerability Factor – VF عامل آسیب‌پذیری

واژه‌نامه فارسی به انگلیسی

Inference استنتاج	آ
Robustness استحکام / مقاومت	Baseline Training آموزش پایه
Systematic Faults اشکال‌های ناشی از طراحی	Vulnerability آسیب‌پذیری
Latent Faults اشکال‌های پنهان	Real-time آنی (در لحظه)
Transient Faults اشکال‌های گذرا	
Permanent Faults اشکال‌های دائمی	ا
Range Anxiety اضطراب برد	Disturbances اغتشاشات
	Redundancy افزونگی
ب	Triple Modular افزونگی پیمانه‌ای سه‌گانه
Computational Load بار محاسباتی	Redundancy – TMR
Confidence Interval بازه اطمینان	Multiple Sensor افزونگی چندگانه‌ی حسگرها
Safety Critical بحرانی-ایمن	Redundancy
Critical بحرانی	Cyber Redundancy افزونگی سایبری
Battery Pack بسته باتری	Data Augmentation افزایش داده
Online برخط	Mission Time افق زمانی مأموریت
Remaining Driving Range – RDR برد باقی‌مانده	Bat Algorithm الگوریتم خفاش
Clipping بریدگی دامنه	Bias انحراف
Overfitting بیش‌برازش	Standard Deviation انحراف معیار
Real-time بی‌درنگ	Compliance انطباق
	Ohm اهمی
پ	Functional Safety ایمنی عملکردی
Pandas پانداز	SOTIF ایمنی عملکرد مورد نظر (ساتیف)
Panasonic 2170 پاناسونیک ۲۱۷۰	Road Vehicles — ایمنی هوش مصنوعی در خودرو
PyTorch Lightning پایتورچ لایتینگ	Safety and Artificial Intelligence

Performance Degradation.....	تخریب عملکرد	Safety Monitoring.....	پایش ایمنی
Fault Detection.....	تشخیص	Filters.....	پالایه‌ها
Anomaly Detection.....	تشخیص ناهنجاری	Particle Filter.....	پالایه ذرات
Fault.....	تشخیص و جداسازی هوشمند اشکال	Kalman Filter.....	پالایه کالمن
	Detection and Isolation – FDI	Adaptive Kalman Filter –...	پالایه کالمن تطبیقی
Error Correction.....	تصحیح خطا	AKF	
Feature Matching.....	تطبیق ویژگی	Extended Kalman Filter –	پالایه کالمن توسعه‌یافته
Spike Fault.....	تغییرهای ناگهانی	EKF	
Drift.....	تغییر تدریجی (رانس)	Thermal Monitoring.....	پایش شرایط حرارتی
Single Event Upset – SEU.	تک‌رخدادهای اشکال	Stability.....	پایداری
Generalizability.....	تعمیم‌پذیری	Integrated Performability.....	پایداری یکپارچه
Interpretability.....	تفسیرپذیری	Integrated System.....	پایداری یکپارچه سامانه
Graceful Degradation.....	تنزل کنترل شده	Performability	
Fine-tuning.....	تنظیم دقیق	Multi-Layer Perceptron – MLP	پرسترون چندلایه
Robust Fine-tuning.....	تنظیم دقیق مقاوم	GPU.....	پردازش گرافیکی
Regularizer.....	تنظیم‌گر	Sliding Window.....	پنجره لغزان
Electric Power.....	توان الکتریکی	Data Coverage.....	پوشش داده
Weibull Distribution.....	توزیع وایبول	One-step Ahead.....	پیش‌بینی تک‌گام
Residual Generation.....	تولید باقیمانده	Aging.....	پیری
Fault Injection.....	تزریق اشکال		
Modeled Fault.....	تزریق اشکال مدل‌سازی شده		

ت

	Injection	Tensors.....	تانسورها
		Transformer.....	تبدیل‌کننده
		Model Stabilization.....	تثبیت مدل
		Number of Nines.....	تعداد نُه‌ها
		Fault Tolerance.....	تحمل‌پذیری اشکال
		Sensitivity Analysis.....	تحلیل حساسیت
		Failure Mode and.....	تحلیل حالت و اثر خرابی
	Error – RMSE	Effects Analysis – FMEA	
Isolation.....	جداسازی اشکال	Principal Component.....	تحلیل مؤلفه‌های اصلی
		Analysis – PCA	
		Nines Analysis.....	تحلیل نُه‌ها

ج

Current Sensors.....	جریان
Data Streaming.....	جریان داده‌ها
Penalty.....	جریمه
Root Mean Square....	جذر میانگین مربعات خطا
	Error – RMSE
Isolation.....	جداسازی اشکال

چ

Mixed Precision دقت ترکیبی
Automatic Mixed Precision دقت ترکیبی خودکار
(AMP)
Temperature Sensors حسگرهای دما
Cell Temperature دمای سلول‌ها

Stuck-at Faults چسبندگی
Energy Density چگالی انرژی
Driving Cycle چرخه رانندگی

ح

Cyber-Physical Systems سامانه‌ی رایا-فیزیکی
CPSs
Drift رانش
Ranking رتبه‌بندی
Support Vector Regression رگرسیون بردار پشتیبان
- SVR
Finite Element Method روش اجزای محدود
FEM
Maximum Likelihood رأی‌گیری بیشینه احتمال
Voting - MLV

Hidden State حالت پنهان
Dropout حذف تصادفی
Voltage Sensors حسگرهای ولتاژ
RAM حافظه دسترسی تصادفی

خ

Maximum Likelihood رأی‌گیری بیشینه احتمال
Voting - MLV

Out-of-Distribution - OOD خارج از توزیع
Random خرابی‌های تصادفی سخت‌افزاری
Hardware Failures
Multi-task Output خروجی چند وظیفه‌ای
Error خطا
Mean Absolute Error - خطای میانگین مطلق
MAE

ز

Markov Chain زنجیره مارکوف
Sideslip Angle زاویه لغزش

Pipeline خط‌لوله
Electric Vehicles - EVs خودروهای برقی
Autoencoder - AE خودرمزگذار

س

Recurrent Structure ساختار بازگشتی
Series Structure ساختار سری
Series System Structure ساختار سری سامانه
Gating Mechanism سازوکار دروازه‌ای
Hardware سخت‌افزار
Hardware-in-the-Loop - HIL سخت‌افزار در حلقه
Computational Overhead سربار محاسباتی
Longitudinal Velocity سرعت طولی

د

Outliers داده‌های پرت
McMaster University دانشگاه مک‌ماستر
Update Gate دروازه‌ی به‌روزرسانی
Reset Gate دروازه‌ی بازنشانی
Forget Gate دروازه‌ی فراموشی
Input Gate دروازه‌ی ورودی
Output Gate دروازه‌ی خروجی

ع

Vulnerability Factor – VF.... عامل آسیب‌پذیری
Actuators..... عملگرها
Signals علائم
Normal عادی
Multiply-Accumulate عملیات ضرب-جمع
Operations (MACs)

Area Under the Curve – AUC . سطح زیر منحنی
Automotive Safety.... سطح ایمنی عملکرد خودرو
Integrity Level – ASIL
Time series سری زمانی
Scikit-learn سائیکیت-لرن
Healthy Signal سیگنال سالم
Back-up..... سامانه پشتیبان
Embedded Systems..... سامانه‌های نهفته

ف

Thermal Runaway فرار حرارتی
Catastrophic Forgetting..... فراموشی فاجعه‌بار

ش

Bidirectional.. شبکه‌های بازگشتی دوسویه دروازه‌دار
Gated Recurrent Unit – BiGRU

ق

Reliability قابلیت اطمینان
Performability قابلیت اجرا
Real-time Constraints..... قیدهای زمانی آنی
Commercial..... قطعات محاسباتی تجاری
Off-the-Shelf – COTS

Artificial Neural Network – شبکه عصبی مصنوعی
ANN
Convolutional Neural .. شبکه‌ی عصبی کانولوشنی
Network – CNN
Recurrent Neural Network – شبکه بازگشتی ساده
RNN
Residual Network..... شبکه باقی‌مانده

ک

Weight Decay..... کاهش وزن
Fault-Tolerant Control – کنترل تحمل‌پذیر اشکال
FTC
Switching..... کلیدزنی

Convolutional-LSTM. شبکه‌های پیچشی-بازگشتی
Network (CNN-LSTM)
Physics-Informed.. شبکه‌های عصبی آگاه از فیزیک
Neural Networks – PINN
Feedforward Neural شبکه عصبی پیش‌خور
Network – FNN

گ

Bottleneck..... گلوگاه

ض

Coefficient of Determination – R^2 . ضریب تبیین
Vulnerability Factor – VF... ضریب آسیب‌پذیری
Hadamard ضرب المان‌به‌المان

ل

Pooling Layer..... لایه‌ی تجمیع
Convolutional Layers لایه‌های کانولوشنی

Equations	لايه‌های کانولوشنی اولیه . . . Initial Convolutional
Inherent Limitations محدودیت‌های ذاتی	Layers
Weighted Sum مجموع وزن‌دار	لايه‌های کانولوشنی عمیق‌تر . . . Deeper Convolutional
	Layers

ن

Learning Rate نرخ یادگیری
Target Failure Rate نرخ خرابی هدف
Software نرم‌افزار
Normalization نرمال‌سازی
Statistical Normalization نرمال‌سازی آماری
Noise نوفه
Accidental Noise نوفه تصادفی
NumPy نام‌پای
Reliability Nines نه‌های اطمینان‌پذیری
Hotspots نقاط داغ
Fault نقص یا اشکال

و

Long Short-Term واحد حافظه طولانی کوتاه مدت
Memory – LSTM
Standby Sparing واحد یدک آماده
Electronic Control Unit – واحد کنترل الکترونیکی
ECU
CPU واحد پردازش مرکزی
GPU واحد پردازش گرافیکی
Calibration واسنجی
State of Charge – SOC وضعیت شارژ
State of Health – SOH وضعیت سلامت باتری
State Parameters مشخصه‌های حالت

ه

م

ماشین بردار پشتیبان . . . Support Vector Machine
SVM
مبدل‌های توان Power Converters
محو شدن گرادیان Vanishing Gradient
مخاطره‌ها Hazards
مدل‌های مدار معادل – Equivalent Circuit Models
ECM
مدل فضای حالت مامبا Mamba
مقاوم (مستحکم) Robust
مشخصه شکل Shape Parameter
مرتبه بزرگی Order of Magnitude
ممیز شناور با دقت ۱۶ بیت . . . Half-precision
Floating-point (FP16)
مدل‌های تمام‌متصل Fully Connected – FC
مدل‌های حرارتی توده‌ای Lumped Thermal Models
مدل‌های حرارتی توزیعی Distributed Thermal
Models
میانگین مربعات خطا MSE – Mean Squared Error
میانگین زمان تا خرابی . . . Mean Time To Failure
MTTF
میانگین زمان بین خرابی‌ها . . . Mean Time Between
Failures – MTBF
میانگین زمان لازم برای تعمیر . . . Mean Time To
Repair – MTTR
مکانیزم توجه Attention Mechanism
معادله‌های دیفرانسیل جزئی . . . Partial Differential

Transfer Learning	یادگیری انتقال	Artificial Intelligence – AI	هوش مصنوعی
Reinforcement Learning	یادگیری تقویتی	False Alarm	هشدار کاذب
Deep Learning	یادگیری عمیق	Warning	هشدار
Machine Learning	یادگیری ماشین	Cell Balancing	هم-ترازسازی سلول ها
Supervised Learning	یادگیری نظارت شده		
Unsupervised Learning	یادگیری بدون نظارت		
Few-Shot Learning	یادگیری با تعداد کم نمونه		

ی

Abstract

Electric vehicles face significant challenges due to their reliance on physical sensors, including high costs, additional weight, and degradation caused by sensor aging, which leads to reduced accuracy and safety over time. This research aims to replace or augment these sensors by designing a robust deep learning-based virtual sensor, thereby reducing costs and enhancing the reliability of the Battery Management System (BMS) in the face of sensor faults. To this end, a Bidirectional Gated Recurrent Unit (BiGRU) architecture is employed for the precise estimation of battery temperature. The proposed method utilizes a two-stage training strategy consisting of nominal relationship learning followed by robust fine-tuning. By incorporating physical laws into the cost function, the model's stability is guaranteed against transient and permanent faults such as drift, bias, and stuck-at errors. Evaluation using a real-world Tesla battery cell dataset demonstrates that the algorithm achieves an accuracy of 1.59°C under normal conditions. Reliability analysis indicates complete coverage of transient faults and preservation of the virtual sensor output stability under critical scenarios, such that the model behavior remains stable over a time horizon corresponding to the vehicle's service life. From an implementation perspective, the proposed model is well suited for embedded automotive systems, featuring a compact memory footprint of approximately 1.7 MB and an inference time of 264 ms, thereby satisfying real-time deployability requirements. These results demonstrate that the proposed approach can be employed as a safety-supporting feature within development processes compliant with the ISO 26262 standard.

Keywords: Virtual Sensor, Battery Management System (BMS), BiGRU, Fault Tolerance, Reliability, Performability, Overheard, Automotive Functional Safety, ISO 26262



Sharif University of Technology
Department of Computer Engineering

M.Sc. Thesis

Sensor-Based Virtual Approaches for Enhancing the Reliability of Electric Vehicles

By:

Yasamin Tavakoli

Supervisor:

Dr. Alireza Ejlali

January 2026